

El modelo Matérn

Un recorrido por la estadística, el análisis numérico y el aprendizaje automático

Emilio Porcu Moreno Bevilacqua Robert Schaback Chris J. Oates

Tabla de contenidos

Presentación	1
Resumen	1
1 Introducción	3
1.1 Configuración y notación	4
2 El modelo Matérn	7
3 Estimación y Predicción con el Modelo Matérn	9
3.1 Estimación utilizando la máxima verosimilitud	9
3.1.1 Asintóticas de dominio crecientes.	10
3.1.2 Asintóticas de dominio fijo.	10
3.2 Predicción y efecto de apantallamiento	11
3.3 Matérn sobre variedades y grafos	13
4 El Modelo Matérn en Estadística Computacional	15
4.1 Implementación como SDE	15
4.2 Implementación como SPDE	15
4.3 Verosimilitud aproximada y el Modelo Matérn	16
4.4 El modelo Matérn <i>para</i> computación bayesiana	17
5 Modelado flexible con Matérn	19
5.1 Campos aleatorios con valores escalares	19
5.2 Campos aleatorios con valores vectoriales	20
5.3 Direcciones, formas y curvas	20
6 El Modelo Matérn fuera de la estadística	21
6.1 Análisis numérico y teoría de aproximación	21
6.2 Aprendizaje automático	22
6.3 Teoría de la probabilidad y procesos estocásticos	23
7 Mejoras del Modelo Matérn	25
7.1 Modelos con soporte compacto	25
7.2 Modelos con decaimiento polinómico	26
7.3 Núcleos poliarmónicos	26
8 ¿Son útiles las mejoras del modelo Matérn?	29
8.1 Generalización Rigurosa del Modelo Matérn	29
8.2 Estimación de modelos mejorados	30
8.3 Predicción con modelos mejorados	31
8.4 Apantallamiento con modelos mejorados	31
8.5 Computación escalable	32
9 Conclusión	35
Referencias	37
10 Modelado a través de Matérn en escenarios no convencionales: la versión extendida	45

Presentación

Esta es la traducción íntegra al español de *The Matérn Model: A Journey through Statistics, Numerical Analysis and Machine Learning*, de Emilio Porcu, Moreno Bevilacqua, Robert Schaback y Chris J. Oates.

Resumen

El modelo Matérn ha sido una piedra angular de la estadística espacial durante más de medio siglo. Más recientemente, ha ocupado un lugar central en disciplinas tan diversas como el análisis numérico, la teoría de la aproximación, la estadística computacional, el aprendizaje automático y la teoría de la probabilidad. En este artículo emprendemos un recorrido por estas disciplinas basado en el modelo Matérn. Primero reflexionamos sobre su importancia para la estimación y la predicción en estadística espacial, y establecemos conexiones con otras disciplinas en las que ha ejercido influencia. Después situamos el modelo Matérn en la literatura sobre macrodatos y computación escalable: se examinan el enfoque SPDE, la aproximación de Vecchia a la verosimilitud y aplicaciones recientes en computación bayesiana. Por último, revisamos desarrollos recientes, entre ellos alternativas flexibles al modelo Matérn, cuyo desempeño comparamos en términos de estimación, predicción, efecto de apantallamiento, computación y propiedades de regularidad de Sobolev.

Palabras clave: teoría de la aproximación, soporte compacto, covarianza, núcleo, kriging, aprendizaje automático, máxima verosimilitud, espacios de Hilbert con núcleo reproductor, estadística espacial, espacios de Sobolev.

Nota editorial

La traducción conserva el contenido y la numeración conceptual del original. Las dos tablas, compuestas como material vectorial en el PDF fuente, se reproducen mediante una imagen de alta resolución de la página original para preservar exactamente sus valores y disposición.

1 Introducción

Este artículo tiene dos propósitos: por un lado, proporcionar una visión panorámica, a través de varias disciplinas, del modelo Matérn. Por otro lado, el artículo ofrece críticas constructivas sobre el papel del modelo Matérn en varias disciplinas, al tiempo que analiza modelos alternativos o más generales y su relevancia para muchos aspectos del modelado estadístico, la estimación, la predicción, la estadística computacional, el análisis numérico y el aprendizaje automático.

[70] proporciona un relato histórico del modelo Matérn. El modelo Matérn, también llamado Matérn *función de covarianza*, o Matérn *núcleo*, según el contexto, se atribuye comúnmente a [108], pero se puede encontrar con nombres alternativos en diferentes ramas de la literatura científica. El uso del modelo Matérn está muy extendido y es imposible abarcar aquí todas sus diversas aplicaciones; Nuestra revisión se centra en una selección de aplicaciones que son de especial interés e importancia. En concreto, pretendemos cubrir

1. estimación y predicción utilizando el modelo de Matérn en estadística, con énfasis en la estimación de máxima verosimilitud, la predicción kriging y el efecto de apantallamiento asociado;

2. Aplicaciones del modelo Matérn en

1. estadística computacional, incluidos los enfoques de ecuaciones diferenciales estocásticas (SDE) y ecuaciones diferenciales parciales estocásticas (SPDE), aproximación de verosimilitud, inferencia de ecuaciones diferenciales parciales (PDE) y método de Stein;

2. modelización estadística, incluidos escenarios no estándar, por ejemplo cuando no se pueden asumir la isotropía y la estacionariedad, o para modelar direcciones y curvas;

3. teoría de aproximación y análisis numérico, donde se utiliza el modelo de Matérn para construir interpolantes basados en núcleo;

4. aprendizaje automático, donde el modelo de Matérn es central en la literatura sobre modelado de procesos gaussianos; y

5. teoría de la probabilidad, donde el modelo de Matérn ha inspirado varias contribuciones basadas en propiedades de las trayectorias muestrales de procesos estocásticos asociados, en conjunto con la solución de ciertas clases de ecuaciones diferenciales estocásticas;

3. comparación con alternativas flexibles recientes al modelo Matérn, centrándose en

1. modelos mejorados con características interesantes, como soporte compacto o decaimiento polinómico;

2. precisión de la estimación asintótica, predicción mal especificada y efectos de apantallamiento;

3. las implicaciones del uso de ciertas clases de núcleos con soporte compacto dentro de la teoría de la aproximación, la estadística computacional y el aprendizaje automático.

Este artículo es novedoso por ser el primero en adoptar una visión amplia de la literatura científica a través del lente del modelo Matérn. En particular, *no* intentamos una revisión de las funciones de covarianza en general. Revisiones recientes proporcionan un panorama bastante exhaustivo de los modelos de covarianza, desde el espacio al espacio-tiempo [126], hasta las funciones de covarianza multivariadas [60] y el modelado basado en covarianza en esferas y variedades [122]. Además, si bien existen muchas aplicaciones fascinantes del modelo de Matérn en el panorama científico, no podemos esperar hacerles justicia a todas. Por lo tanto, nuestro énfasis se limita a cuestiones metodológicas y teóricas que esperamos sean relevantes en una amplia gama de disciplinas en las que se utiliza el modelo Matérn.

1.1. Configuración y notación

En todo momento, las letras en negrita se refieren a vectores y matrices, y el operador de transposición se indica como $\top$. Sea $d \in \mathbb{N}$ y $Z = \{Z(x), x \in \mathbb{R}^d\}$ un campo aleatorio gaussiano de valor real, con media cero y *función de covarianza* $K : \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$ definida a través de $K(x, y) := \text{Cov}(Z(x), Z(y))$. Las funciones de covarianza son simétricas y definidas positivas, donde en este artículo el término *definida positiva* se entiende como

$$\sum_{i=1}^n \sum_{j=1}^n c_i K(x_i, x_j) c_j \geq 0$$

para todo $c_i \in \mathbb{R}$, todo $n \in \mathbb{N}$ y todo $x_i \in \mathbb{R}^d$. Si la desigualdad anterior es estricta, entonces K se llamará definida estrictamente positiva.

Cada función definida positiva simétrica $K : \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$ define las funciones *trasladadas* $K(x, \cdot)$ en $\mathbb{R}^d$, para todos los $x \in \mathbb{R}^d$. Además, se puede definir un producto interno en dos funciones trasladadas por

$$\langle K(x, \cdot), K(y, \cdot) \rangle_{H(K)} := K(x, y), \quad x, y \in \mathbb{R}^d,$$

en términos de K sí mismo. Esto se extiende a todas las combinaciones lineales de traduce y *genera*, al completarse, un espacio de Hilbert $H(K)$ de funciones en $\mathbb{R}^d$. Este espacio se llama espacio *nativo* para K . Observe que el espacio de Hilbert permite evaluaciones de puntos continuas. $\delta_x : f \mapsto f(x)$ via a *reproduction formula*

$$f(x) = \langle f, K(x, \cdot) \rangle_{H(K)}, \quad x \in \mathbb{R}^d, \quad f \in H(K)$$

que se sigue de ([eqHKKK]). Entonces $H(K)$ se llama *núcleo reproductor del espacio de Hilbert (RKHS)* con *núcleo* K . En particular, las funciones trasladadas $K(x, \cdot)$ quedarse en cama $H(K)$, formando su finalización y siendo los representantes de Riesz de los funcionales delta δ_x . Son fundamentales para el aprendizaje automático, el análisis numérico y la teoría de la aproximación, ya que ([eqHKKK]) permite productos internos en el espacio abstracto. $H(K)$ ser explícitamente computable usando el núcleo - el llamado *truco del núcleo*. Consulte la Sección 6.1 y [166] para más detalles. Para un núcleo positivo definido y estacionario K , its Fourier transform $\hat{K}$ se puede utilizar para refundir el producto interno ([eqHKKK]) en el espacio de Hilbert $H(K)$ por

$$\langle f, g \rangle_{H(K)} = \int_{\mathbb{R}^d} \frac{\hat{f}(\omega) \overline{\hat{g}(\omega)}}{\hat{K}(\omega)} d\omega, \quad f, g \in H(K),$$

hasta un factor constante. Aquí, $\bar{g}$ denota el conjugado complejo de una función g . Observe cómo el espectro de K penaliza el espectro de las funciones en $H(K)$. Aproximadamente, el espacio de Hilbert $H(K)$ consta de funciones f para cual $\hat{f}/\sqrt{\hat{K}}$ es cuadrado integrable sobre $\mathbb{R}^d$. Las sutiles conexiones del espacio de Hilbert $H(K)$ para muestrear caminos de procesos gaussianos con función de covarianza K Aparecerá en muchos lugares de este artículo, p. en las Secciones 2, 4.4, 6.3 y 7.1. En este sentido, los núcleos son vínculos importantes entre los modelos deterministas y probabilísticos.

Un núcleo definido estrictamente positivo K se llama *estacionario* si $K(x, y) \equiv K(x - y)$. Según el teorema de Bochner [28], K es la transformada de Fourier de una medida positiva y acotada F , es decir,

$$K(x - y) = \int_{\mathbb{R}^d} e^{i(x-y, \omega)} F(d\omega), \quad x, y \in \mathbb{R}^d.$$

Aquí, $(\cdot, \cdot)$ es el producto interno en $\mathbb{R}^d$ y i es el número complejo unitario. La inversión de Fourier es posible cuando K es absolutamente integrable, en cuyo caso llamamos a la transformada de Fourier $\hat{K}$ su *densidad espectral*. Observamos que $\hat{K}$ es no negativa y es integrable. Además, la mayor parte del artículo supone estacionariedad e isotropía para la función de covarianza, K , de modo que

$$\text{Cov}(Z(x), Z(y)) = K(x - y) = \sigma^2 \varphi(\|x - y\|),$$

para $x, y \in \mathbb{R}^d$ y $\|\cdot\|$ que denota la distancia euclidiana. Aquí, suponemos φ ser continuo con $\varphi(0) = 1$. En lo que sigue, llamaremos indistintamente φ una *función* o una *función de correlación*, la última como atajo para $\varphi(\|\cdot\|)$. Por tanto, el parámetro $\sigma^2 > 0$ es la varianza de $Z(x)$, para todos $x \in \mathbb{R}^d$. Sea Φ_d denota la clase de tales funciones φ que inducen una función de covarianza K a través de la identidad ([covarianza]) *i.e.* Φ_d es la clase de funciones de correlación isotrópica continua definida en $\mathbb{R}^d$. Tales funciones tienen una representación integral precisa según [142], dado por

$$\varphi(x) = \int_0^\infty \Omega_d(rx) F_d(dr), \quad x \geq 0,$$

con F_d siendo una medida de probabilidad y

$$\Omega_d(x) = \Gamma(d/2) \left(\frac{2}{x}\right)^{d/2-1} J_{d/2-1}(x), \quad x \geq 0,$$

con $\Gamma(\cdot)$ la función gamma y J_ν la función de Bessel de primer tipo de orden $\nu > 0$ [118 formula 10.2.2]. para un miembro φ de la clase Φ_d , podemos usar que es d -transformada de Fourier variable de $\varphi(\|x - y\|)$ es nuevamente isotrópico y, por lo tanto, reducible a una fórmula integral escalar

$$\widehat{\varphi}(z) = \frac{z^{1-d/2}}{(2\pi)^{d/2}} \int_0^\infty u^{d/2} J_{d/2-1}(uz) \varphi(u) du, \quad z \geq 0,$$

lo que define su d -variar *densidad espectral isotrópica*, y asumimos que esta integral existe. Si el denominador $(2\pi)^{d/2}$ se omite, la misma fórmula es válida para la transformada radial inversa de Fourier. A lo largo, escribimos Φ_∞ para $\bigcap_{d \geq 1} \Phi_d$, la clase de funciones φ induciendo funciones radiales definidas positivas en cada d -dimensional espacio euclidiano. Por tanto, $\varphi \in \Phi_d$ si y solo si $\varphi(\|\cdot\|)$ es una función de correlación en $\mathbb{R}^d$.

2 El modelo Matérn

El *modelo Matérn*, $M_{\nu,\alpha}$, se define como [148]

$$M_{\nu,\alpha}(x) = \frac{2^{1-\nu}}{\Gamma(\nu)} \left(\frac{x}{\alpha}\right)^\nu K_\nu\left(\frac{x}{\alpha}\right), \quad x \geq 0,$$

con $\alpha > 0$ el parámetro *escala*, $\nu > 0$ los parámetros de *suavidad*, y K_ν una función de Bessel modificada de segundo tipo de orden ν [2 9.6.22]. Se puede comprobar que $M_{\nu,\alpha}(0) = 1$, de modo que [matern] es una función de correlación. Argumentos en [148][p48] muestra que $M_{\nu,\alpha}$ pertenece a la clase Φ_∞ . la función $\sigma^2 M_{\nu,\alpha}$ se denominará *función de covarianza de Matérn*, y $\sigma^2 > 0$ denotará la varianza del campo aleatorio gaussiano asociado.

La importancia de la clase Matérn surge del parámetro ν que controla la diferenciabilidad de las trayectorias muestrales del campo gaussiano asociado. Específicamente, para cualquier entero positivo k , las trayectorias muestrales de un campo gaussiano Z en $\mathbb{R}^d$ con función de correlación de Matérn son k veces diferenciables en media cuadrática (en cualquier dirección) si y solo si $\nu > k$. Además, una versión reescalada de la función de correlación de Matérn converge al núcleo exponencial gaussiano o al cuadrado como $\nu \rightarrow \infty$, es decir

$$M_{\nu,\alpha/(2\sqrt{\nu})}(x) \xrightarrow{\nu \rightarrow \infty} \exp(-x^2/\alpha^2), \quad x \geq 0,$$

siendo la convergencia uniforme en cualquier conjunto compacto de $\mathbb{R}^d$. Por este motivo, la parametrización $M_{\nu,\alpha/(2\sqrt{\nu})}$ a veces también se adopta [169].

Cuando $\nu = k + 1/2$, para k es un número entero no negativo, la función de correlación de Matérn se simplifica al producto de una función de correlación exponencial negativa con un polinomio de orden k . Por ejemplo, $M_{1/2,1}(x) = \exp(-x)$ y $M_{3/2,1}(x) = \exp(-x)(1+x)$. En general,

$$M_{k+1/2,1}(x) = \exp(-x) \sum_{i=0}^k \frac{(k+i)!}{2k!} \binom{k}{i} (2x)^{k-i}$$

por $k \in \mathbb{N}_0$. Esta forma algebraica simple de las funciones de correlación de Matérn ha contribuido sin duda a la amplia popularidad del modelo de Matérn.

Ahora estamos en condiciones de explorar en detalle las múltiples caras del modelo Matérn. La sección 3 analiza la estimación de máxima verosimilitud, la predicción de kriging y el efecto de apantallamiento, mientras que la sección 4 explora una caracterización SPDE del modelo Matérn. La sección 5 analiza el modelo Matérn como componente básico de modelos más sofisticados, mientras que la sección 6 analiza el panorama científico a través de la lente del modelo Matérn, con especial énfasis en el análisis numérico, la teoría de la probabilidad y el aprendizaje automático. La sección [sec6] presenta algunas alternativas y generalizaciones recientemente desarrolladas del modelo Matérn, mientras que la sección 8 compara estos modelos alternativos en términos de estimación, predicción y efecto de apantallamiento.

3 Estimación y Predicción con el Modelo Matérn

Sea $D \subset \mathbb{R}^d$ un subconjunto de $\mathbb{R}^d$. Considere un conjunto $X_n = \{x_1, \dots, x_n\}$ de ubicaciones (distintas) en D , en el que se observan los valores $Z_n = (Z(x_1), \dots, Z(x_n))^\top$ del campo aleatorio gaussiano Z , definido en la sección 1.1. Un problema importante tiene que ver con la *predicción* de los valores $Z(x_0)$ en una ubicación no observada $x_0 \in D \setminus X_n$. Entonces un predictor especialmente natural para $Z(x_0)$ es

$$\hat{Z}_n = c_n^\top R_n^{-1} Z_n$$

con el vector $[c_n]_i = K(x_0, x_i)$ y la *matriz del núcleo* $[R_n]_{i,j} = K(x_i, x_j)$. El predictor [blup] se puede motivar desde múltiples direcciones. Clásicamente, [blup] está motivado como el mejor predictor lineal insesgado (BLUP) para $Z(x_0)$, y a menudo se lo conoce como el predictor *kriging simple* de $Z(x_0)$ [44]. Desde una perspectiva moderna, donde el papel de la estimación insesgada se cuestiona cada vez más, podemos motivar esta elección utilizando propiedades de optimización alternativas, que incluyen:

1. es la expectativa de $Z(x_0)$ condicionada a la realización de Z_n ;
2. es la estimación óptima (es decir, la acción de Bayes) para $Z(x_0)$ basada en el conjunto de datos Z_n , bajo pérdida de error al cuadrado [116 Section 13.3];
3. produce la interpolación mínima de la norma RKHS de los datos evaluados en x_0 , por la Sección 6.1;
4. es el algoritmo para aproximar $Z(x_0)$ a partir de Z_n el que minimiza el peor de los errores en el sentido de la complejidad basada en la información [116 Section 10.2] y la teoría de aproximación (ver Sección 6.1),

por nombrar sólo algunos. El modelo Matérn proporciona un entorno natural para estudiar el rendimiento de [blup] si suponemos que Z tiene una función de covarianza isotrópica estacionaria $\sigma^2 M_{\nu, \alpha}$. La cuestión crucial de cómo seleccionar valores adecuados para los parámetros σ , α , ν se considerará primero en la sección 3.1, y luego se estudiará el rendimiento de [blup] en la sección 3.2. La posibilidad de una extensión directa del modelo de Matérn a dominios más generales, como variedades y gráficos, se analiza en la sección [3.3].

3.1. Estimación utilizando la máxima verosimilitud

La máxima verosimilitud (ML) y los métodos de estimación similares son populares en este entorno debido a la disponibilidad de métodos numéricos prácticos (incluidos los basados en gradientes) para el cálculo y la teoría clásica que sustenta la ML. Por otro lado, en el uso del ML está implícito que el modelo estadístico está bien especificado y este juicio debe hacerse caso por caso. Para limitar el alcance, nos centramos en la estimación de ML en lo que sigue. Nuestro objetivo es comprender cuándo los parámetros del modelo de Matérn pueden estimarse consistentemente a partir de datos y comprender la distribución asintótica del estimador ML. Para ello, recuerde que la función logarítmica de verosimilitud gaussiana es

$$\mathcal{L}_n(\theta) = -\frac{1}{2} \left(\log(|\sigma^2 R_n|) + \frac{1}{\sigma^2} Z_n^\top R_n^{-1} Z_n \right),$$

hasta una constante aditiva, con $\theta = (\nu, \alpha, \sigma^2)$. El estimador ML se define como

$$\hat{\theta}_n = \operatorname{argmax}_{\theta \in \mathbb{R}_+^3} \mathcal{L}_n(\theta).$$

La estimación de ML para el parámetro de varianza se puede calcular en forma cerrada como $\hat{\sigma}_n^2 = Z_n^\top R_n^{-1} Z_n / n$; conectar esta expresión a [eq:17] reduce el problema numérico a la optimización de la llamada *probabilidad concentrada* sobre $\mathbb{R}_+^2$. Sin embargo, maximizar la probabilidad logarítmica (concentrada) requiere resolver un problema de optimización no lineal, para el cual se deben utilizar métodos numéricos; consulte la Sección [4.3].

El rendimiento de la estimación ML se ha estudiado principalmente en dos límites asintóticos diferentes. Bajo *asintóticas de dominio fijo*, el dominio de muestreo D está acotado y el conjunto de ubicaciones muestreadas X_n se vuelve cada vez más denso en D . Bajo *asintóticas de dominio crecientes*, el dominio D crece con el número n de datos observados, y la distancia entre dos ubicaciones muestreadas cualesquiera está acotada desde cero. [180] tenga en cuenta que el rendimiento del estimador ML puede ser bastante diferente en estos dos marcos, como se analizará a continuación.

3.1.1. Asintóticas de dominio crecientes.

[107] hace uso de asintóticas de dominio crecientes para establecer, bajo condiciones de regularidad leve, que el estimador ML es *fuertemente consistente*, lo que significa que $\hat{\theta}_n \xrightarrow{a.s.} \theta_0$ para el parámetro *verdadero* ψ_0 . Además, establecen que el estimador ML es *asintóticamente normal*, es decir,

$$F^{1/2}(\theta_0)(\hat{\theta}_n - \theta_0) \xrightarrow{d} \mathcal{N}(0, I)$$

donde $F(\theta) = -E[\mathcal{L}_n''(\theta)]$ es la matriz de información de Fisher, cuyas entradas son

$$F(\theta)_{i,j} = \frac{1}{2} \text{tr} \left(\frac{d\Sigma_n}{d\theta_i} \Sigma_n^{-1} \frac{d\Sigma_n}{d\theta_j} \Sigma_n^{-1} \right),$$

y $\Sigma_n = \sigma^2 R_n$. Aunque nos centramos en el modelo de Matérn, observamos que este tipo de resultados asintóticos son válidos para cualquier función de correlación paramétrica que obedezca condiciones de regularidad particulares que se expresan en términos de condiciones de valores propios en la matriz de correlación y sus derivadas. [107], aunque estos pueden no ser fáciles de verificar en general (ver por ejemplo [144], para el caso exponencial). En términos generales, siempre que la extensión espacial de la región de muestreo sea grande en comparación con el rango de dependencia del campo aleatorio, las asintóticas de dominio creciente proporcionan una descripción muy precisa del comportamiento de la estimación de ML. [180; 144; 84].

3.1.2. Asintóticas de dominio fijo.

[179] consideró la estimación de ML para el modelo de Matérn bajo asintóticas de dominio fijo, lo que demuestra que cuando el parámetro de suavidad ν es conocido y fijo, ninguno de los parámetros σ^2 y α se puede estimar de manera consistente cuando $d = 1, 2, 3$. En su lugar, sólo el parámetro

$$\text{micro}_M = \sigma^2 / \alpha^{2\nu},$$

a veces denominado *microergodic* parameter [180; 148], se puede estimar consistentemente. Esto es una consecuencia de la equivalencia de las dos medidas gaussianas correspondientes, que denotamos con $P(\sigma_i^2 M_{\nu, \alpha_i})$, con $i = 0, 1$. En particular, para cualquier conjunto infinito acotado $D \subset \mathbb{R}^d$, $d = 1, 2, 3$, $P(\sigma_0^2 M_{\nu, \alpha_0})$ es equivalente a $P(\sigma_1^2 M_{\nu, \alpha_1})$ en los caminos de $Z(x), x \in D$, si y sólo si

$$\sigma_0^2 / \alpha_0^{2\nu} = \sigma_1^2 / \alpha_1^{2\nu}.$$

En cambio, para $d \geq 5$, [8] demostró la ortogonalidad de dos medidas gaussianas con diferentes funciones de covarianza de Matérn y, por lo tanto, en este caso, todos los parámetros pueden estimarse consistentemente bajo asintóticas de dominio fijo. el caso $d = 4$ ha sido estudiado recientemente en [31].

Los resultados asintóticos asociados con la estimación de ML del parámetro microergódico, nuevamente para un parámetro de suavidad conocido fijo ν , se pueden encontrar en [179] y más adelante en [84]. En particular, para un campo gaussiano de media cero definido en un conjunto infinito acotado $D \subset \mathbb{R}^d$, $d = 1, 2, 3$, con una función de covarianza de Matérn $\sigma_0^2 M_{\nu, \alpha_0}$, el estimador ML $\hat{\sigma}_n^2 / \hat{\alpha}_n^{2\nu}$ del parámetro microergódico es fuertemente consistente, *i.e.*,

$$\hat{\sigma}_n^2 / \hat{\alpha}_n^{2\nu} \xrightarrow{a.s.} \sigma_0^2 / \alpha_0^{2\nu},$$

y su distribución asintótica viene dada por

$$\sqrt{n}(\hat{\sigma}_n^2 / \hat{\alpha}_n^{2\nu} - \sigma_0^2 / \alpha_0^{2\nu}) \xrightarrow{d} \mathcal{N}(0, 2(\sigma_0^2 / \alpha_0^{2\nu})^2).$$

. En términos generales, cuando el rango de dependencia del campo aleatorio es grande con respecto a la extensión espacial de la región de muestreo, las asintóticas de dominio fijo proporcionan una descripción muy precisa del comportamiento de la estimación ML del parámetro microergódico [84]. Las extensiones de estos resultados al caso donde se observa Z con errores gaussianos se pueden encontrar en [156], mientras que los resultados para una versión espacio-temporal del modelo de Matérn se pueden encontrar en [77] y [55]. Finalmente destacamos que la estimación eficiente del parámetro microergódico asumiendo que el parámetro de suavidad es desconocido aún es un problema abierto; Algunos resultados prometedores en esta dirección se pueden encontrar en [105].

3.2. Predicción y efecto de apantallamiento

La equivalencia de medidas gaussianas dentro de la clase Matérn tiene consecuencias para la predicción de $Z(x_0)$ en una ubicación no observada $x_0 \in D \setminus X_n$; estas consecuencias se discutirán ahora. En lo que sigue, se supone que ν es conocido y solucionado, y consideramos la configuración donde σ y α están *mal especificados*. Es decir, suponemos que Z es un campo gaussiano con covarianza Matérn $\sigma_0^2 M_{\nu, \alpha_0}$, y consideramos el rendimiento del predictor [blup] cuando se utiliza un modelo Matérn $\sigma_1^2 M_{\nu, \alpha_1}$. Esta situación es típica, ya que los verdaderos parámetros σ_0 y α_0 del proceso de generación de datos serán desconocidos en general. Nuestro escenario teórico serán las asintóticas de dominio fijo.

Tenga en cuenta, primero, que [blup] no depende del valor de σ_1 , pero sí depende del valor del parámetro α_1 (y del parámetro ν , pero este parámetro es fijo). Esta dependencia se enfatizará utilizando la notación $c_n(\alpha_1)$ y $R_n(\alpha_1)$. Bajo la medida gaussiana $P(\sigma_0^2 M_{\nu, \alpha_0})$ asociada con el modelo *verdadero* $\sigma_0^2 M_{\nu, \alpha_0}$, el error cuadrático medio del predictor $\hat{Z}_n(\alpha_1)$ viene dado por

$$\begin{aligned} & \text{var}_{\alpha_0, \sigma_0^2} [\hat{Z}_n(\alpha_1) - Z(x_0)] \\ &= \sigma_0^2 \left(1 - 2c_n(\alpha_1)^\top R_n(\alpha_1)^{-1} c_n(\alpha_0) \right. \\ & \quad \left. + c_n(\alpha_1)^\top R_n(\alpha_1)^{-1} R_n(\alpha_0) R_n(\alpha_1)^{-1} c_n(\alpha_1) \right), \end{aligned}$$

mientras que si no hay ninguna especificación errónea entonces la expresión anterior se reduce a

$$\begin{aligned} & \text{var}_{\alpha_0, \sigma_0^2} [\hat{Z}_n(\alpha_0) - Z(x_0)] \\ &= \sigma_0^2 (1 - c_n(\alpha_0)^\top R_n^{-1}(\alpha_0) c_n(\alpha_0)). \end{aligned}$$

En condiciones de regularidad, y para asintóticas de dominio fijo, [146] muestra que tanto la predicción asintóticamente eficiente como la estimación asintóticamente correcta de la varianza de la predicción se mantienen cuando las dos medidas gaussianas $P(\sigma_i^2 M_{\nu, \alpha_i})$, $i = 0, 1$ son equivalentes, *es decir* [matern_equivalence]. Específicamente,

$$\frac{\text{var}_{\sigma_0^2, \alpha_0}[\widehat{Z}_n(\alpha_1) - Z(x_0)]}{\text{var}_{\sigma_0^2, \alpha_0}[\widehat{Z}_n(\alpha_0) - Z(x_0)]} \xrightarrow{a.s.} 1$$

y

$$\frac{\text{var}_{\sigma_1^2, \alpha_1}[\widehat{Z}_n(\alpha_1) - Z(x_0)]}{\text{var}_{\sigma_0^2, \alpha_0}[\widehat{Z}_n(\alpha_1) - Z(x_0)]} \xrightarrow{a.s.} 1.$$

La implicación de ([kauf3_1]) es que, según el modelo verdadero, si el valor correcto de ν se utiliza cualquier valor de α_1 dará eficiencia asintótica. La implicación de ([kauf3_3]) es más fuerte y garantiza que el uso del predictor mal especificado bajo los modelos correcto y mal especificado es asintóticamente equivalente desde el punto de vista del error cuadrático medio. Tenga en cuenta que este tipo de resultados no considera la incertidumbre asociada con los parámetros de covarianza del modelo mal especificado.[84] demuestre que ([kauf3_3]) todavía se cumple considerando el estimador ML de la varianza $\hat{\sigma}_n^2 = Z_n^\top R_n^{-1}(\alpha_1) Z_n / n$ en su lugar σ_1^2 .

También se han establecido condiciones de equivalencia de dos medidas gaussianas basadas en una versión espacio-temporal [77] y bivariada [14] del modelo de Matérn. A continuación, consideramos un aspecto prácticamente importante de la predicción; el llamado efecto de apantallamiento.

Efecto de cribado. El *efecto de cribado* se refiere al fenómeno en el que el predictor [blup] depende casi exclusivamente de aquellas observaciones que se encuentran más cercanas al predictand [149]. Como tal, el efecto de apantallamiento es una herramienta importante que se puede utilizar para mitigar la carga computacional de evaluar [blup] en presencia de grandes conjuntos de datos. Esta cuestión ha sido tradicionalmente un tema importante en geoestadística [109; 110; 111; 41]. De hecho, [109] [110], en la Escuela de Geoestadística de la Escuela de Minas, desarrolló una primera formalización del efecto de cribado, refiriéndose a situaciones en las que las observaciones situadas lejos del pronóstico reciben un peso kriging cero. La definición de Matheron tiene una conexión directa con la propiedad de Markov en la recta real, que ocurre cuando se realiza kriging bajo el modelo exponencial (de hecho, $M_{1/2, \alpha}$).

M. Stein [148; 149; 151; 152] adopta una definición alternativa del efecto de apantallamiento que se describirá a continuación. Sea Z un campo aleatorio gaussiano de media cuadrática continua, media cero y débilmente estacionario en $\mathbb{R}^d$. Sea $e(X_n)$ el error del predictor [blup] de $Z(x_0)$ basado en Z_n . Se considerarán dos opciones para el conjunto X_n de ubicaciones de observación y, para este fin, dejaremos que F_ϵ, N_ϵ sean conjuntos, indexados por $\epsilon > 0$, de modo que N_ϵ contenga las observaciones más cercanas al predictando y F_ϵ las observaciones más lejanas. Luego [149] dice que N_ϵ *excluye asintóticamente* F_ϵ cuando

$$\lim_{\epsilon \downarrow 0} \frac{\mathbb{E} e(N_\epsilon \cup F_\epsilon)^2}{\mathbb{E} e(N_\epsilon)^2} = 1.$$

Se puede encontrar una discusión exhaustiva de las implicaciones de esta definición en [128], donde se informan diferencias no triviales entre dominio fijo y asintóticos de dominio creciente.

La configuración espacial del punto de muestreo X_n determina si se mantendrá el efecto de apantallamiento. [128] se refiere a un *esquema regular* como aquel para el cual $F_\epsilon = \{\epsilon(x_0 + j)\}$, $j \in \mathbb{Z}^d$ y N_ϵ son la restricción de F_ϵ a alguna región fija con x_0 en su interior, asumiendo $x_0 \notin \mathbb{Z}^d$. Para esquemas regulares, [149] estableció ([def-screening]) siempre que *el espectro $\widehat{K}$ varía regularmente en el infinito [27] en todas las direcciones con un índice de variación común* [citado de [128]]. Sin embargo, esta condición puede no ser útil para procesos espacio-temporales, donde las propiedades de diferenciabilidad en las coordenadas espacio-temporales no son necesariamente idénticas. Para superar este problema, consideramos en su lugar un *esquema irregular*: para que $x_1, \dots, x_n$ sea elementos distintos de $\mathbb{R}^d$, $y_1, \dots, y_N$ sean elementos distintos de $\mathbb{R}^d$, $x_0 = 0 \in \mathbb{R}^d$ y $y_0 \in \mathbb{R}^d$ sean distintos de cero, tenemos $N_\epsilon = \{\epsilon x_1, \dots, \epsilon x_n\}$ y $F_\epsilon = \{y_0 + \epsilon y_1, \dots, y_0 + \epsilon y_N\}$. La *hipótesis de Stein* [denominada en [128]]

$$\forall R > 0, \quad \lim_{\|\omega\| \rightarrow \infty} \sup_{\|\tau\| < R} \left| \frac{\widehat{K}(\omega + \tau)}{\widehat{K}(\omega)} - 1 \right| = 0,$$

proporciona una condición suficiente para el efecto de apantallamiento en este entorno (bajo algunas condiciones adicionales leves en $\widehat{K}$ y N_ϵ), que se puede verificar en dimensiones $d = 1$ y $d = 2$ para campos aleatorios continuos pero no diferenciables de media cuadrática, para algunos diseños específicos N_ϵ [151]. El modelo Matérn con $K = M_{\alpha,\nu}$ admite una expresión simple para su espectro[2 11.4.44]:

$$\widehat{M}_{\nu,\alpha}(z) = \frac{\Gamma(\nu + d/2)}{\pi^{d/2}\Gamma(\nu)} \frac{\alpha^d}{(1 + \alpha^2 z^2)^{\nu+d/2}}, \quad z \geq 0,$$

a partir del cual se puede verificar [condition1].

De este modo se puede establecer el efecto de cribado para el modelo de Matérn, tanto bajo esquemas regulares como irregulares, justificando el uso de aproximaciones “locales” al predictor [blup].

3.3. Matérn sobre variedades y grafos

Sea M una variedad general. Una pregunta pragmática es si la función de correlación de Matérn [matern] se puede componer con una métrica adecuada g , definida en la variedad, para preservar la precisión positiva sobre M . Para el caso de la esfera, una métrica natural es la distancia geodésica; la longitud del arco que conecta cualquier par de puntos ubicados sobre la capa esférica. Para esta métrica, $(x, y) \mapsto M_{\nu,\alpha}(g(x, y))$ es una función de correlación solo para $0 < \nu \leq 1/2$ [63]. Esta limitación se enfatiza en [3], quien propone la familia F , un modelo válido en la esfera y que tiene las mismas propiedades que la función de Matérn en términos de diferenciabilidad cuadrática media y dimensión fractal. La función Matérn en otras variedades generales ha sido estudiada por [98]. [69] propone una expansión espectral para definir una función de covarianza que imita el modelo de Matérn, pero [101] critica esta construcción por ser incorrecta ya que la expansión espectral no reproduce las mismas propiedades del modelo de Matérn.

Lamentablemente, parece que la aplicabilidad limitada del modelo Matérn en cualquier espacio que no sea una superficie plana se extiende también a entornos más abstractos. Un elegante argumento de incrustación isométrica en [9] demuestra que la restricción $0 < \nu \leq 1/2$ es necesaria cuando el espacio de entrada es un gráfico con aristas euclidianas. Un argumento más general en [112] demuestra que la misma restricción se hereda para un espacio cuasi métrico general dotado de una métrica geodésica. El notable esfuerzo de [30] proporciona un modelo que alguna vez es diferenciable en gráficos métricos. Es razonable concluir que, en general, se necesita alguna forma del enfoque SPDE, que analizamos a continuación en la sección 4.2, para extender el modelo de Matérn a una variedad general.

4 El Modelo Matérn en Estadística Computacional

Esta sección explora la interacción del modelo Matérn con las estadísticas computacionales, comenzando con métodos numéricos para *implementación* del modelo Matérn (Secciones 4.1, 4.2 y [4.3]), y luego pasando a los usos del modelo Matérn para *facilitar* el cálculo numérico en sí (Sección 4.4).

4.1. Implementación como SDE

El modelo de Matérn admite una representación en *espacio de estados* como un SDE, lo que permite emplear técnicas computacionales eficientes de la literatura sobre procesamiento de señales para simulación, estimación y predicción. En efecto, centrándose en la dimensión $d = 1$, y dejando

$$\mathbf{Z}(x) = (Z, dZ/dx, \dots, d^k Z/dx^k),$$

el modelo Matérn $\mathcal{M}_{\nu, \alpha}$ con $\nu = k + 1/2$ admite la caracterización

$$d\mathbf{Z} = \begin{pmatrix} 0 & 1 & & \\ & \vdots & \ddots & \\ & & 0 & 1 \\ -a_0 & -a_1 & \dots & -a_{k-1} \end{pmatrix} \mathbf{Z} dx + \begin{pmatrix} 0 \\ \vdots \\ 0 \\ 1 \end{pmatrix} dW$$

dónde $a_i = {}_{k+1}C_i \cdot \alpha^{-k-1+i}$, el C_i son coeficientes binomiales, y $W(x)$ representa un proceso de ruido blanco de media cero en $x \in \mathbb{R}$ [73]. La ventaja de las formulaciones de espacio de estados es que tanto la estimación como la predicción se pueden realizar en un *único paso* a través de los datos, en niveles lineales. $O(n)$ costo, utilizando ecuaciones de actualización familiares de Kalman como se describe en [135] y con más detalle en el Capítulo 6 de [75]. Se pueden encontrar caracterizaciones similares para dimensiones superiores, incluidas versiones espacio-temporales del modelo Matérn, en [135], aunque observamos que estos conservan la complejidad lineal sólo en el número de pasos de tiempo; la complejidad es cúbica en el tamaño de la cuadrícula espacial. El enfoque SPDE puede ofrecer una solución a este respecto, y lo analizamos a continuación.

4.2. Implementación como SPDE

Una de las principales razones de la continua popularidad del modelo Matérn es la disponibilidad de métodos numéricos eficientes y escalables para la simulación, debido en gran parte a [102]. Estos autores consideran la SPDE

$$(\alpha^{-2} - \Delta)^{\gamma/2} Z(x) = W(x), \quad x \in \mathbb{R}^d,$$

dónde $\alpha > 0$, Δ es el laplaciano, y W es un ruido blanco gaussiano en $\mathbb{R}^d$, de modo que $\text{Cov}(W(A_1), W(A_2)) = |A_1 \cap A_2|$, dónde A_i son subconjuntos de $\mathbb{R}^d$, $i = 1, 2$ y donde $|\cdot|$ es la integral de volumen. [167] y [168] demostró que la solución a [SPDE] es un campo gaussiano con covarianza Matérn $\sigma^2 \mathcal{M}_{\nu, \alpha}$ con parámetros α (como antes) y

$$\sigma^2 = \frac{\Gamma(\nu) \alpha^{2\nu}}{\Gamma(\nu + d/2) (4\pi)^{d/2}}, \quad \nu = \gamma - d/2.$$

Esta perspectiva ofrece dos ideas; En primer lugar, las herramientas desarrolladas para la aproximación numérica de las SPDE pueden aplicarse al modelo de Matérn y, en segundo lugar, existe un camino claro para generalizar la definición del modelo de Matérn a cualquier variedad (planar o no plana) en la que se pueda definir la SPDE análoga. (Por ejemplo,[78] tomar esta perspectiva para generalizar el modelo de Matérn al ámbito $\mathbb{S}^d$.)

Para proporcionar una aproximación computacionalmente conveniente a ([SPDE]), [102] consideró la solución débil a ([SPDE]) y la aproximación de la solución débil utilizando funciones básicas con soporte compacto sobre un dominio compacto $\Omega \subset \mathbb{R}^d$ (específicamente, se utilizó una aproximación *Galerkin* usando funciones de base de elementos finitos). Como resultado, los autores establecen una ruta formal para la aproximación del campo aleatorio Z con un campo aleatorio *Gauss–Markov* que tiene una matriz de precisión *dispersa*. El álgebra matricial dispersa permite una simulación rápida de realizaciones del campo aleatorio de Matérn y una evaluación rápida de la probabilidad [eq:17] (aunque no una evaluación rápida del gradiente de probabilidad).

La elección del dominio Ω introduce efectos de límite que deben mitigarse cuidadosamente. [87] [37] proporciona una solución para el caso en el que γ es un número entero; el caso no entero se considera en [30]. La extensión del campo Matérn basado en SPDE al espacio-tiempo la proporciona [39] y posteriormente [15] [42], mientras que el caso multivariado de Matérn se ha explorado en [33]. [92] ha proporcionado aproximaciones alternativas basadas en los métodos de Galerkin en variedades. [121] propone un enfoque interesante que permite trabajar en variedades con grandes conjuntos de datos. El interés por esta literatura es dual. Por un lado, los aspectos técnicos relacionados con la representación en dimensión finita de campos aleatorios gaussianos son extremadamente interesantes *per se*. Por otro lado, este grupo de autores en realidad está motivado por proporcionar herramientas para una computación eficiente. Esto lo atestiguan los paquetes existentes relevantes (R-INLA, inlabru y rSPDE, por ejemplo) y nos remitimos a la revisión de [101].

[133] intenta explicar el equilibrio entre precisión y escalabilidad en la aproximación numérica del modelo Matérn. Recuerde que, en el enfoque SPDE [102], Z en ([SPDE]) se aproxima numéricamente utilizando un proceso gaussiano

$$Z_\delta(x) = \sum_{k=1}^{n_\delta} \omega_k \epsilon_k(x), \quad x \in \Omega,$$

dónde ϵ_k son funciones de base de elementos finitos y el vector $\omega = (\omega_1, \dots, \omega_{n_\delta})^\top$ es gaussiano multivariado con media cero y con una matriz de precisión dispersa. La precisión de la aproximación. Z_δ depende de (a) el soporte compacto de las funciones de base de elementos finitos, (b) los efectos de frontera debidos al dominio Ω , y (c) por el ancho de malla δ que determina la cardinalidad n_δ en ([delta]). La mayor parte de la literatura anterior ha considerado ([delta]) con n_δ proporcional al tamaño de la muestra n del conjunto de datos que se está modelando.[133] adoptar un enfoque asintótico de dominio fijo para explicar cuándo $n_\delta \ll n$ podría ser una estrategia legítima. Para ello, consideran la regresión del proceso gaussiano y trabajan bajo el marco de tasas de contracción bayesianas. Sus resultados justifican escalas específicas de n_δ con $n_\delta = o(n)$, siempre que la suavidad ν es suficientemente alto.

Recientemente se tomó un camino diferente hacia los campos aleatorios SPDE y Gauss-Markov en [134], que adopta discretizaciones de SPDE basadas en gráficos. Este enfoque puede resultar adecuado para trabajar con nubes de puntos discretas y no estructuradas, como en tareas de aprendizaje automático donde los datos pertenecen a una variedad de baja dimensión definida implícitamente. Una segunda ventaja de este enfoque es que no se requiere una triangulación explícita del dominio.

4.3. Verosimilitud aproximada y el Modelo Matérn

Al estimar los parámetros del modelo Matérn usando ML [eq: max like], se requiere optimización numérica. Aunque se pueden utilizar rutinas de optimización genéricas, un enfoque a menudo mejor es construir primero una aproximación precisa pero barata a la probabilidad, que luego puede maximizarse más fácilmente. De hecho, las probabilidades aproximadas son esenciales cuando se trata de grandes conjuntos de datos, ya que la evaluación de ([eq:17]) requiere calcular la inversa y el determinante de la matriz de correlación, generalmente mediante la descomposición de Cholesky con complejidad $O(n^3)$ y costo de almacenamiento $O(n^2)$.

Quizás la aproximación más exitosa sea el *método de Vecchia* [163], que ha atraído una notable atención en los últimos tiempos [inc. [147]; 48; 49; 67; 47]. La aproximación de Vecchia se puede utilizar con cualquier modelo de correlación y su idea básica es reemplazar ([eq:17]) con un producto de distribuciones condicionales gaussianas, en las que cada distribución condicional involucra solo un pequeño subconjunto de datos. Esta aproximación requiere que los datos estén *ordenados* y que se especifique el número m de datos ‘anteriores’ sobre los cuales condicionar. Generalmente, un m más grande implica una aproximación más precisa y computacionalmente costosa, mientras que la elección del orden afecta la precisión de la aproximación [67]. El método Vecchia proporciona una aproximación dispersa al factor de Cholesky de la matriz de precisión, de modo que la probabilidad aproximada se puede calcular en tiempo $O(nm^3)$ y con costo de almacenamiento $O(nm^2)$. Consulte la revisión reciente de [83] para obtener más detalles. La verosimilitud de Vecchia puede verse como un ejemplo específico de una clase más general de métodos de estimación llamados verosimilitud cuasi o compuesta [103; 162] que se han utilizado ampliamente para la estimación de campos gaussianos con el modelo de Matérn [52; 26; 13].

Un método alternativo para mitigar la carga computacional de la estimación de ML es la *reducción gradual de la covarianza* [59]. La idea básica es multiplicar el modelo de Matérn con una función de correlación con soporte compacto, lo que da como resultado un modelo de Matérn “modificado” con soporte compacto. Esto induce dispersidad en la matriz de covarianza asociada, de modo que los algoritmos para matrices dispersas pueden explotarse para una evaluación computacionalmente eficiente de la descomposición de Cholesky [59]. Sin embargo, algunos autores [25; 23] sugieren que el tapering podría ser un enfoque obsoleto en vista de que recientemente se han propuesto modelos flexibles con soporte compacto que incluyen el modelo Matérn como caso especial; consulte la sección 8. Una revisión exhaustiva de las aproximaciones de probabilidad está fuera del alcance de este documento, por lo que remitimos al lector a [154] y [74] para obtener más detalles.

4.4. El modelo Matérn para computación bayesiana

En la última década ha habido un interés creciente en el uso de métodos núcleo para resolver PDE. Considere un sistema

$$\begin{aligned} \mathcal{A}u &= f && \text{en } \Omega \\ \mathcal{B}u &= g && \text{sobre } \partial\Omega \end{aligned}$$

especificado por una ecuación diferencial que involucra $\mathcal{A}$ y f , y condiciones iniciales o de contorno especificadas por $\mathcal{B}$ y g . Se remonta al menos a [57] en el contexto determinista, y reinterpretado a través de una lente bayesiana por autores como [43], se puede buscar una aproximación a la solución fuerte $u : \Omega \rightarrow \mathbb{R}$ modelando u como *a priori* un campo aleatorio gaussiano y condicionando ese campo para satisfacer la ecuación diferencial en ubicaciones $\{x_1, \dots, x_m\} \subset \Omega$ y satisfacer las condiciones de contorno en ubicaciones $\{x_{m+1}, \dots, x_n\} \subset \partial\Omega$. La media condicional de este proceso coincide con el método de *colocación simétrica* introducido por [57], a la que volvemos en la Sección 6.1, mientras que la varianza condicional proporciona una cuantificación probabilística de la incertidumbre para la solución, expresando la incertidumbre que queda como resultado de usar solo un presupuesto computacional finito. Para implementar estos métodos, se requiere un proceso gaussiano cuyas trayectorias de muestra posean suficiente regularidad para la operación de condicionamiento en la derivada. $\mathcal{A}u$ estar bien definido. Por otro lado, asumir una suavidad excesiva podría llevar a una cuantificación de la incertidumbre excesivamente confiada. Por lo tanto, se requiere un núcleo con suavidad personalizable, que pueda adaptarse a la ecuación diferencial en cuestión. La clase Matérn satisface este requisito, pero no es la única que lo hace; Continuamos la discusión de este punto en la Sección 7.

Una PDE específica que ha recibido considerable atención recientemente en la comunidad estadística bayesiana es la *ecuación de Stein*, para la cual $\mathcal{A}u = c + p^{-1} \nabla \cdot (p \nabla u)$, donde p es la función de densidad de probabilidad de una distribución posterior de interés, f es una función cuya expectativa posterior buscamos calcular y c es una constante. Si la ecuación de Stein tiene solución, entonces c debe ser el valor de la expectativa posterior que buscamos. Esto ha motivado varios esfuerzos para resolver numéricamente la ecuación de Stein, como una alternativa más directa a aproximar primero p (por ejemplo usando la cadena de Markov Monte Carlo) y luego usar la aproximación de p para aproximar la expectativa de interés. En este contexto, los métodos del núcleo se usan típicamente [117; 145] y, en particular, el núcleo debe tener una suavidad dos órdenes mayor que la de la función f cuya expectativa es de interés, ya que la ecuación de Stein es una PDE de segundo orden. La

generalización de la ecuación de Stein a variedades de Riemann se consideró en [19], quien abogó por el uso de núcleos con suavidad personalizable que reproducen espacios de funciones de Sobolev en la variedad, como la (generalización múltiple del) modelo Matérn. La conexión entre el modelo Matérn y los espacios de Sobolev se establece en el apartado 6.1.

5 Modelado flexible con Matérn

Se podría objetar que el modelo de Matérn no es lo suficientemente flexible para muchas aplicaciones estadísticas, ya que está limitado a campos aleatorios con valores escalares que son estacionarios, isotrópicos y gaussianos. Sin embargo, el modelo Matérn también es un componente importante para muchos modelos más sofisticados, algunos de los cuales se describirán a continuación. Ésta es una literatura rica y nuestra discusión es necesariamente sucinta; se puede encontrar una versión ampliada de esta sección en el Apéndice 10 del Material complementario.

5.1. Campos aleatorios con valores escalares

Comencemos analizando modelos para campos aleatorios con valores escalares que se basan en el modelo de Matérn. Tenga en cuenta que se pueden introducir trivialmente funciones medias distintas de cero en el modelo de Matérn, o combinar (de forma aditiva o multiplicativa) núcleos para obtener un núcleo potencialmente más expresivo; No nos detendremos en ninguno de los dos puntos.

Para relajar el supuesto de isotropía del modelo de Matérn, [7] considera mezclas de escala que tienen en cuenta direcciones preferenciales en las que se desarrolla la dependencia espacial. Por otro lado, el caso de los modelos espacio-temporales requiere un tratamiento especial, y las versiones no separables del núcleo Matérn se describen en [62] [178].

El supuesto de estacionariedad se relajó de manera paramétrica en [119] y luego de manera no paramétrica en [132]. En [170] se informó sobre un intento de lograr un equilibrio entre la manejabilidad computacional de los modelos paramétricos y la flexibilidad de los modelos no paramétricos, quien propuso *input warping* para transformar las entradas al modelo Matérn utilizando una red neuronal.

La suposición gaussiana se puede relajar mediante *deformación de salida*, es decir, transformación de la forma $\tilde{Z}(x) = w(Z(x))$ donde $w(\cdot)$ es un mapa no lineal de $\mathbb{R}^d$ a $\mathbb{R}^d$. La función de covarianza de $\tilde{Z}$ no será Matérn en general, cuando la función de covarianza de Z sea Matérn, pero si w es suficientemente regular, entonces las propiedades de suavidad de Z se transfieren a $\tilde{Z}$. La pregunta de si existen procesos no gaussianos cuya función de covarianza sea, sin embargo, de clase Matérn fue respondida positivamente en [1]. [174] ha propuesto campos aleatorios *transgaussianos* con función de covarianza Matérn. [29] y posteriormente [164] proporcionaron construcciones basadas en SPDE para campos Matérn no gaussianos. Las clases generales de campos no gaussianos con covarianza $g(M_{\nu,\alpha})$, para $g(\cdot)$, una función adecuada que preserve las propiedades positivas de definición y suavidad del modelo de Matérn, han sido proporcionadas, por ejemplo, por [120] [173; 24; 113].

Una extensión importante del modelo Matérn, que ha recibido atención reciente, son los campos aleatorios en espacios para los cuales las nociones clásicas de suavidad no están bien definidas. Por ejemplo, [9] considere gráficos con bordes euclidianos, equipados con la distancia geodésica sobre el gráfico o la métrica de resistencia. [112] proporciona una generalización de esta configuración considerando espacios cuasimétricos. [Bolin, Simas y Wallin \(2022\)](#) adopta un enfoque diferente para crear campos aleatorios con su estructura de covarianza en gráficos métricos. La versión espacio-temporal del modelo de Matérn, para gráficos con aristas euclidianas, ha sido considerada por [155] y [127]. Estos esfuerzos amplían considerablemente la aplicabilidad del modelo Matérn.

La función de covarianza de Matérn decae exponencialmente con la distancia, lo que puede resultar inadecuado para modelar procesos que implican una larga memoria. Se han desarrollado varios enfoques para modificar las colas de la función de correlación de Matérn preservando al mismo tiempo muchas de sus características deseables; los describimos en la sección 7.

[68] considera campos aleatorios gaussianos definidos para las celosías $\mathbb{Z}^d$ con una función de covarianza que es la restricción de la covarianza de Matérn a $\mathbb{Z}^d$. El espectro resultante es una versión suavizada de la densidad espectral asociada con la covarianza de Matérn. Para esta situación específica, la aproximación SPDE puede

sobreestimar la escala, α . Sin embargo, no está claro cómo se extiende este mensaje a los campos gaussianos que se indexan continuamente en $\mathbb{R}^d$.

5.2. Campos aleatorios con valores vectoriales

Ha habido una gran cantidad de enfoques relacionados con el modelado espacial multivariado y se remite al lector a [60]. Aquí, la función de covarianza isotrópica $K : [0, \infty) \rightarrow \mathbb{R}^{p \times p}$ tiene un valor matricial. Los elementos de la diagonal, K_{ii} , se denominan funciones de *autocovarianza*, y los elementos K_{ij} , $i \neq j$, se denominan funciones de *covarianza cruzada*. [64] propuso un modelo Matérn multivariado

$$K_{ij}(x) = \sigma_{ii}\sigma_{jj}\rho_{ij}M_{\nu_{ij}, \alpha_{ij}}(x), \quad x \geq 0,$$

dónde σ_{ii}^2 es la varianza de Z_i , el i ésimo componente de un campo aleatorio multivariado en $\mathbb{R}^p$, y ρ_{ij} es el coeficiente de correlación colocado. Hay restricciones en los parámetros. ν_{ij} , α_{ij} y ρ_{ij} requerido para asegurar una definición positiva y, a menudo, las restricciones sobre los coeficientes de correlaciones colocadas ρ_{ij} son bastante estrictos. Esta última observación ha motivado enfoques alternativos, y se remite al lector a [11] y más recientemente a [54]. Las extensiones a las estructuras multivariadas espacio-temporales de Matérn han sido proporcionadas por [6] y a través de un enfoque técnico por [125]. Las funciones multivariadas no estacionarias de Matérn han sido propuestas por [88]. Los modelos multivariados de Matérn con efecto *hoyuelo* han sido estudiados por [4]; un ‘hoyuelo’ en un modelo de covarianza espacio-temporal se refiere al caso en el que $\text{Cov}(Z(x, t), Z(x', t'))$ es más grande que $\text{Cov}(Z(x, t), Z(x', t))$, que requiere un tratamiento matemático especial.

El modelado multivariado de Matérn en gráficos ha sido investigado recientemente en [51], quien propone una clase de procesos gaussianos gráficos multivariados a través de *costuras*, una construcción que obtiene funciones de covarianza multivariadas del gráfico y garantiza independencia condicional a nivel de proceso entre variables. Cuando se combina con el modelo de Matérn, la unión produce un proceso gaussiano multivariado cuyos componentes univariados son procesos gaussianos de Matérn y que concuerda con la independencia condicional a nivel de proceso como lo especifica el modelo gráfico. La unión puede ofrecer enormes ganancias computacionales y reducción de dimensiones de parámetros. [97] propuso recientemente un enfoque ingenioso para la construcción del proceso gaussiano que involucra la función de covarianza de Matérn, quien consideró un espacio de producto que involucra el espacio euclidiano de dimensión d cruzando un conjunto abstracto que permite indexar etiquetas de grupos.

5.3. Direcciones, formas y curvas

El modelo de Matérn tiene un papel importante en el estudio de procesos direccionales, formalizando [18] las nociones de *procesos en diferencias finitas* direccionales y *procesos derivados direccionales* con especial énfasis en el modelo de Matérn. El modelo Matérn también tiene un papel en el análisis de formas, donde [16] introdujo *wombling bayesiano* para medir gradientes *espaciales* relacionados con curvas a través de límites de ‘wombling’, y el enfoque se llevó más allá en [71]. Las propiedades de suavidad del modelo Matérn se adaptan perfectamente a una estructura de este tipo. [131] ha propuesto enfoques de modelado de gradientes *temporales* utilizando el modelo Matérn. En relación con estos enfoques, el parámetro de suavidad ν del modelo Matérn juega un papel central en el artículo reciente de [71], quien analiza superficies aleatorias para explicar la dependencia latente dentro de una variable de respuesta de interés.

Esto representa un breve recorrido por las aplicaciones *estadísticas* del modelo Matérn, pero su alcance va mucho más allá de las estadísticas, y a continuación exploramos la importancia del modelo Matérn en campos relacionados.

6 El Modelo Matérn fuera de la estadística

Esta sección explora el impacto del modelo Matérn en el análisis numérico y la teoría de la aproximación (Sección 6.1), el aprendizaje automático (Sección 6.2) y la teoría de la probabilidad (Sección 6.3).

6.1. Análisis numérico y teoría de aproximación

El problema considerado aquí es *reconstruir* una función de valor real f definida en un dominio $D \subset \mathbb{R}^d$ a partir de *valores de datos* dados $y_i = f(x_i)$ disponibles en un conjunto $X_n = \{x_1, \dots, x_n\}$ de *ubicaciones de datos* distintas. A diferencia de la exposición estadística de la sección 3.1, desde el punto de vista del análisis numérico no se supone que estos datos sean aleatorios de ninguna manera. Sin embargo, muchas de las expresiones matemáticas que anteriormente motivamos desde una perspectiva estadística aparecen también en la solución de esta tarea numérica. El vector de datos Z_n se reinterpreta como $Z_n = (f(x_1), \dots, f(x_n))^T$ y la tarea es aproximar el valor $f(x)$ de la función desconocida f en una ubicación sin muestrear $x \in D \setminus X_n$. Una solución natural es un interpolante de norma mínima

$$s_{f, X_n, K} = \arg \min_{s \in \mathcal{H}(K)} \|s\|_{\mathcal{H}(K)} \quad \text{s.t.} \quad s(x_i) = f(x_i), \quad i = 1, \dots, n,$$

que recordamos fue la tercera propiedad de optimización a la que se hace referencia en la Sección 3. Así, usando nuevamente la *matriz núcleo* $R_n = [K(x_i, x_j)]_{i,j=1}^n$, el sistema $R_n c_n = Z_n$ se resuelve para un vector de coeficiente fijo c_n que determina una combinación lineal

$$s_{f, X_n, K}(x) = \sum_{i=1}^n c_i K(x_i, x), \quad x \in D,$$

en el lapso del *traduce* $K(x_i, \cdot)$. Esto se desprende fácilmente de la fórmula de reproducción ([eqrepro]) y ([eqHKKK]). La fórmula anterior es idéntica a ([blup]) al configurar $x = x_0$, y el valor resultante $s_{f, X_n, K}(x)$ se interpreta como una aproximación numérica a $f(x)$. La función de probabilidad logarítmica ([eq:17]) puede verse de manera equivalente como una penalización de la norma del interpolante, ya que $\|s_{f, X_n, K}\|_{H(K)}^2 = Z_n^\top R_n^{-1} Z_n$.

El cuarto principio de optimización en la sección 3 corresponde aquí al hecho de que la norma del error funcional $\epsilon_x : f \mapsto f(x) - s_{f, X_n, K}(x)$ en el espacio dual $\mathcal{H}(K)^*$ de $H(K)$ es mínima bajo todos los algoritmos de reconstrucción lineal en $H(K)$ que utilizan los mismos datos Z_n . La herramienta clave es la *función de potencia* P_{K, X_n} , definida para todos los $x \in D$ por

$$P_{K, X_n}(x) = \sup \left\{ f(x) : f \in H(K), f(X_n) = 0, \|f\|_{H(K)} \leq 1 \right\}$$

Tiene la propiedad $P_{K, X_n}(x) = \|\epsilon_x\|_{H^*(K)}$ y conduce a límites de error óptimos de la forma

$$|f(x) - s_{f, X_n, K}(x)| \leq P_{K, X_n}(x) \|f\|_{H_K}.$$

para todo $x \in D$ y $f \in H(K)$. Se puede calcular numéricamente utilizando la matriz del núcleo basada en $X_n \cup \{x\}$, pero omitimos el detalle. Sorprendentemente, la función de potencia coincide con la raíz cuadrada de

la *varianza kriging*[141], dando la varianza del error de kriging en x para ubicaciones de datos determinadas X_n y núcleo K .

El análisis del error de aproximación en este contexto se reduce así al análisis de la función de potencia y, a su vez, al análisis del espacio $\mathcal{H}(K)$. De ([eqHK]) y ([stein1]), el RKHS generado por el núcleo Matérn $M_{\nu,1}$ tiene el producto interno

$$\langle f, g \rangle_{H(M_{\nu,1})} = \int_{\mathbb{R}^d} \frac{\hat{f}(\omega) \overline{\hat{g}(\omega)}}{(1 + \|\omega\|^2)^{\nu+d/2}} d\omega$$

hasta constantes, que reconocemos como el producto interno del *espacio de Sobolev* clásico $W_2^{\nu+d/2}(\mathbb{R}^d)$. Según el teorema de incrustación de Sobolev, los elementos de este espacio son funciones continuas bien definidas siempre que $\nu > 0$. Este espacio es un escenario canónico para el análisis matemático de PDE, una conexión que analizamos en la Sección 4.4. En resumen, el uso de núcleos Matérn produce técnicas de recuperación óptimas para funciones en espacios de Sobolev a partir de datos de muestra dados. Las recuperaciones generalizadas que utilizan datos derivados producen métodos numéricos *sin malla* para resolver PDE en espacios de Sobolev, incluido el método de *colocación simétrica* que utiliza datos derivados para el PDE basados en [172] y comparte propiedades similares de optimización del espacio de Hilbert [137]. El uso del núcleo de Matérn está fuertemente motivado por el hecho de que la teoría PDE a menudo implica que las soluciones se encuentran en espacios de Sobolev. Por otro lado, también hay buenos argumentos para sustituir los núcleos Matérn por poliarmónicos. [138; 50].

Se pueden encontrar muchos otros resultados sobre problemas de recuperación deterministas utilizando núcleos en [166], mientras que las aplicaciones están en [139] y los programas MATLAB combinados con la teoría esencial están en [58].

En análisis numérico y teoría de aproximación, Matérn y otros núcleos se utilizan normalmente para valores bastante grandes de su parámetro de suavidad, porque buscan resolver una tarea de interpolación en lugar de una de regresión. [114] demostró que las tasas de convergencia dependen del mínimo de la suavidad de la función f que proporciona los datos y el núcleo; un núcleo Matérn *mal especificado*, para el cual el parámetro de suavidad ν se considera demasiado grande en relación con la suavidad de f , produce un error que converge a la misma velocidad que habríamos logrado si ν se hubiera especificado correctamente. Por otro lado, [159] demuestra en el mismo escenario que el error de predicción se vuelve más sensible a la propiedad de relleno de espacio de los puntos de diseño. En particular, las tasas de convergencia óptimas requieren también que se controle la *cuasi-uniformidad* del diseño experimental.

Por supuesto, el uso de núcleos en análisis numérico y teoría de aproximación requiere la estimación de los parámetros del núcleo. La cantidad σ no aparece en la matriz de correlación R_n , pero el parámetro de escala α tiene una fuerte influencia en el error del interpolador. Existe una vasta literatura sobre *estimación de escala* que se basa parcialmente en nociones estadísticas como ML (ver referencias en la Sección 3). Por otro lado, alternativas específicas al modelo de Matérn, como los núcleos poliarmónicos de la Sección 7.3, pueden omitir la estimación de escala debido a la notable propiedad de que el interpolante es independiente del valor del parámetro de escala utilizado. Consulte [166] y la sección 7.3.

6.2. Aprendizaje automático

Los métodos de núcleo son una rama importante de la investigación del aprendizaje automático, donde los núcleos se utilizan de forma rutinaria para resolver una variedad de tareas de aprendizaje supervisadas y no supervisadas. En comparación con la configuración de interpolación de la sección 6.1, los datos en el aprendizaje automático generalmente se observan con ruido, lo que requiere que se especifique una función de probabilidad o de pérdida.

El modelo de Matérn suele ser conveniente para el análisis de métodos de núcleo; por ejemplo, [160] proporciona condiciones suficientes para que las tasas de convergencia de la regresión de la cresta del núcleo de Matérn excedan las tasas minimax estándar tanto bajo la norma L_2 como bajo la norma del RKHS. Sin embargo, la presencia de ruido en los datos puede plantear un desafío sustancial para la selección de parámetros de suavidad como ν en el modelo Matérn. [81] demuestra que la estimación ML de ν no puede *subestimar* asintóticamente la verdad bajo asintóticas de dominio fijo; es decir, si la función de regresión verdadera tiene una suavidad de Sobolev $\nu_0 + d/2$

, entonces la estimación del parámetro de suavidad no puede ser asintóticamente menor que $\nu_0 + d/2$, pero esto en sí mismo no es una motivación convincente para usar ML [82]. Como resultado de estos desafíos adicionales, la práctica estándar es mantener el núcleo general en la medida de lo posible al desarrollar la metodología y, en la medida de lo posible, aprender una forma adecuada para el núcleo utilizando los criterios de selección de datos y modelos. Sin embargo, la reciente metodología de aprendizaje automático para datos no euclidianos depende del enfoque SPDE y, como consecuencia, se están utilizando explícitamente los modelos de Matérn y relacionados.

A medida que los tipos de datos que los investigadores buscan analizar se vuelven más heterogéneos y estructurados, ha habido una demanda de modelos de procesos gaussianos flexibles definidos en dominios no euclidianos como variedades y dominios discretos basados en gráficos. Bajo el marco de los procesos gaussianos, [35] propuso evitar la solución numérica del SPDE [SPDE] y en su lugar trabajar con una aproximación de rango finito al modelo de proceso gaussiano. En concreto, consideran la SPDE en ([SPDE]) apropiadamente adaptada a una variedad riemanniana M , para la cual el correspondiente modelo de Matérn admite una expansión en serie del tipo

$$\sum_{n=0}^{\infty} \left(\frac{2\nu}{\alpha^2} + \lambda_n \right)^{-\nu-d/2} f_n(x) f_n(x'), \quad x, x' \in M$$

donde $\{\lambda_n\}_{n=0}^{\infty}$ y $\{f_n\}_{n=0}^{\infty}$ son, respectivamente, las secuencias de valores propios y funciones propias del operador de Laplace-Beltrami $-\Delta_M$. Los autores proponen resolver primero numéricamente las funciones propias principales $\{f_i\}_{i=0}^n$ del operador de Laplace-Beltrami y luego trabajar con un proceso gaussiano de rango finito cuyas realizaciones son combinaciones lineales del $\{f_i\}_{i=0}^n$. Aunque resolver el problema propio puede ser más difícil que resolver numéricamente el SPDE, los autores sostienen que el almacenamiento en caché de las funciones propias puede conducir a un ahorro de costos en entornos donde se deben resolver múltiples tareas en el mismo colector. Este enfoque se extiende ingeniosamente a gráficos no dirigidos por [34], y ha tenido un impacto directo en los procesos gaussianos definidos en redes neuronales [80], el condicionamiento de procesos gaussianos [171], la inteligencia de simulación en IA [93] y la extensión a los métodos del núcleo dentro de los gráficos en tiempo cruzado [115]. Otras aplicaciones incluyen el muestreo de Thomson en sistemas de información neuronal [161], la optimización bayesiana en robótica [79] y la regresión de procesos gaussianos en espacios métricos [90].

6.3. Teoría de la probabilidad y procesos estocásticos

El modelo de Matérn está bien estudiado desde el punto de vista de la teoría de la probabilidad y del proceso estocástico. Desde la perspectiva de la regularidad, [140] resume las propiedades de los campos aleatorios gaussianos con funciones de covarianza de Matérn; las trayectorias muestrales son k veces diferenciables en el sentido cuadrático medio si y solo si $\nu > k$. Bajo la misma condición, las trayectorias muestrales tienen un exponente del espacio de Sobolev (local) que es idénticamente igual a k . Además, un campo aleatorio gaussiano con covarianza de Matérn tiene una dimensión fractal que es idénticamente igual a $\min(\nu, d)$, siendo d la dimensión del espacio euclidiano en el que se define el campo aleatorio. Para campos aleatorios no gaussianos con covarianza Matérn, [86] estudia las propiedades de continuidad.

Se han investigado varias otras propiedades del modelo de Matérn. [85] estudia campos aleatorios fraccionarios bajo el escenario de ecuaciones estocásticas de calor fraccional bajo un modelo de Matérn; consulte también [96]. En [95] se estudiaron campos aleatorios definidos sobre la bola unitaria incrustada en $\mathbb{R}^d$, con una función de covarianza que es la restricción del modelo de Matérn a un rango finito. En [94] se estudiaron campos aleatorios con valores tensoriales con una clase equivalente de funciones de covarianza de Matérn. [157] considera espectros angulares para campos aleatorios no gaussianos con la función de covarianza de Matérn. Una contribución reciente [158] proporciona una conexión interesante entre el modelo de Matérn y ciertas representaciones AR-MA laplacianas de una clase de procesos estocásticos. [99] muestran que el proceso de Matérn es una versión amortiguada del movimiento browniano fraccional. [100] estudia campos aleatorios con una covarianza de Matérn generalizada obtenida como solución a la ecuación diferencial estocástica fraccionaria con dos órdenes fraccionarios, lo que permite a los autores deducir las propiedades de la ruta muestral del campo aleatorio asociado. [10] proporciona extensiones espacio-temporales de los campos aleatorios de Matérn mediante ecuaciones estocásticas de Helmholtz.

Según N. Leonenko¹, uno de los principales contribuyentes a esta literatura, la importancia del modelo de Matérn se basa en el teorema de dualidad [72 Theorem 1] que proporciona una relación explícita entre ciertas clases de funciones características de vectores aleatorios simétricos y su densidad. En concreto, la densidad espectral asociada al modelo de Matérn es en sí misma una función de covarianza, denominada función de covarianza multicuadrática inversa de Cauchy, que permite parametrizar el efecto Hurst del campo aleatorio gaussiano asociado.

Se completa así nuestro recorrido por el panorama científico a través del objetivo del modelo Matérn. Nuestra atención se centra ahora en el futuro y en las prometedoras mejoras que se pueden realizar en el modelo Matérn.

¹Comunicación personal, enero de 2023.

7 Mejoras del Modelo Matérn

Esta sección describe *mejoras* del modelo Matérn; funciones de covarianza que comparten (al menos parcialmente) las propiedades locales del modelo Matérn al tiempo que proporcionan características y funcionalidades adicionales. Aquí presentamos primero los modelos uno por uno, con comentarios críticos sobre sus características remitidos a la Sección 8.

7.1. Modelos con soporte compacto

Los modelos de covarianza con soporte compacto tienen una larga historia que se remonta a [12], quien propuso el núcleo

$$A_{\mu,\beta}(x) = \left(1 - \frac{x}{\beta}\right)_+^{\mu}, \quad x \geq 0,$$

con β y μ siendo estrictamente positivo, y donde $(x)_+ = \max(0, x)$ es la *potencia truncada*. En ese trabajo se demostró que $A_{\mu,\beta}$ pertenece a Φ_d para todo $\beta > 0$ si y solo si $\mu \geq (d+1)/2$. Es evidente que el mapeo $x \mapsto A_{\mu,\beta}(\|x\|)$ se apoya de forma compacta sobre una bola con radio β incrustado en $\mathbb{R}^d$. Como resultado, las matrices de covarianza contienen entradas exactas de cero siempre que los estados asociados x_i y x_j satisfacen $\|x_i - x_j\| \geq \beta$; Las ventajas computacionales de esta dispersidad se analizan con más detalle en la sección [8.5].

[165] aplicó el enfoque *montée y descente* [110] de Matheron a las funciones Askey, obteniendo funciones de covarianza soportadas de forma compacta con suavidad de orden superior que son polinomios truncados como funciones de $\|x\|$. Esta estrategia no pudo generar espacios de Sobolev de orden entero en dimensiones de espacio par, un problema que se resolvió en [136], quien identificó las funciones de Wendland “faltantes”. [62] proporcionó una vista unificada de las funciones de Wendland. [175] proporcionó las condiciones necesarias y suficientes para una clase general que abarca funciones Wendland tanto ordinarias como faltantes. [38] proporcionó una generalización de las funciones de Wendland, con suficientes condiciones paramétricas que permiten que la nueva clase pertenezca a Φ_d para un d determinado. Esas funciones, denominadas funciones *Buhmann*, fueron estudiadas luego por [176] y posteriormente por [177] [129] y [56]. [76] y [40] han estudiado representaciones y propiedades alternativas de las funciones de Wendland. También se han desarrollado extensiones de las funciones de Wendland a multivariado [124; 46], espacio-temporal [123] y procesos no estacionarios [89].

Sigue una discusión más técnica, en la que presentamos dos clases adicionales de funciones de correlación con soporte compacto, cada una de las cuales será el tema de discusión en la Sección 8.

1. La familia generalizada Wendland (*GW*) [61; 176] contiene funciones de correlación con soporte compacto que, como en el modelo de Matérn, admiten una parametrización continua de suavidad del campo aleatorio gaussiano subyacente. El modelo $GW_{\kappa,\mu,\beta}$ depende de los parámetros $\kappa \geq 0$ y $\mu, \beta > 0$ a través de la identidad

$$\begin{aligned} & GW_{\kappa,\mu,\beta}(x) \\ &= \frac{\Gamma(\kappa)\Gamma(2\kappa + \mu + 1)}{\Gamma(2\kappa)\Gamma(\kappa + \mu + 1)2^{\mu+1}} A_{\kappa+\mu,\beta^2}(x^2) \\ &\times {}_2F_1\left(\frac{\mu}{2}, \frac{\mu+1}{2}; \kappa + \mu + 1; A_{1,\beta^2}(x^2)\right), \end{aligned}$$

dónde $\mu \geq (d+1)/2 + \kappa$ es necesario para $GW_{\kappa,\mu,\beta}$ pertenecer a la clase Φ_d y ${}_2F_1(a, b, c, \cdot)$ es la función hipergeométrica gaussiana[2]. Rutas de muestra de la $GW_{\kappa,\mu,\beta}$ modelo son k multiplicada por la media cuadrática

diferenciable, en cualquier dirección, si y sólo si $\kappa > k - 1/2$ [61], de modo que κ juega el papel del parámetro de suavidad en este modelo. Cuando $\kappa = k \in \mathbb{N}$, $GW_{k,\mu,\beta}$ factores en el producto de la función Askey $A_{\mu+k,\beta}$ con un polinomio de grado k . Este modelo incluye las funciones Wendland ($\kappa = k$, un número entero positivo), así como las funciones de Wendland que faltan ($\kappa = k + 1/2$). Teorema 1(3) en [25] implica que el RKHS inducido por $GW_{\kappa/2-(d+1)/4,\mu,\beta}$, con $\kappa \geq (d + 1/2)$, es norma equivalente al espacio de Sobolev $W_2^\kappa(\mathbb{R}^d)$.

2. La familia [53] hipergeométrica de Gauss ($\mathcal{GH}$) se define como

$$\begin{aligned} & \mathcal{GH}_{\kappa,\delta,\gamma,\beta}(x) \\ &= \frac{\Gamma(\delta - d/2)\Gamma(\gamma - d/2)}{\Gamma(\delta - \kappa + \gamma - d/2)\Gamma(\kappa - d/2)} \\ & \quad \times A_{\delta-\kappa+\gamma-d/2+1,\beta^2}(x^2) \times \\ & {}_2F_1(\delta - \kappa; \gamma - \kappa; \delta - \kappa + \gamma - d/2; A_{1,\beta^2}(x^2)). \end{aligned}$$

Este modelo tiene cuatro parámetros y pertenece a la clase. Φ_d por cada positivo β provided $\kappa > d/2$ con

$$2(\delta - \kappa)(\gamma - \kappa) \geq \kappa, \quad \text{y} \quad 2(\delta + \gamma) \geq 6\kappa + 1.$$

Rutas de muestra de la $\mathcal{GH}_{\kappa,\delta,\gamma,\beta}$ modelo son $[k/2]$ multiplicada por la media cuadrática diferenciable, en cualquier dirección, si y sólo si $\kappa > (k + d)/2$. El parámetro κ también controla la suavidad de las muestras de este modelo.

La importancia de los modelos $\mathcal{GW}$ y $\mathcal{GH}$ se analiza en la sección 8.

7.2. Modelos con decaimiento polinómico

Los modelos de correlación con desintegración polinomial, como el modelo generalizado de Cauchy [65] o los modelos de Dagum [22], pueden resultar útiles al modelar datos con dependencia de largo alcance. Sin embargo, al utilizar estos modelos de correlación se pierde control sobre la diferenciabilidad de las trayectorias muestrales, una propiedad clave del modelo de Matérn. [106] propuso recientemente una modificación de la clase Matérn que permite la desintegración polinomial, manteniendo al mismo tiempo las propiedades locales del modelo Matérn convencional. La función de correlación asociada a este modelo viene dada por

$$\mathcal{CH}_{\nu,\eta,\beta}(x) = \frac{\Gamma(\nu + \eta)}{\Gamma(\nu)} \mathcal{U}\left(\eta, 1 - \nu, \nu \left(\frac{x}{\beta}\right)^2\right), \quad x \geq 0,$$

dónde $\mathcal{U}$ es la función hipergeométrica confluyente de segundo tipo [2]. Here $\nu > 0$ controla la diferenciabilidad cuadrática media cerca del origen, como en el caso de Matérn, mientras que $\eta > 0$ Controla el peso de la cola. La construcción ([anciano]) se basa en una mezcla de escalas de (una versión reparametrizada de) el modelo de Matérn que involucra la distribución gamma inversa. [106] han demostrado que esta clase es particularmente útil para problemas de extrapolación donde predominan grandes distancias.

7.3. Núcleos poliarmónicos

Nuestro catálogo de mejoras del modelo Matérn termina con *núcleos poliarmónicos*, definidos como

$$H_{\nu,d}(x) := \begin{cases} x^{2\nu-d} \log x & \text{para } 2\nu - d \in 2\mathbb{Z} \\ x^{2\nu-d} & \text{else} \end{cases}$$

hasta la señal $(-1)^{\lfloor \nu-d/2 \rfloor + 1}$. En función de $x = \|x\|$, $x \in \mathbb{R}^d$, el núcleo de Matérn $M_{\nu-d/2,1}$ comienza con potencias pares de x seguido por $H_{\nu,d}$, y en este sentido los dos modelos están relacionados. Hasta un factor constante, la

transformada generalizada de Fourier de $H_{\nu,d}(\|x\|)$ en $\mathbb{R}^d$ es $\|\omega\|^{-2\nu}$, y luego un parámetro de escala es simplemente otro factor constante. Esto hace que la interpolación basada en núcleo por poliarmónicos sea independiente de la escala. Compare con ([stein1]) para ver la conexión con $M_{\nu-d/2,\alpha}$ en el espacio de Fourier.[150] proporciona una conexión formal entre núcleos poliarmónicos, para los cuales también se utiliza el nombre de funciones de covarianza *ley de potencia*, y el modelo de Matérn. Los núcleos poliarmónicos son *definidos condicionalmente positivos* de orden $\lfloor \nu - d/2 \rfloor + 1$; para una definición técnica ver[166]. En lugar de espacios de Hilbert, los núcleos poliarmónicos generan *espacios Beppo-Levi*, que comparten similitudes con los espacios de Sobolev, módulo en el que se debe agregar un espacio polinomial adicional para permitir la predicción (Sección 3) y la interpolación (Sección 6.1); ver[166]. En general, los núcleos poliarmónicos surgen como covarianzas en campos gaussianos *fraccionales*, incluidas las formas de movimiento browniano.[104 Theorem 3.3].

A continuación, nuestra atención se centra en una discusión crítica sobre si tales mejoras al modelo de Matérn son necesarias.

8 ¿Son útiles las mejoras del modelo Matérn?

Esta sección final proporciona comentarios críticos sobre el modelo Matérn y las versiones mejoradas del modelo presentadas en la Sección 7.

8.1. Generalización Rigurosa del Modelo Matérn

El modelo de Matérn no permite soporte compacto, efectos de agujero (oscilaciones entre valores positivos y negativos) a grandes distancias, o colas que decaen lentamente adecuadas para modelar dependencia de largo alcance. La mayoría de las mejoras de la sección 7 tienen como objetivo resolver este tipo de problemas; Aquí describimos cómo los modelos $\mathcal{GW}$, $\mathcal{GH}$ y $\mathcal{CH}$ pueden verse como generalizaciones rigurosas del modelo de Matérn.

[23] han demostrado que el modelo Matérn es un caso límite de una versión reescalada del modelo $\mathcal{GW}$. En particular han considerado el modelo $\widetilde{\mathcal{GW}}$ definido como

$$\widetilde{\mathcal{GW}}_{\kappa, \mu, \beta}(x) = \mathcal{GW}_{\kappa, \mu, \beta\left(\frac{\Gamma(\mu+2\kappa+1)}{\Gamma(\mu)}\right)^{\frac{1}{1+2\kappa}}}(x), \quad x \geq 0,$$

y demostraron que

$$\lim_{\mu \rightarrow \infty} \widetilde{\mathcal{GW}}_{\kappa, \mu, \beta}(x) = M_{\kappa+1/2, \beta}(x), \quad \kappa \geq 0,$$

con convergencia uniforme sobre el conjunto $x \in (0, \infty)$. Por lo tanto, el parámetro μ permite cambiar de modelos con soporte compacto a modelos con soporte global, y puede corregirse para garantizar matrices de correlación dispersas o puede estimarse en función del conjunto de datos. Sin embargo, esta equivalencia se aplica sólo a los parámetros de suavidad mayores o iguales a $1/2$ en el modelo Matérn, por lo que no se cubre el rango completo del parámetro de suavidad. Esto es desafortunado, ya que la dimensión fractal [una medida ampliamente utilizada de rugosidad de las trayectorias de muestra para series temporales y datos espaciales; 66] está completamente parametrizado utilizando el modelo Matérn cuando el parámetro de suavidad se encuentra entre 0 y 1. Como consecuencia, el modelo $\mathcal{GW}$ (o $\widetilde{\mathcal{GW}}$) no puede parametrizar completamente la dimensión fractal del campo aleatorio. Este tipo de problema se puede resolver con el modelo $\mathcal{GH}$, que incluye el modelo $\mathcal{GW}$ como caso especial [53]:

$$\mathcal{GH}_{\frac{d+1}{2}+\nu, \frac{d+\mu+1}{2}+\nu, \frac{d+\mu}{2}+1+\nu, \beta}(x) = \mathcal{GW}_{\nu, \mu, \beta}(x)$$

Dejar que β , δ y γ tiendan al infinito de tal manera que $\beta/\sqrt{4\delta\gamma}$ tiende a $\alpha > 0$, el modelo $\mathcal{GH}$ ([emery]) converge uniformemente al modelo Matérn $\mathcal{M}_{\kappa-d/2, \alpha}(x)$, y en este caso el *rango completo* del parámetro de suavidad del modelo Matérn es cubierto.

El modelo Matérn también surge como caso límite especial del modelo $\mathcal{CH}$. Específicamente, [106] muestra que

$$\lim_{\eta \rightarrow \infty} \mathcal{CH}_{\nu, \eta, 2\sqrt{\nu(\eta+1)}\beta}(x) = M_{\nu, \beta}(x),$$

tiene una convergencia uniforme en cualquier conjunto compacto.

El operador *banda giratoria* de [109] se puede aplicar a una función de correlación para crear efectos de agujero manteniendo la definición positiva del núcleo. Un argumento de Schoenberg demuestra que, para una correlación isotrópica en $\mathbb{R}^d$, los valores de correlación no pueden ser menores que $-1/d$ [143]. Dado que el modelo Matérn es un modelo válido para todos los d , esto implica que la aplicación de bandas giratorias al modelo Matérn no proporcionará ningún efecto de agujero. Por otro lado, los modelos GW y GH permiten tal efecto.

8.2. Estimación de modelos mejorados

La estimación de ML para el modelo de Matérn se comprende bien; Aquí discutimos hasta qué punto se pueden obtener resultados similares para mejoras del modelo Matérn.

En el contexto de asintóticas de dominio crecientes, los parámetros de los modelos GW y CH se pueden estimar consistentemente usando ML y se conoce la distribución asintótica asociada; consulte la sección 3.1.1.

En el contexto de asintóticas de dominio fijo, similar al modelo clásico de Matérn, los parámetros de estos modelos mejorados no se pueden estimar de manera consistente. Por ejemplo, [25] muestra que el parámetro microergódico del modelo de covarianza $\sigma^2 GW_{\kappa, \mu, \beta}$, suponiendo que κ y μ se conozcan, viene dado por $\text{micro}_{GW} = \sigma^2 / \beta^{2\kappa+1}$. Además, demuestran que para un campo gaussiano de media cero definido en un conjunto infinito acotado $D \subset \mathbb{R}^d$ ($d = 1, 2, 3$), con el modelo de covarianza $\sigma_0^2 GW_{\kappa, \mu, \beta_0}$, el estimador ML $\hat{\sigma}_n^2 / \hat{\beta}_n^{2\kappa+1}$ del parámetro microergódico es fuertemente consistente, *i.e.*,

$$\hat{\sigma}_n^2 / \hat{\beta}_n^{2\kappa+1} \xrightarrow{a.s.} \sigma_0^2 / \beta_0^{2\kappa+1}.$$

Además, para $\mu > (d+1)/2 + \kappa + 3$, es asintótico la distribución viene dada por

$$\sqrt{n}(\hat{\sigma}_n^2 / \hat{\beta}_n^{2\kappa+1} - \sigma_0^2 / \beta_0^{2\kappa+1}) \xrightarrow{d} \mathcal{N}(0, 2(\sigma_0^2 / \beta_0^{2\kappa+1})^2).$$

Los análogos para el modelo $\mathcal{GH}$ propuesto no están disponibles en este momento.

De manera similar, [106] muestra que el parámetro microergódico del modelo de covarianza $\sigma^2 CH_{\nu, \eta, \beta}$, suponiendo que ν sea conocido, está dado por

$$\text{micro}_{CH} = (\sigma^2 \Gamma(\nu + \eta)) / (\beta^{2\nu} \Gamma(\eta)).$$

. Además, prueban que para un campo gaussiano de media cero definido en un conjunto infinito acotado $D \subset \mathbb{R}^d$ ($d = 1, 2, 3$), con el modelo de covarianza $\sigma_0^2 CH_{\nu, \eta_0, \beta_0}$, el estimador ML $(\hat{\sigma}_n^2 / \hat{\beta}_n^{2\nu})(\Gamma(\nu + \hat{\eta}_n) / \Gamma(\hat{\eta}_n))$ del parámetro microergódico es fuertemente consistente, *i.e.*,

$$\frac{\hat{\sigma}_n^2(\Gamma(\nu + \hat{\eta}_n))}{\hat{\beta}_n^{2\nu} \Gamma(\hat{\eta}_n)} \xrightarrow{a.s.} \frac{\sigma_0^2 \Gamma(\nu + \eta_0)}{\beta_0^{2\nu} \Gamma(\eta_0)}$$

y, si $\eta_0 > d/2$, su distribución asintótica viene dada por

$$\begin{aligned} & \frac{\hat{\sigma}_n^2(\Gamma(\nu + \hat{\eta}_n))}{\hat{\beta}_n^{2\nu} \Gamma(\hat{\eta}_n)} - \frac{\sigma_0^2 \Gamma(\nu + \eta_0)}{\beta_0^{2\nu} \Gamma(\eta_0)} \\ & \xrightarrow{d} \mathcal{N}\left(0, 2\left(\frac{\sigma_0^2 \Gamma(\nu + \eta_0)}{\beta_0^{2\nu} \Gamma(\eta_0)}\right)^2\right). \end{aligned}$$

Estos resultados respaldan ampliamente el uso de estimaciones del complemento ML para estas versiones mejoradas del modelo Matérn; La cuestión del rendimiento predictivo se analiza a continuación.

8.3. Predicción con modelos mejorados

Si dos medidas gaussianas son equivalentes, entonces las predicciones asociadas y los errores cuadráticos medios son asintóticamente idénticos (consulte la sección 3.2). Con este fin, resultados recientes han buscado establecer equivalencia entre las medidas gaussianas para el modelo de Matérn y las mejoras del modelo de Matérn. [25] considere el modelo $\sigma_1^2 GW_{\kappa, \mu, \beta}$ y demuestre que para $\sigma_1 \geq 0$, $\nu \geq 1/2$ y $\kappa \geq 0$ dados, si $\nu = \kappa + 1/2$, $\mu > d + \kappa + 1/2$ y

$$\sigma_0^2 \alpha^{-2\nu} = \left(\frac{\Gamma(2\kappa + \mu + 1)}{\Gamma(\mu)} \right) \sigma_1^2 \beta^{-(1+2\kappa)},$$

entonces $P(\sigma_0^2 M_{\nu, \alpha})$ es equivalente a $P(\sigma_1^2 GW_{\kappa, \mu, \beta})$, para $d = 1, 2, 3$, en los caminos de $Z(x)$ para $x \in D \subset \mathbb{R}^d$. Así, las predicciones realizadas utilizando el $\mathcal{GW}$ modelo con soporte compacto son asintóticamente idénticos a los realizados con el modelo Matérn. Asimismo, [106] demostrar que para un determinado $\eta \geq d/2$ y $\nu \geq 0$, si

$$\sigma_0^2 \alpha^{-2\nu} = \left(\frac{\Gamma(\nu + \eta)}{\Gamma(\eta)} \right) \sigma_1^2 \left(\frac{\beta^2}{2} \right)^{-\nu},$$

entonces $P(\sigma_0^2 M_{\nu, \alpha})$ es equivalente a $P(\sigma_1^2 CH_{\nu, \eta, \beta})$, para $d = 1, 2, 3$, en los caminos de $Z(x)$ para $x \in D \subset \mathbb{R}^d$. Así, las predicciones realizadas utilizando el $\mathcal{GW}$ El modelo con decaimiento de cola polinomial es asintóticamente idéntico a los realizados usando el modelo de Matérn.

Si el interés está en el predictor [blup], pero no en la incertidumbre predictiva resultante del campo aleatorio gaussiano asociado, entonces es interesante observar que el supuesto de estacionariedad del modelo de Matérn puede no ser necesario. [153] demostró que, bajo condiciones paramétricas adecuadas, se puede considerar $\alpha = 0$ en el modelo de Matérn, y esto es equivalente a la predicción usando los núcleos poliarmónicos $H_{\nu, d}$ en ([eqKmd]). El teorema 1 de ese trabajo muestra que si $d \leq 3$ y el parámetro ν satisfacen la condición (2) del mismo (o $d = 1$), entonces *es imposible distinguir $\alpha > 0$ de $\alpha = 0$ en un dominio acotado*. La observación anterior refleja el hecho de que la predicción utilizando poliarmónicos Los núcleos, como en la sección 6.1, son independientes de la escala. Esto se deriva de la homogeneidad de la transformada de Fourier y elimina la necesidad de realizar una estimación de escala en este contexto.

8.4. Apantallamiento con modelos mejorados

El efecto de cribado se extiende también a las versiones mejoradas del modelo Matérn. Para esquemas regulares, el Teorema 1 en [128] muestra que el modelo GW permite un efecto de apantallamiento asintótico cuando $\mu > (d + 1)/2 + \kappa$. Esta condición no es restrictiva, ya que $\mu \geq (d + 1)/2 + \nu$ ya es necesario para que $GW_{\kappa, \mu, \beta}$ pertenezca a la clase Φ_d . Para los esquemas irregulares la situación es más complicada. Por ejemplo, para campos no diferenciables en $d = 1$, el teorema 1 en [151] junto con el teorema 1 en [128] explica que el modelo de Askey $GW_{0, \mu, \beta}$ permite un efecto de apantallamiento proporcionado $\mu > 1$. Para $d = 2$, el teorema 2 en [151] implica que el modelo Askey permite la detección siempre que $\mu > 3/2$. El modelo $\mathcal{GW}$ satisface la condición de Stein en (1.3) de [128], lo que a su vez permite verificar la hipótesis de Stein [condición1].

Los experimentos numéricos en [128] sugieren que el efecto de apantallamiento es aún más fuerte en modelos mejorados con soporte compacto, en comparación con el modelo Matérn estándar. Esto puede ofrecer ventajas computacionales, que analizamos a continuación.

8.5. Computación escalable

La eterna lucha entre la precisión estadística y la escalabilidad computacional ha producido métodos que intentan abordar este notorio compromiso. La discusión que sigue se centra específicamente en esta compensación en el contexto del modelo Matérn. No se discutirán enfoques generales, como aquellos basados en procesos predictivos [17] y aquellos basados en kriging de rango fijo [45]; Se remite al lector interesado a la revisión de [154].

La complejidad computacional asociada con el modelo Matérn se rige en términos generales por la dimensión del espacio de entrada (d), el número (p) de parámetros del núcleo que deben estimarse y el número de datos (n). Estos desafíos se considerarán uno por uno.

Primero, consideramos el desafío del d grande, que a menudo se encuentra en el aprendizaje automático, cuando la regresión del proceso gaussiano se realiza en espacios de entrada de alta dimensión [169]. Dado que el modelo de Matérn $M_{\nu,\alpha}$ reproduce un espacio de Sobolev hasta una norma equivalente (c.f. Sección 6.1), y se requiere que $\nu > d/2$ para que los elementos de este espacio estén bien definidos puntualmente, se deduce que ν debe tender al infinito como d tiende a infinito, de modo que el modelo de Matérn se reduce al modelo gaussiano [eqGauLim]. La flexibilidad de algunos modelos mejorados también se pierde en este límite; la condición $\mu \geq (d+1)/2 + \kappa$ en el modelo $\widetilde{GW}_{\kappa,\mu,\beta}$ obliga al parámetro μ a ir al infinito con d , lo que a su vez obliga a $\widetilde{GW}_{\kappa,\mu,\beta}$ a acercarse a $M_{\nu,\alpha}$. Desde este punto de vista, la clase $\mathcal{GH}_{\kappa,\delta,\gamma,\beta}$ parece más prometedora para usar en d grandes. Una observación adicional es que, para $d \geq 5$, todas las medidas gaussianas con funciones de covarianza de Matérn son ortogonales [8]. Esto tiene consecuencias filosóficas para la regresión del proceso gaussiano cuando el modelo de Matérn se ve como una distribución *previa* que codifica una creencia *a priori*, ya que un pequeño cambio en los parámetros del núcleo da como resultado que se cambie todo el soporte de la anterior.

Junto con la gran dimensión de entrada d , está el desafío de que aparezca una gran cantidad de parámetros p en el modelo. El modelo multivariado de Matérn sufre por el hecho de que p no solo aumenta exponencialmente con d , sino que las condiciones de validez del modelo implican severas restricciones en el coeficiente de correlación colocado ρ_{ij} en ([stma]). [54] muestran que tales restricciones ya se vuelven extremadamente severas con $p = 3$. Se aplican comentarios similares a otras funciones de covarianza multivariadas, incluido el modelo multivariado $\mathcal{GW}$ en [46].

Finalmente consideramos el caso donde el número n de datos es grande, lo que implica un costo computacional $O(n^3)$ y un costo de almacenamiento $O(n^2)$ asociado con el predictor [blup]. Se han propuesto varios enfoques para reducir estos costos en el contexto del modelo Matérn, muchos de los cuales aprovechan la dispersidad (aproximada) de la covarianza (Σ_n) o la precisión (Σ_n^{-1}), o su factor de Cholesky ($\text{ch}(\Sigma_n^{-1})$):

- La dispersidad en la matriz de covarianza Σ_n del modelo Matérn es explotada directamente por versiones mejoradas del modelo Matérn de la Sección 7. Estos enfoques pueden resultar útiles cuando el soporte compacto (estimado) es relativamente pequeño con respecto a la extensión espacial de la región de muestreo, de modo que las aproximaciones son extremadamente dispersas; véase a continuación una investigación empírica de este punto.
- La matriz de precisión Σ_n^{-1} asociada con el modelo Matérn en general no es dispersa (excepto en el caso $d = 1$ y $\nu = 0.5$), pero resulta que los valores de la matriz en general son relativamente cercanos a 0, es decir, Σ_n^{-1} es *cuasidisparso*. Como consecuencia, aproximar Σ_n^{-1} con una matriz dispersa puede ser una buena estrategia. Un ejemplo notable de este enfoque es el enfoque SPDE de la Sección 4.2. Este enfoque también puede estar motivado a partir de resultados en álgebra lineal numérica, que demuestran que si los elementos de una matriz muestran una propiedad de desintegración, entonces los elementos de su inversa también muestran un comportamiento similar (y más rápido) [20].
- La aproximación de Vecchia [163] y sus extensiones [48; 67; 83; 47] implican una dispersa aproximación de $\text{ch}(\Sigma_n^{-1})$ y a menudo se aplican al modelo de Matérn, aunque se pueden aplicar a cualquier modelo de covarianza. Una posible limitación de estos métodos es que dependen del orden de las variables y de la elección de conjuntos de condicionamiento que determinan el patrón de dispersidad de Cholesky [67].

Es instructivo investigar numéricamente la dispersidad de matrices asociadas con mejoras del modelo Matérn, y para ello nos centramos en el modelo $\widetilde{GW}_{\kappa,\mu,\beta}$, que nos permite pasar de un modelo con soporte compacto de radio

TABLE 1
percentage of zero values in the upper triangular part of the matrix Σ_n , and quasi-sparsity (defined in the main text) matrix (Σ_n^{-1}) and its Cholesky factor ($\text{ch}(\Sigma_n^{-1})$)) for

$\kappa = 0$										$\kappa = 1$										$\kappa = 2$									
μ	C	Σ_n		Σ_n^{-1}		$\text{ch}(\Sigma_n^{-1})$		μ	C	Σ_n		Σ_n^{-1}		$\text{ch}(\Sigma_n^{-1})$		μ	C	Σ_n		Σ_n^{-1}		$\text{ch}(\Sigma_n^{-1})$							
		1156	4489	1156	4489	1156	4489			1156	4489	1156	4489	1156	4489			1156	4489	1156	4489	1156	4489						
1.5	0.07	98.4	98.3	32.3	1.46	35.7	2.17	2.5	0.11	97.1	96.7	3.80	1.67	6.39	4.44	3.5	0.13	94.7	95.0	2.90	1.31	5.63	6.12						
4	0.20	90.1	89.6	45.9	56.0	45.0	54.9	4	0.16	93.4	93.3	34.2	47.1	36.6	48.7	4	0.15	94.8	94.2	10.4	11.9	15.0	22.6						
8	0.40	66.4	65.7	56.6	64.2	52.0	60.0	8	0.28	80.9	80.7	69.7	57.0	69.3	59.2	8	0.25	84.7	84.4	42.8	61.0	47.3	64.8						
16	0.80	16.4	15.2	59.8	71.5	53.8	66.6	16	0.54	48.1	47.1	64.2	80.1	64.0	76.0	16	0.45	59.1	58.3	51.7	73.0	54.6	74.2						
32	1.60	0	0	61.2	79.0	55.8	72.8	32	1.04	1.91	1.61	66.4	83.8	66.5	82.2	32	0.86	11.0	10.1	52.3	75.7	54.8	77.2						
120	6.01	0	0	65.2	76.6	58.9	68.2	120	3.82	0	0	66.2	84.6	65.9	81.2	120	3.09	0	0	52.4	75.7	54.1	76.5						
∞	∞	0	0	66.2	77.5	58.9	70.0	∞	∞	0	0	66.2	84.9	65.1	80.7	∞	∞	0	0	52.4	75.4	53.6	74.6						

TABLE 2
As in Table 1, but with β chosen such that the practical Matérn model is equal to 0.4.

$\kappa = 0$								$\kappa = 1$								$\kappa = 2$													
μ	C	Σ_n	Σ_n^{-1}	$\text{ch}(\Sigma_n^{-1})$				μ	C	Σ_n	Σ_n^{-1}	$\text{ch}(\Sigma_n^{-1})$				μ	C	Σ_n	Σ_n^{-1}	$\text{ch}(\Sigma_n^{-1})$									
		1156	4489	1156	4489	1156	4489			1156	4489	1156	4489	1156	4489			1156	4489	1156	4489	1156	4489			1156	4489	1156	4489
1.5	0.20	90.0	89.1	0	0	0	0	2.5	0.28	80.5	80.2	0	0	0	0	3.5	0.35	72.6	71.4	0	0	0	0						
4	0.53	48.7	47.3	1.03	9.62	0.58	2.77	4	0.42	65.0	63.7	0	1.03	1.12	0.81	4	0.39	67.2	66.4	0	0	0	0						
8	1.07	1.43	1.21	4.14	25.6	1.84	8.15	8	0.75	20.7	19.7	5.91	14.5	4.49	12.9	8	0.67	30.7	29.6	0.71	2.73	2.13	6.90						
16	2.13	0	0	15.0	43.5	4.98	21.3	16	1.43	0	0	21.2	45.2	17.1	30.8	16	1.21	1.72	1.29	13.7	25.8	14.8	27.9						
32	4.27	0	0	22.8	44.4	12.7	24.3	32	2.78	0	0	37.2	55.0	29.0	41.0	32	2.29	0	0	25.5	23.5	24.8	42.7						
120	16.0	0	0	21.0	46.2	8.33	21.9	120	10.2	0	0	40.8	59.8	32.2	46.2	120	8.24	0	0	26.0	10.9	25.9	46.4						
∞	∞	0	0	23.4	47.9	9.85	24.0	∞	∞	0	0	42.6	61.3	34.3	48.0	∞	∞	0	0	26.0	18.2	25.9	46.6						

Figura 8.1: Tablas 1 y 2. Porcentajes de dispersidad y cuasidispersidad de las matrices asociadas con el modelo $\widehat{\mathcal{GW}}$.

$$C = \beta \left(\frac{\Gamma(\mu + 2\kappa + 1)}{\Gamma(\mu)} \right)^{\frac{1}{1+2\kappa}}$$

al modelo Matérn aumentando la μ parámetro. En nuestro experimento, la dispersidad de Σ_n y la *casi-dispersidad* de Σ_n^{-1} y $\text{ch}(\Sigma_n^{-1})$ se informan, este último se define como el porcentaje de valores en la matriz triangular superior con un valor absoluto inferior a una constante pequeña arbitraria ϵ , y en nuestro ejemplo establecemos $\epsilon = 1.e - 8$.

La evaluación empírica considera los sitios de ubicación $n = 1, 156$ y $n = 4, 489$ sobre $[0, 1]^2$, donde los puntos están igualmente espaciados por 0.03 y 0.015 respectivamente en una cuadrícula regular. Para $\nu = 0, 1, 2$, configuramos β de modo que el rango práctico del modelo Matérn sea igual a 0.15 ($\beta = 0.050, 0.0316, 0.0253$ respectivamente) y consideramos aumentar $\mu = 1.5 + \kappa, 4, 8, 16, 32, 120, \infty$ (siendo $\widetilde{GW}_{\kappa, \infty, \beta}$ el modelo Matérn $M_{\kappa+1/2, \beta}$).

Los resultados se informan en la Tabla [tab2222]. Para los valores bajos $\mu = 1.5, 2.5, 3.5$ y $\nu = 0, 1, 2$, la matriz de covarianza es muy dispersa, mientras que la dispersidad disminuye al aumentar μ , como se esperaba. Existe una clara compensación entre la dispersidad de Σ_n y la cuasi dispersidad de Σ_n^{-1} y $\text{ch}(\Sigma_n^{-1})$ para cada $\nu = 0, 1, 2$. Sin embargo, cuando se aumenta μ , es decir, cuando Σ_n se acerca a la matriz de covarianza de Matérn, entonces Σ_n^{-1} o $\text{ch}(\Sigma_n^{-1})$ tienden a ser muy dispersos.

Replicamos el mismo experimento pero con un alcance práctico del modelo Matérn igual a 0.4. Esto lleva a $\beta = 0.133, 0.084, 0.067$ para $\nu = 0, 1, 2$ respectivamente. Los resultados se informan en la Tabla [tab333]. Las conclusiones son las mismas que en la configuración anterior, pero en este caso tenemos niveles más bajos de dispersidad para Σ_n y de cuasi dispersidad para Σ_n^{-1} y $\text{ch}(\Sigma_n^{-1})$.

Estos experimentos numéricos resaltan una clara compensación entre la (casi) dispersidad de Σ_n^{-1} (o $\text{ch}(\Sigma_n^{-1})$) y Σ_n al aumentar μ para β y ν fijos, es decir, al cambiar de un soporte compacto a un Modelo Matérn apoyado globalmente. En particular, cuando $\mu \rightarrow \infty$ (el modelo Matérn), entonces Σ_n^{-1} es muy cuasi-disperso y Σ_n es denso. Por el contrario, cuando μ es pequeño, entonces Σ_n^{-1} no es casi disperso, pero Σ_n es muy disperso. Esto parece sugerir que la aproximación matricial de dispersa precisión debería funcionar razonablemente bien para el modelo de Matérn, pero podría ser problemática cuando se manejan datos que exhiben una dependencia corta y con soporte compacto. En este caso, un mejor enfoque debería ser explotar la dispersidad de Σ_n , como lo permiten las versiones mejoradas del modelo Matérn.

9 Conclusión

El impacto del modelo Matérn desde su concepción ha sido sustancial y el modelo sigue utilizándose ampliamente en una amplia gama de disciplinas científicas y más allá. Si bien la motivación original para el modelo de Matérn provino de su flexibilidad en el contexto de la interpolación espacial, ahora también existe una rica literatura sobre versiones alternativas y mejoradas del modelo. En particular, el SPDE y enfoques relacionados permiten definir análogos del modelo de Matérn en dominios bastante generales, admitiendo dispersas aproximaciones a matrices de precisión, mientras que los avances recientes en modelos mejorados con soporte compacto pueden facilitar el cálculo escalable a través de aproximaciones dispersas de matrices de covarianza, y son adecuados para procesos con dependencia de corta escala. Las propiedades teóricas y empíricas de estos modelos mejorados se han estudiado recientemente y activamente. Por otro lado, quedan abiertas cuestiones teóricas de importancia práctica, como la estimación de parámetros en tamaños de muestra finitos y el impacto de la estimación de parámetros en el desempeño de las predicciones asociadas.

Nuestra comprensión actual del modelo Matérn ha surgido como resultado del compromiso entre científicos y profesionales de diferentes disciplinas, y nuestra esperanza es que esta perspectiva multidisciplinaria arroje más luz sobre el modelo Matérn.

Referencias

- Åberg, S. y Podgórski, K. (2011). Una clase de campos aleatorios de segundo orden no gaussianos. , 14(2):187–222.
- Abramowitz, M. y Stegun, I. A., editores (1970). . Dover, Nueva York.
- Alegría, A., Cuevas-Pacheco, F., Diggle, P. y Porcu, E. (2021a). La familia F de funciones de covarianza: un análogo de Matérn para modelar campos aleatorios en esferas. , 43:100512.
- Alegría, A., Emery, X. y Porcu, E. (2021b). Covarianzas bivariadas de Matérn con hoyuelo cruzado para modelar variables correogionalizadas. , 41:100491.
- Alegría, A., Ramírez, F. y Porcu, E. (2023). Clases paramétricas híbridas de funciones de covarianza isotrópicas para campos aleatorios espaciales. .
- Allard, D., Clarotto, L. y Emery, X. (2022). Funciones de covarianza de Gneiting totalmente inseparables para datos espacio-temporales multivariados. , 52:100706.
- Allard, D., Senoussi, R. y Porcu, E. (2016). Modelos de anisotropía para datos espaciales. , 48(3):305–328.
- Andéres, E. (2010). Sobre la separación consistente de escala y varianza para campos aleatorios gaussianos. , 38(2):870–893.
- Anderes, E., Møller, J. y Rasmussen, J. G. (2020). Funciones de covarianza isotrópicas en gráficos y sus aristas. , 48(4):2478–2503.
- Angulo, J., Kelbert, M. Y., Leonenko, N. y Ruiz-Medina, M. D. (2008). Campos aleatorios espaciotemporales asociados con ecuaciones de calor y Helmholtz fraccionarias estocásticas. , 22(1):3–13.
- Apanasovich, T. V., Genton, M. G. y Sun, Y. (2012). Una clase Matérn válida de funciones de covarianza cruzada para campos aleatorios multivariados con cualquier número de componentes. , 107(497):180–193.
- Askey, R. (1973). Funciones características radiales. .
- Bachoc, F., Bevilacqua, M. y Velandia, D. (2019). Estimación de verosimilitud compuesta para un proceso gaussiano bajo asintóticas de dominio fijo. , 174:104534.
- Bachoc, F., Porcu, E., Bevilacqua, M., Furrer, R. y Faouzi, T. (2022). . , 28(4):2518–2545.
- Bakka, H., Krainski, E., Bolin, D., Rue, H. y Lindgren, F. (2020). La extensión basada en la difusión del campo Matérn al espacio-tiempo. .
- Banerjee, S. y Gelfand, A. E. (2006). Wombling bayesiano: evaluación de gradiente curvilíneo bajo modelos de procesos espaciales. , 101(476):1487–1501.
- Banerjee, S., Gelfand, A. E., Finley, A. O. y Sang, H. (2008). Modelos de procesos predictivos gaussianos para grandes conjuntos de datos espaciales. , 70(4):825–848.
- Banerjee, S., Gelfand, A. E. y Sirmans, C. F. (2003). Tasas direccionales de cambio bajo modelos de procesos espaciales. , 98(464):946–954.
- Barp, A., Oates, C. J., Porcu, E. y Girolami, M. (2022). Un método del núcleo de Riemann-Stein. , 28(4):2181–2208.
- Benzi, M. (2016). Localización en cálculos matriciales: teoría y aplicaciones. En Benzi, M. y Simoncini, V., editores, *Explotación de la estructura oculta en cálculos matriciales: algoritmos y aplicaciones: Cetraro, Italia 2015*, páginas 211–317. Publicaciones internacionales Springer.

- Berg, C. (2008). Stieltjes–Pick–Bernstein–Schoenberg y su conexión con la monotonía total. En Mateu, S. y Porcu, E., editores, *Funciones definidas positivas: de Schoenberg a los desafíos del espacio-tiempo*, páginas 15–45. España: Departamento de Matemáticas, Universidad Jaume I, Castellón de la Plana.
- Berg, C., Mateu, J. y Porcu, E. (2008). La familia Dagum de funciones de correlación isotrópica. , 14(4):1134–1149.
- Bevilacqua, M., Caamaño-Carrillo, C. y Porcu, E. (2022). Unificación de funciones de covarianza de Matérn y soporte compacto en estadística espacial. , 189:104949.
- Bevilacqua, M., Caamaño-Carrillo, C., Arellano-Valle, R. B. y Morales-Oñate, V. (2021). Modelado geoestadístico no gaussiano utilizando procesos t (sesgados). , 48(1):212–245.
- Bevilacqua, M., Faouzi, T., Furrer, R. y Porcu, E. (2019). . , 47(2):828–856.
- Bevilacqua, M. y Gaetan, C. (2015). Comparación de métodos de verosimilitud compuesta basados en pares para campos aleatorios espaciales gaussianos. , 25(5):877–892.
- Bingham, N. H., Goldie, C. M. y Teugels, J. (1987). . , 27:145–156.
- Bochner, S. (1955). . Monografías de California en ciencias matemáticas. Prensa de la Universidad de California.
- Bolín, D. (2014). Campos espaciales de Matérn impulsados por ruido no gaussiano. , 41(3):557–579.
- Bolin, D. y Kirchner, K. (2020). El enfoque SPDE racional para campos aleatorios gaussianos con suavidad general. , 29(2):274–285.
- Bolin, D. y Kirchner, K. (2022). Equivalencia de medidas y predicción lineal asintóticamente óptima para campos aleatorios gaussianos con operadores de covarianza de orden fraccionario. .
- Bolin, D., Simas, A. B. y Wallin, J. (2022). Campos gaussianos de Whittle-Matérn en gráficos métricos.
- Bolin, D. y Wallin, J. (2016). Campos aleatorios de ecuación diferencial parcial estocástica de Matérn tipo multivariante. .
- Borovitskiy, V., Azangulov, I., Terenin, A., Mostowsky, P., Deisenroth, M. y Durrande, N. (2021). Procesos gaussianos de Matérn en gráficos. En Banerjee, A. y Fukumizu, K., editores, *Actas de la 24^a Conferencia Internacional sobre Inteligencia Artificial y Estadística*, volumen 130 de *Actas de investigación sobre aprendizaje automático*, páginas 2593–2601. PMLR.
- Borovitskiy, V., Terenin, A., Mostowsky, P., et al. (2020). Procesos gaussianos de Matérn en variedades de Riemann. , 33:12426–12437.
- Bourotte, M., Allard, D. y Porcu, E. (2016). Una clase flexible de funciones de covarianza cruzada no separables para datos espacio-temporales multivariados. , 18:125–146.
- Brown, R. D., Bardsley, J. M. y Cui, T. (2020). Métodos de semivariograma para modelar prioritarios de Whittle-Matérn en problemas inversos bayesianos. , 36(5):055006.
- Buhmann, M. (2001). Una nueva clase de funciones de base radial con soporte compacto. , 70(233):307–318.
- Cameletti, M., Lindgren, F., Simpson, D. y Rue, H. (2013). Modelado espacio-temporal de la concentración de material particulado mediante el enfoque spde. , 97(2):109–131.
- Chernih, A. y Hubbert, S. (2014). Representaciones en forma cerrada y propiedades de las funciones de Wendland generalizadas. , 177:17–33.
- Chilès, J. y Delfiner, P. (2012). . Wiley, Nueva York.
- Clotto, L., Allard, D., Romary, T. y Desassis, N. (2022). El enfoque spde para conjuntos de datos espacio-temporales con advección y difusión: un enfoque sin matrices. En *15^a Conferencia Internacional del Grupo de Trabajo ERCIM sobre Estadística Computacional y Metodológica (CMStatistics 2022)*.
- Cockayne, J., Oates, C. J., Sullivan, T. J. y Girolami, M. (2019). Métodos numéricos probabilísticos bayesianos. , 61(4):756–789.
- Cressie, N. (1990). Los orígenes del kriging. , 22(3):239–252.

- Cressie, N. y Johannesson, G. (2008). kriging de rango fijo para conjuntos de datos espaciales muy grandes. , 70(1):209–226.
- Daley, D. J., Porcu, E. y Bevilacqua, M. (2015). Clases de funciones de covarianza compatibles de forma compacta para campos aleatorios multivariados. , 29(4):1249–1263.
- Datta, A. (2022). Matrices de Cholesky dispersas del vecino más cercano en estadística espacial. , 14(5):e1574.
- Datta, A., Banerjee, S., Finley, A. O. y Gelfand, A. E. (2016a). Modelos de procesos gaussianos jerárquicos del vecino más cercano para grandes conjuntos de datos geoestadísticos. , 111(514):800–812.
- Datta, A., Banerjee, S., Finley, A. O., Hamm, N. A. y Schaap, M. (2016b). Modelos de procesos gaussianos dinámicos no separables del vecino más cercano para grandes datos espacio-temporales con una aplicación al análisis de partículas. , 10(3):1286.
- Davydov, O. y Schaback, R. (2019). Plantillas óptimas en espacios de Sobolev. , 39:398–422.
- Dey, D., Datta, A. y Banerjee, S. (2022). Modelos gráficos de procesos gaussianos para datos espaciales altamente multivariados. , 109(4):993–1014.
- Eidsvik, J., Shaby, B., Reich, B., Wheeler, M. y Niemi, J. (2013). Estimación y predicción en modelos espaciales con probabilidades compuestas de bloques. , aparecer.
- Emery, X. y Alegría, A. (2022). El núcleo de covarianza hipergeométrica de Gauss para modelar campos aleatorios estacionarios de segundo orden en espacios euclidianos: su soporte compacto, propiedades y representación espectral. , 36:2819—2834.
- Emery, X., Porcu, E. y White, P. (2022). Nuevas condiciones de validez para el modelo multivariado de Correogionalización de Matérn, con aplicación a la geoquímica de exploración. , páginas 1–26.
- Faouzi, T., Porcu, E. y Bevilacqua, M. (2022). Estimación y predicción espacio-temporal bajo asintóticas de dominio fijo con funciones de covarianza soportadas de forma compacta. , 32:1–17.
- Faouzi, T., Porcu, E., Bevilacqua, M. y Kondrashuk, I. (2020). Operadores Zastavnyi y funciones radiales definidas positivas. , 157:108620.
- Fasshauer, G. (1997). Resolución de ecuaciones diferenciales parciales mediante colocación con funciones de base radial. En LeMéhauté, A., Rabut, C. y Schumaker, L., editores, *Métodos de ajuste de superficies y multiresolución*, páginas 131–138. Prensa de la Universidad de Vanderbilt, Nashville, Tennessee.
- Fasshauer, G. y McCourt, M. (2015). , volumen 19 de *Ciencias Matemáticas Interdisciplinarias*. World Scientific, Singapur.
- Furrer, R., Genton, M. G. y Nychka, D. (2006). Reducción gradual de la covarianza para la interpolación de grandes conjuntos de datos espaciales. , 15(3):502–523.
- Genton, M. G. y Kleiber, W. (2015). Funciones de covarianza cruzada para geoestadísticas multivariadas. , 30(2):147–163.
- Gneiting, T. (2002a). Funciones de correlación con soporte compacto. , 83:493–508.
- Gneiting, T. (2002b). Funciones de covarianza estacionarias no separables para datos espacio-temporales. , 97:590–600.
- Gneiting, T. (2013). Funciones definidas estrictamente y no estrictamente positivas en esferas. , 19(4):1327–1349.
- Gneiting, T., Kleiber, W. y Schlather, M. (2010). Funciones de covarianza cruzada de Matérn para campos aleatorios multivariados. , 105:1167–1177.
- Gneiting, T. y Schlather, M. (2004). Modelos estocásticos que separan la dimensión fractal y el efecto Hurst. , 46(2):269–282.
- Gneiting, T., Ševčíková, H. y Percival, D. B. (2012). , 27(2):247–277.
- Guinness, J. (2018). Métodos de permutación y agrupación para afinar las aproximaciones del proceso gaussiano. , 60(4):415–429.

- Guinness, J. (2022). Inversas de las covarianzas de Matérn en grillas. , 109(2):535–541.
- Guinness, J. y Fuentes, M. (2016). Funciones de covarianza isotrópica en esferas: algunas propiedades y consideraciones de modelado. , 143:143–152.
- Guttorp, P. y Gneiting, T. (2006). Estudios de historia de la probabilidad y la estadística XLIX: Sobre la familia de correlaciones de Matérn. , 93(4):989–995.
- Halder, A., Banerjee, S. y Dey, DK (2023). Modelado bayesiano con procesos de curvatura espacial. , ?(recién aceptado):1–27.
- Harrar, SW, Seneta, E. y Gupta, AK (2006). Dualidad entre distribuciones de matriz variable t y de matriz variable vg . , 97(6):1467–1475.
- Hartikainen, J. y Särkkä, S. (2010). Soluciones de filtrado y suavizado de Kalman para modelos de regresión de procesos gaussianos temporales. En *Taller internacional IEEE de 2010 sobre aprendizaje automático para procesamiento de señales*, páginas 379–384. IEEE.
- Heaton, M. J., Datta, A., Finley, A. O., Furrer, R., Guinness, J., Guhaniyogi, R., Gerber, F., Gramacy, R. B., Hammerling, D., Katzfuss, M., Lindgren, F., Nychka, D. W., Sun, F. y Zammit-Mangion, A. (2019). Una competencia de estudios de caso entre métodos para analizar grandes datos espaciales. , 24:398–425.
- Hennig, P., Osborne, M. A. y Kersting, H. P. (2022). . Prensa de la Universidad de Cambridge.
- Hubbert, S. (2012). Representaciones de forma cerrada para una clase de funciones de base radial con soporte compacto. , 36(1):115–136.
- Ip, H. L. y Li, W. K. (2017). Sobre algunas funciones de covarianza de Matérn para campos aleatorios espacio-temporales. , 27:805–822.
- Jansson, E., Kovács, M. y Lang, A. (2022). Aproximación de elementos finitos de superficie de campos aleatorios esféricos gaussianos de Whittle–Matérn. , 44(2):A825–A842.
- Jaquier, N., Borovitskiy, V., Smolensky, A., Terenin, A., Asfour, T. y Rozo, L. (2022). Optimización bayesiana consciente de la geometría en robótica utilizando núcleos Riemannian Matérn. En *Conferencia sobre aprendizaje de robots*, páginas 794–805. PMLR.
- Jensen, K., Kao, T.-C., Tripodi, M. y Hennequin, G. (2020). Múltiples gplvms para descubrir estructuras latentes no euclidianas en datos neuronales. , 33:22580–22592.
- Karvonen, T. (2022). Límites asintóticos para estimaciones de parámetros de suavidad en la regresión del proceso gaussiano. .
- Karvonen, T. y Oates, C. J. (2022). La estimación de máxima verosimilitud en la regresión del proceso gaussiano está mal planteada. . Para aparecer.
- Katzfuss, M. y Guinness, J. (2021). . , 36(1):124 - 141.
- Kaufman, C. G. y Shaby, B. A. (2013). El papel del parámetro de rango para la estimación y predicción en geoestadística. , 100:473–484.
- Kelbert, M. Y., Leonenko, N. N. y Ruiz-Medina, M. (2005). Campos aleatorios fraccionarios asociados con ecuaciones estocásticas de calor fraccional. , 37(1):108–133.
- Kent, JT (1989). Propiedades de continuidad para campos aleatorios. , páginas 1432–1440.
- Khristenko, U., Scarabosio, L., Swierczynski, P., Ullmann, E. y Wohlmuth, B. (2019). Análisis de efectos de contorno en el muestreo basado en PDE de campos aleatorios de Whittle–Matérn. , 7(3):948–974.
- Kleiber, W. y Nychka, D. (2012). Modelado no estacionario para procesos espaciales multivariados. , 112:76–91.
- Kleiber, W. y Porcu, E. (2015). Covarianzas matriciales no estacionarias: soporte compacto, dependencia de largo alcance y construcciones cuasi-aritméticas. , 29(1):193–204.
- Koepernik, P. y Pfaff, F. (2021). Consistencia de la regresión del proceso gaussiano en espacios métricos. , 22:244–1.

- Laga, I. y Kleiber, W. (2017). El proceso de Matérn modificado. , 6(1):241–247.
- Lang, A. y Pereira, M. (2021). Aproximación de Galerkin-Chebyshev de campos aleatorios gaussianos en variedades compactas de Riemann. .
- Lavin, A., Zenil, H., Paige, B., Krakauer, D., Gottschlich, J., Mattson, T., Anandkumar, A., Choudry, S., Rocki, K., Baydin, A. G., et al. (2021). Inteligencia de simulación: hacia una nueva generación de métodos científicos. .
- Leonenko, N. y Malyarenko, A. (2017). Campos aleatorios con valores tensoriales de clase Matérn y más. , 168(6):1276–1301.
- Leonenko, N., Malyarenko, A. y Olenko, A. (2022). Sobre la teoría espectral de los campos aleatorios en la pelota. , 107:61–76.
- Leonenko, N., Ruiz-Medina, M. D. y Taqqu, M. S. (2011). Campos aleatorios elípticos, hiperbólicos y parabólicos fraccionados. , 16:1134–1172.
- Li, D., Jones, A., Banerjee, S. y Engelhardt, B. E. (2021a). Procesos gaussianos multigrupo. .
- Li, D., Tang, W. y Banerjee, S. (2021b). Inferencia para procesos gaussianos con covariograma de Matérn sobre variedades compactas de Riemann. .
- Lilly, J. M., Sykulski, A. M., Early, J. J. y Olhede, S. C. (2017). Movimiento browniano fraccional, proceso de Matérn y modelado estocástico de dispersión turbulenta. , 24(3):481–514.
- Lim, S. y Teo, LP (2009). Campo aleatorio generalizado de Whittle-Matérn como modelo de fluctuaciones correlacionadas. , 42(10):105202.
- Lindgren, F., Bolin, D. y Rue, H. (2022). El enfoque SPDE para campos gaussianos y no gaussianos: 10 años y aún en funcionamiento. , página 100599.
- Lindgren, F., Rue, H. y Lindstroem, J. (2011). Un vínculo explícito entre los campos gaussianos y los campos aleatorios gaussianos de Markov: el enfoque estocástico de la ecuación diferencial parcial. , 73:423–498.
- Lindsay, B. (1988). Métodos de verosimilitud compuestos. , 80:221–239.
- Lodhia, A., Sheffield, S., Sun, X. y Watson, SS (2016). . , 13(ninguno):1 - 56.
- Loh, W.-L., Sun, S. y Wen, J. (2021). . , 49(6):3127–3152.
- Ma, P. y Bhadra, A. (2022). Más allá de Matérn: sobre una clase de funciones de covarianza hipergeométricas confluentes interpretables. , páginas 1–14.
- Mardia, K. V. y Marshall, J. (1984). Estimación de máxima verosimilitud de modelos de covarianza residual en regresión espacial. , 71:135–146.
- Matérn, B. (1986). . Springer, Heidelberg, 2^a edición.
- Matheron, G. (1963). . Mémoires du Bureau de Recherches Géologiques et Minières, núm. 24. Ediciones BRGM, París.
- Matheron, G. (1965). . Massón, París.
- Matheron, G. (1971). . Centre de Géostatistique, Ecole des Mines de Paris, Fontainebleau, Francia.
- Menegatto, V., Oliveira, C. y Porcu, E. (2020). Clase gneiting, espacios semimétricos e incrustaciones isométricas. , 3(2):85–95.
- Morales-Navarrete, D., Bevilacqua, M., Caamaño-Carrillo, C. y Castro, L. (2022). Modelado de datos de recuento espacial con referencia a puntos: un enfoque de proceso de Poisson. , 0(0):1–25.
- Narcowich, F. J., Ward, J. D. y Wendland, H. (2006). Estimaciones del error de Sobolev y desigualdad de Bernstein para la interpolación de datos dispersos mediante funciones de base radial. , 24(2):175–186.
- Nikitin, A. V., John, S., Solin, A. y Kaski, S. (2022). Núcleos de gráficos espacio-temporales no separables a través de SPDE. En *Conferencia Internacional sobre Inteligencia Artificial y Estadística*, páginas 10640–10660. PMLR.

- Novak, E. y Woźniakowski, H. (2008). , volumen 2. Sociedad Matemática Europea.
- Oates, C. J., Girolami, M. y Chopin, N. (2017). Funcionales de control para la integración Monte Carlo. , 79(3):695–718.
- Olver, F. W., Lozier, D. M., Boisvert, R. F. y Clark, C. W. (2010). . Prensa de la Universidad de Cambridge, Cambridge.
- Paciorek, C. J. y Schervish, MJ (2006). Modelado espacial utilizando una nueva clase de funciones de covarianza no estacionarias. , 17(5):483–506.
- Palacios, M. B. y Steel, M. F. J. (2006). Modelado geoestadístico bayesiano no gaussiano. , 101:604–618.
- Pereira, M., Desassis, N. y Allard, D. (2022). Geoestadística para grandes conjuntos de datos sobre variedades de Riemann: un enfoque sin matrices. .
- Porcu, E., Alegría, A. y Furrer, R. (2018). Modelado de datos espacialmente globales y en evolución temporal. , 86:344–377.
- Porcu, E., Bevilacqua, M. y Genton, M. G. (2020a). Funciones de covarianza espacio-temporal no separables con soportes compactos dinámicos. , 30:719–739.
- Porcu, E., Daley, D. J., Buhmann, M. y Bevilacqua, M. (2013). Funciones de base radial con soporte compacto para geoestadísticas multivariadas. , 27(4):909–922.
- Porcu, E., Emery, X. y Mery, N. (2022a). Criterios y caracterizaciones para funciones de covarianza valoradas en matrices espacialmente isotrópicas y temporalmente simétricas. , 41(223).
- Porcu, E., Furrer, R. y Nychka, D. (2021). años de funciones de covarianza espacio-temporal. , 13(2):e1512.
- Porcu, E., White, P. A. y Genton, M. G. (2022b). Funciones de covarianza estacionarias espacio-temporales no separables en redes a través del tiempo. .
- Porcu, E., Zastavnyi, V., Bevilacqua, M. y Emery, X. (2020b). Hipótesis de Stein y efecto de apantallamiento de covarianzas con soporte compacto. , 14(2):2510–2528.
- Porcu, E., Zastavnyi, P. y Bevilacqua, M. (2016). Funciones de covarianza de Buhmann, sus soportes compactos y su suavidad. .
- Posa, D. (2023). Clases especiales de funciones de covarianza isotrópicas. , En prensa.
- Quick, H., Banerjee, S. y Carlin, B. P. (2013). Modelado de gradientes temporales en datos de hospitalización por asma de California agregados regionalmente. , 7(1):154.
- Roininen, L., Girolami, M., Lasanen, S. y Markkanen, M. (2019). Hiperpriors para campos Matérn con aplicaciones en inversión bayesiana. , 13(1).
- Sanz-Alonso, D. y Yang, R. (2022a). Representaciones de elementos finitos de procesos gaussianos: equilibrio de la precisión numérica y estadística. , 10(4):1323–1349.
- Sanz-Alonso, D. y Yang, R. (2022b). El enfoque SPDE a los campos Matérn: representaciones grafos. , 37(4):519–540.
- Sarkka, S., Solin, A. y Hartikainen, J. (2013). Aprendizaje espaciotemporal mediante filtrado y suavizado bayesiano de dimensión infinita: una mirada a la regresión del proceso gaussiano mediante el filtrado de Kalman. , 30(4):51–61.
- Schaback, R. (2011). Las funciones Wendland que faltan. , 34(1):67–81.
- Schaback, R. (2015). Una herramienta computacional para comparar todos los solucionadores de PDE lineales. , 41:333–355.
- Schaback, R. (2017). Análisis de errores de métodos nodales sin malla. En Griebel, M. y Schweitzer, M., editores, *Meshfree Methods for Partial Differential Equations VIII*, volumen 115 de *Lecture Notes in Computational Science and Engineering*, páginas 117–143. Saltador.

- Schaback, R. y Wendland, H. (2006). Técnicas del Kernel: del Machine Learning a los Métodos Meshless. , 15:543–639.
- Scheuerer, M. (2010). Regularidad de los caminos muestrales de un campo aleatorio general de segundo orden. , 120(10):1879–1897.
- Scheuerer, M., Schaback, R. y Schlather, M. (2013). Interpolación de datos espaciales: ¿un problema estocástico o determinista? , 24(4):601–629.
- Schoenberg, I.-J. (1938). Espacios métricos y funciones completamente monótonas. , 39(4):811–841.
- Schoenberg, IJ (1942). Funciones definidas positivas en esferas. , 9:96–108.
- Shaby, B. y Ruppert, D. (2012). Covarianza cónica: estimación bayesiana y asintóticas. , 21:433–452.
- South, L. F., Karvonen, T., Nemeth, C., Girolami, M. y Oates, C. J. (2022). Funcionales de control semiexactos del método de Sard. , 109(2):351–367.
- Stein, M. (1988). Predicción asintóticamente eficiente de un campo aleatorio con una función de covarianza mal especificada. , 16:55–63.
- Stein, M. (2005). Métodos estadísticos para el seguimiento periódico de datos. , 67:667–687.
- Stein, ML (1999). . Springer, Nueva York.
- Stein, ML (2002). El efecto de apantallamiento en kriging. , 30(1):298–323.
- Stein, ML (2004). Equivalencia de medidas gaussianas para algunos campos aleatorios no estacionarios. , 123(1):1–11.
- Stein, ML (2011). Conferencia de Rietz: ¿Cuándo se produce el efecto de apantallamiento? , 39(6):2795–2819.
- Stein, ML (2015). ¿Cuándo no se mantiene el efecto de apantallamiento? , 11:65–80.
- Stein, M. L., Chi, Z. y Welty, L. J. (2004). Probabilidades aproximadas para grandes conjuntos de datos espaciales. , 66(2):275–296.
- Sun, Y., Li, B. y Genton, M. G. (2012). Geoestadísticas para grandes conjuntos de datos. En *Avances y desafíos en el modelado espacio-temporal de eventos naturales*, páginas 55–77. Saltador.
- Tang, J. y Zimmerman, D. (2020). Modelos de covarianza espacio-temporal en redes con aplicación en flujos. .
- Tang, W., Zhang, L. y Banerjee, S. (2021). Sobre la identificabilidad y consistencia de la pepita en los modelos de procesos espaciales gaussianos. , 83(5):1044–1070.
- Terdik, G. (2015). Espectros angulares para campos isotrópicos no gaussianos. , 29(4):833–865.
- Terdik, G. (2022). Funciones de covarianza espaciotemporal para campos ARMA laplacianos en dimensiones superiores. , 107:111–132.
- Tuo, R. y Wang, W. (2020). Predicción de kriging con correlaciones isotrópicas de Matérn: robustez y diseños experimentales. , 21:187–1.
- Tuo, R., Wang, Y. y Jeff Wu, C. (2020). Sobre las tasas de convergencia mejoradas para la regresión de crestas del núcleo tipo Matérn con aplicación a la calibración de modelos informáticos. , 8(4):1522–1547.
- Vakili, S., Moss, H., Artemev, A., Dutordoir, V. y Picheny, V. (2021). Muestreo escalable de Thompson utilizando modelos de procesos gaussianos dispersos. , 34:5631–5643.
- Varin, C., Reid, N. y Firth, D. (2011). Una descripción general de los métodos de probabilidad compuesta. , 21:5–42.
- Vecchia, AV (1988). Estimación e identificación de modelos para procesos espaciales continuos. , páginas 297–312.
- Wallin, J. y Bolin, D. (2015). Modelado geoestadístico utilizando campos Matérn no gaussianos. , 42(3):872–890.
- Wendland, H. (1995). Funciones radiales de grado mínimo polinómicas por partes, definidas positivas y compactamente soportadas. , 4:389–396.

- Wendland, H. (2004). , volumen 17. Prensa de la Universidad de Cambridge.
- Whittle, P. (1953). El análisis de múltiples series temporales estacionarias. , 15(1):125–139.
- Whittle, P. (1963). Procesos estocásticos en varias dimensiones. , 40(2):974–994.
- Williams, C. K. y Rasmussen, C. E. (2006). , volumen 2. MIT press Cambridge, MA.
- Wilson, A. G., Hu, Z., Salakhutdinov, R. y Xing, E. P. (2016). Aprendizaje profundo del núcleo. En *Inteligencia artificial y estadística*, páginas 370–378. PMLR.
- Wilson, J. T., Borovitskiy, V., Terenin, A., Mostowsky, P. y Deisenroth, M. P. (2021). Condicionamiento de trayectoria de procesos gaussianos. , 22:105–1.
- Wu, Z. (1992). ermite: interpolación de Birkhoff de datos dispersos mediante funciones de base radial. , 8/2:1–10.
- Xua, G. y Genton, M. G. (2017). Campos aleatorios Tukey g-y-h. , 112:1236-1249.
- Yan, Y. y Genton, M. G. (2018). Inferencia de probabilidad gaussiana sobre datos de campos aleatorios trans-gaussianos con función de covarianza de Matérn. , 29(5-6):e2458.
- Zastavnyi, V. (2002). Funciones radiales definidas positivas y splines. , 66:213–216.
- Zastavnyi, V. (2006). Sobre algunas propiedades de las funciones de Buhmann. , 58(8).
- Zastavnyi, V. y Porcu, E. (2017). Sobre la certeza positiva de algunas funciones radiales. , 38(2):386–394.
- Zastavnyi, V. P. y Porcu, E. (2011). Teoremas de caracterización de la clase Gneiting de funciones de covarianza espacio-temporal. , 17(1):456–465.
- Zhang, H. (2004). Estimación inconsistente e interpolaciones asintóticamente equivalentes en geoestadísticas basadas en modelos. , 99:250–261.
- Zhang, H. y Zimmerman, D. (2005). Hacia la conciliación de dos marcos asintóticos en estadística espacial. , 92:921–936.

Material complementario

10 Modelado a través de Matérn en escenarios no convencionales: la versión extendida

Se podría objetar que la clase Matérn está limitada a campos aleatorios con valores escalares que son estacionarios e isotrópicos. Si bien esto es cierto, también lo es que la clase Matérn representa la base para escenarios mucho más sofisticados. Los enumeramos a lo largo.

1. Campos aleatorios con valores escalares.

1. Anisotropías. Si la dimensión espacial se desarrolla en direcciones preferenciales, la isotropía ya no es una suposición realista para el modelado espacial. En [7] se cuestionan varios tipos de anisotropías y se muestra que la clase Matérn se puede componer con deformaciones *ad hoc* para tener en cuenta direcciones preferenciales en términos de dependencia espacial.

2. No estacionario. El núcleo Matérn ha sido utilizado por [119] para construir modelos no estacionarios. Considere una colección de distribuciones gaussianas indexadas por su media, de modo que el elemento con media x tenga la matriz de covarianza Σ_x . Deje

$$Q_{x,y} = (x - y)^\top \left(\frac{\Sigma_x + \Sigma_y}{2} \right)^{-1} (x - y)$$

y

$$K(x, y) = |\Sigma_x|^{1/4} |\Sigma_y|^{1/4} \left| \frac{\Sigma_x + \Sigma_y}{2} \right|^{-1/2} M_{\nu, \alpha} \left(\sqrt{Q_{x,y}} \right).$$

Entonces, K es positivo definido. Este enfoque se generalizó recientemente en [132]. Alternativamente, se puede inducir la no estacionariedad *deformando* las entradas de la función de covarianza de Matérn, como $K(x, y) = \mathcal{M}_{\nu, \alpha}(\|w(x) - w(y)\|)$ por algún difeomorfismo $w : \mathbb{R}^d \rightarrow \mathbb{R}^d$ que a su vez puede parametrizarse. El caso en el que w está parametrizado por una red neuronal profunda fue explorado en [170].

3. Gráficos y espacios cuasimétricos. [9] considera gráficos con aristas euclidianas, equipados con la distancia geodésica sobre el gráfico o la métrica de resistencia. Demuestran que $M_{\nu, \alpha}$ se puede componer con la métrica de resistencia sobre el gráfico proporcionado $0 < \nu \leq 1/2$. Más recientemente, [112] proporciona una generalización de esta configuración al considerar espacios cuasimétricos. Al parecer, en este caso se aplican restricciones similares. Recientemente, [32] adoptó un enfoque diferente para crear campos aleatorios con su estructura de covarianza en gráficos métricos. La versión espacio-temporal de la clase Matérn, por ser el espacio un grafo con aristas euclidianas, ha sido considerada por [155] y por [127].

4. Espacio-tiempo. Para un campo aleatorio gaussiano de espacio-tiempo $\{Z(x, t), x \in \mathbb{R}^{d+1}, t \in \mathbb{R}\}$, una suposición típica de segundo orden es que la covarianza es isotrópica en el espacio y estacionaria en el tiempo. Es decir,

$$\text{Cov}(Z(x, t), Z(y, t')) = K(\|x - y\|, |t - t'|)$$

para todo $(x, t), (y, t') \in \mathbb{R}^d \times \mathbb{R}$. La función Matérn se ha utilizado como componente básico de dicha estructura. De particular interés son las funciones de covarianza *no separables*, que permiten una interacción entre el espacio y el tiempo, y en este contexto [62] y [178] demostrar que

$$K(x, u) = \frac{\sigma^2}{\psi(u^2)} M_{\nu, \alpha} \left(\frac{x}{\psi(u^2)} \right), \quad x, u \geq 0,$$

generar una función de covarianza espacio-temporal válida del tipo ([space-time]). Aquí, ψ es una función estrictamente positiva que tiene una derivada completamente monótona[21].

5. Campos no gaussianos. Al considerar las transformaciones $w : \mathbb{R} \rightarrow \mathbb{R}$, se puede utilizar el modelo de Matérn como base para una variedad de modelos no gaussianos $\tilde{Z}(x) = w(Z(x))$. Sin embargo, la función de covarianza de $\tilde{Z}$ no será Matérn en general. La pregunta de si existen procesos no gaussianos cuya función de covarianza sea, sin embargo, de clase Matérn fue respondida positivamente en [1]. [174] ha propuesto campos aleatorios transgaussianos con función de covarianza Matérn. [29] y posteriormente [164] han proporcionado construcciones basadas en SPDE para campos Matérn no gaussianos. Se puede obtener una clase general de campos no gaussianos con núcleo $g(M_{\nu, \alpha})$ con $g(\cdot)$ una función adecuada que preserva la definición positiva mediante una transformación de (réplicas independientes de) un campo gaussiano (ver, por ejemplo, [120; 173; 24; 113]).

6. Mezclas de campos gaussianos. Se puede modelar un fenómeno del mundo real como una superposición $Z_1 + Z_2$ donde se podría seleccionar Z_1 para capturar una tendencia general (por ejemplo, $Z_1(x) = c_1\phi_1(x) + \dots + c_p\phi_p(x)$) para algunas funciones fijas $\phi_1, \dots, \phi_p$ y algunos coeficientes $c \in \mathbb{R}^p$ y Z_2 podría ser Matérn, para capturar el nivel de suavidad del proceso. Dichos procesos aparecen en la regresión lineal bayesiana, donde el coeficiente c se considera aleatorio debido a la incertidumbre epistémica, por ejemplo, $c \sim \mathcal{N}(\mu, \Sigma)$, y tanto c como Z_2 deben inferirse conjuntamente. La mezcla $Z_1 + Z_2$ vuelve a ser un campo aleatorio gaussiano.

7. Modelos Matérn con colas modificadas. La función de covarianza de Matérn decae exponencialmente con la distancia. Esto puede ser un inconveniente en presencia de mucha memoria. Algunas clases de funciones de covarianza permiten indexar memoria larga versus corta en datos espaciales. El Cauchy [65] generalizado y el Dagum [22] son ejemplos destacados de familias que permiten indexar tanto las dimensiones fractales como la memoria larga, también denominado efecto Hurst. Sin embargo, estas familias no permiten parametrizar la suavidad de la misma manera que la clase Matérn. Este dilema ha preocupado a varios científicos. A continuación describimos los enfoques dedicados a modificar las colas del modelo de Matérn preservando (a) la definición positiva y (b) el comportamiento local, a su vez conectado con la diferenciabilidad cuadrática media y la parametrización del espacio de Sobolev. Cada una de las contribuciones a continuación tiene diferentes motivaciones, como se explica a lo largo.

1. Modelos Matérn con colas periódicas. [91] ha propuesto una modificación de la densidad espectral del modelo Matérn. La idea principal es proponer una clase isotrópica de densidades espectrales, $\tilde{M}_{\nu, \alpha, \sigma^2}$, que esté conectada a la familia Matérn $\widehat{M}_{\nu, \alpha, \sigma^2}$ a través de la identidad

$$\tilde{M}_{\nu, \alpha, \sigma^2}(z) = (b^2 + z^2)^\xi \widehat{M}_{\nu, \alpha, \sigma^2}(z),$$

con $b \geq 0$ y $\xi < \nu$. While b es un parámetro de rango adicional, ξ está relacionado con la fluidez del proceso respectivo. Más precisamente, el campo aleatorio es k -veces el cuadrado medio diferenciable si y solo si $\nu - \xi > k$. En el caso límite $\xi \rightarrow 0$, se recupera el modelo tradicional de Matérn.

Esta escala en la densidad espectral produce un cambio en la moda del espectro; por tanto, es particularmente útil para obtener procesos con fuertes periodicidades. La función de covarianza asociada a ([laga]) no tiene una expresión explícita conocida, por lo que se deben emplear metodologías estadísticas en el dominio espectral cuando se trata de este modelo.

2. Modelos híbridos. Otra generalización del modelo de Matérn aprovecha el hecho de que puede escribirse como una mezcla de escalas de un núcleo gaussiano frente a una función de densidad de probabilidad

$$\mathcal{M}_{\nu, \alpha}(x) = \int_0^\infty \exp(-ux^2) \pi_{IG}(u; \nu, 1/(4\alpha^2)) du$$

del tipo gamma inverso.[5]hacer uso de la identidad anterior para crear modelos *híbridos* que permitan preservar las propiedades locales del modelo Matérn convencional al tiempo que logran comportamientos más flexibles a

grandes distancias. Una posible construcción híbrida, llamada Matérn-Cauchy y denotada $\mathcal{MC}_{\nu_1, \nu_2, \alpha, \xi}$, se logra a través de

$$\mathcal{MC}_{\nu_1, \nu_2, \alpha, \xi}(x) = \int_0^\xi \exp(-ux^2) \pi_G(u; \nu_1/2, \alpha) du + \int_\xi^\infty \exp(-ux^2) \pi_{IG}(u; \nu_2, 1/(4\alpha^2)) du.$$

Here, π_G es la función de densidad de probabilidad gamma, con una parametrización de tasa de forma, π_{IG} es la densidad en ([inverse_gamma]), $\alpha > 0$ es un parámetro de rango, $\nu_1 > 0$ controla la tasa polinómica de decadencia de la covarianza, $\nu_2 > 0$ indexa la diferenciabilidad cuadrática media, y $\xi \geq 0$ es un parámetro adicional que equilibra las contribuciones de Matérn y Cauchy a la función de covarianza total. Como $\xi \rightarrow 0$, el modelo híbrido tiende a un Matérn covarianza. En [5] se proporciona una expresión en formato cerrado para este modelo. Tenga en cuenta que esta función de covarianza es definida positiva en cualquier dimensión y es un competidor natural del modelo ([anciano]).

Otro modelo híbrido se construye en [5] reemplazando el núcleo gaussiano en ([mixture]) con una diferencia de núcleos gaussianos

$$(a \exp(-ubx^2) - \exp(-ux^2)) (a - 1)^{-1},$$

donde a y b satisfacen la condición $1 < b < a^{2/d}$, para obtener un núcleo definido positivo en $\mathbb{R}^d$ [130]. El modelo resultante tiene un comportamiento local de tipo Matérn y permite correlaciones negativas a grandes distancias (efecto agujero). Los parámetros a y b controlan la nitidez del efecto del agujero. Cuando a es arbitrariamente grande, se recupera el modelo Matérn convencional. Las expresiones algebraicamente cerradas se informan en [5].

2. Campos aleatorios con valores vectoriales.

Sea $\{Z(x), x \in \mathbb{R}^d\} \subset \mathbb{R}^p$ un campo aleatorio variable p con mapeo de covarianza isotrópica $K : \mathbb{R}^d \rightarrow \mathbb{R}^{p \times p}$ que tiene elementos K_{ij} definidos como

$$K_{ij}(x) = \text{cov}(Z_i(0), Z_j(x)), \quad 0, x \in \mathbb{R}^d.$$

Específicamente, K_{ii} y K_{ij} se denominan covarianza automática y cruzada función.

1. Espacial multivariado. Ha habido una gran cantidad de enfoques relacionados con el modelado espacial multivariado, y se remite al lector a [60]. [64] han propuesto una estructura de covarianza multivariada del tipo

$$K_{ij}(x) = \sigma_{ii} \sigma_{jj} \rho_{ij} M_{\nu_{ij}, \alpha_{ij}}(\|x\|), \quad x \in \mathbb{R}^d,$$

dónde σ_{ii}^2 es la varianza de Z_i de Z , y ρ_{ij} es el coeficiente de correlación colocado. Hay restricciones en los parámetros. ν_{ij} , α_{ij} y ρ_{ij} para preservar la precisión positiva y, a menudo, las restricciones sobre los coeficientes de correlaciones colocados ρ_{ij} son graves. Esto motivó enfoques alternativos para aliviar las restricciones paramétricas, y se remite al lector a [11] y, más recientemente, a [54].

2. Espacio-tiempo multivariado. La configuración anterior se puede generalizar al espacio-tiempo considerando $\{Z(x, t), x \in \mathbb{R}^d, t \in \mathbb{R}\} \subset \mathbb{R}^p$ un campo aleatorio variable p con mapeo de covarianza isotrópica $K : \mathbb{R}^d \times \mathbb{R} \rightarrow \mathbb{R}^{p \times p}$ que tiene elementos K_{ij} definidos como

$$K_{ij}(x, u) = \text{cov}(Z_i(0, t), Z_j(x, t + u))$$

para $0, x \in \mathbb{R}^d$, $t, u \in \mathbb{R}$. [36] considere asignaciones K_{ij} del tipo

$$K_{ij}(x, u) = \frac{\sigma_{ii} \sigma_{jj} \rho_{ij}}{\psi(u^2)^{d/2}} M_{\nu_{ij}, \alpha_{ij} \psi(u^2)}(\|x\|)$$

para $x \in \mathbb{R}^d$, $u \in \mathbb{R}$ y una función continua y de valor positivo adecuada ψ . Esta configuración ha sido generalizada recientemente por [6] y mediante un enfoque técnico por [125]: para ambas contribuciones, la idea es reemplazar (puntualmente) el mapeo ψ con el mapeo ψ que tiene elementos continuos y estrictamente positivos ψ_{ij} .

3. Multivariado No Estacionario. [88] deriva una clase de funciones de covarianza con valores matriciales donde las funciones de covarianza directa y cruzada pertenecen a la clase Matérn. Se permite que los parámetros de la clase Matérn varíen con la ubicación, lo que produce variaciones locales, rangos locales, anisotropías geométricas locales y suavidades locales.

Definir $\Sigma_{i,x} = \Sigma_i(x) : \mathbb{R}^d \rightarrow \mathbb{R}^{d \times d}$ y suponer $\Sigma_i(x)$ es positivo definido para todos los i y todo $x \in \mathbb{R}^d$. Dejar

$$Q_{ij;x,y} = (x - y)^\top \left(\frac{\Sigma_{i,x} + \Sigma_{j,y}}{2} \right)^{-1} (x - y)$$

y

$$K_{ij}(x, y) = \rho_{ij} \sigma_{i,x} \sigma_{j,y} M_{\nu,\alpha} \left(\sqrt{Q_{ij;x,y}} \right).$$

Entonces, $K(\cdot, \cdot) = [K_{ij}(\cdot, \cdot)]_{i,j=1}^p$ es positivo definido.

4. Matern multivariado con hoyuelo. En un contexto espacial bivariado, cada elemento de la función de covarianza matricial de Matérn admite una representación de mezcla de escala como en ([mixture]). [4] consideró una modificación de dicha mezcla para obtener una generalización del modelo de Matérn, dada por

$$\tilde{K}_{ij}(x) = \sigma_{ii} \sigma_{jj} \rho_{ij} \int_0^\infty \exp(-ux^2) g_{ij}(u; \xi) \times \pi_{IG}(u; \nu_{ij}, 1/(4\alpha_{ij}^2)) du,$$

dónde $g_{ii}(u; \xi) = 1$, y $g_{ij}(u; \xi) = 1\{u \leq \xi\} - 1\{u \geq \xi\}$ para $i \neq j$, con $1\{\cdot\}$ siendo la función indicadora y ξ un parámetro no negativo, y donde π_{IG} es la función de densidad de probabilidad de una variable aleatoria gamma inversa, es decir

$$\pi_{IG}(z; a, b) = \frac{b^a}{\Gamma(a)} z^{-a-1} \exp(-b/z), \quad z > 0.$$

Observe que los elementos diagonales de la covarianza valorada matricial no se modifican; de esta manera se mantienen los atractivos atributos locales del modelo Matérn. Esta construcción sólo tiene un impacto en las covarianzas cruzadas. De hecho, [4] demostró que $\tilde{K}_{12}(x)$ no es una función monótonamente decreciente de x . Más precisamente, la covarianza cruzada puede alcanzar su valor máximo a una distancia estrictamente positiva. Esta propiedad se llamó hoyuelo cruzado en [4]. El parámetro ξ regula la intensidad del hoyuelo en cruz. Claramente, el modelo bivariado tradicional de Matérn es un caso límite de esta construcción ($\xi \rightarrow \infty$). [4] proporciona expresiones de formato cerrado para ([dimple]). Además, $\nu_{12} = 1/2 + n$, $n \in \mathbb{N}$, $\tilde{K}_{12}(x)$ se pueden expresar en términos de funciones de error y funciones exponenciales.

3. Direcciones, formas y curvas. El modelo Matérn es fundamental para el estudio de los procesos direccionales. [18] formaliza las nociones de procesos direccionales en diferencias finitas y procesos direccionales derivados con especial énfasis en la función de covarianza de Matérn. Proporcionan resultados completos de la teoría de la distribución bajo los supuestos de un modelo de proceso gaussiano estacionario (con covarianza de Matérn), ya sea para los datos o para efectos aleatorios espaciales. [16] introdujo el movimiento bayesiano para medir los gradientes relacionados con las curvas a través de los límites del movimiento. Las propiedades de suavidad del modelo Matérn han demostrado ser exitosas dentro de dicho marco. [131] ha propuesto enfoques de modelado de gradientes temporales utilizando el modelo Matérn.