

Modelado de regresión bayesiana con INLA

Traducción al español

Xiaofeng Wang

Yu Ryan Yue

Julian J. Faraway

2026-08-08

Tabla de contenidos

Presentación	1
Prefacio	3
1 Introducción	5
1.1 Inicio rápido	5
1.1.1 Ley de Hubble	5
1.1.2 Análisis estándar	6
1.1.3 Análisis bayesiano	7
1.1.4 INLA	8
1.2 Teoría de Bayes	12
1.3 Distribuciones previas y posteriores	13
1.4 Comprobación del modelo	14
1.5 Selección del modelo	15
1.6 Contraste de hipótesis	16
1.7 Computación bayesiana	17
1.7.1 Cálculo exacto	17
1.7.2 Muestreo	17
1.7.3 Aproximación	18
2 Teoría de INLA	21
2.1 Modelos gaussianos latentes (LGM)	21
2.2 Campos aleatorios gaussianos de Markov (GMRF)	23
2.3 Aproximación de Laplace e INLA	24
2.3.1 Aproximación de $\pi(\theta \mathbf{y})$	26
2.3.2 Aproximación de $\pi(\eta_i \theta, \mathbf{y})$	26
2.3.3 Exploración de $\tilde{\pi}(\theta \mathbf{y})$	27
2.3.4 Aproximación de $\pi(\theta_j \mathbf{y})$	27
2.3.5 Ejemplo: datos simulados	28
2.4 Problemas de INLA	29
2.4.1 Reproducibilidad	29
2.4.2 Precisión de la aproximación	30
2.4.3 Fallos	30
2.5 Extensiones	32
2.5.1 Aproximación de la verosimilitud marginal	32
2.5.2 Selección de modelos	32
2.5.3 Comprobación del modelo	33
2.5.4 Combinaciones lineales del campo latente	33
3 Regresión lineal bayesiana	35
3.1 Introducción	35

Tabla de contenidos

3.2	Inferencia bayesiana para la regresión lineal	36
3.2.1	Ejemplo: contaminación atmosférica	37
3.3	Predicción	39
3.4	Selección y comprobación del modelo	40
3.4.1	Selección mediante DIC	40
3.4.2	Comprobación predictiva posterior	41
3.4.3	Comprobación por validación cruzada	41
3.4.4	Análisis bayesiano de residuos	42
3.5	Regresión robusta	43
3.6	Análisis de varianza	43
3.7	Regresión ridge para multicolinealidad	44
3.8	Regresión con errores autorregresivos	46
3.8.1	Ejemplo: desempleo en Nueva Zelanda	47
4	Modelos lineales generalizados	49
4.1	GLM	49
4.2	Respuestas binarias	50
4.2.1	Ejemplo: bajo peso al nacer	50
4.3	Respuestas de conteo	52
4.3.1	Regresión Poisson	52
4.3.2	Regresión binomial negativa	53
4.4	Modelado de tasas	54
4.4.1	Ejemplo: reclamaciones de seguros	54
4.5	Regresión gamma para datos sesgados	55
4.5.1	Ejemplo: resistividad de obleas	55
4.6	Respuestas proporcionales	56
4.6.1	Ejemplo: rendimiento de gasolina	56
4.7	Modelado de datos inflados en cero	57
4.7.1	Ejemplo: publicaciones científicas	58
5	Modelos lineales mixtos y lineales generalizados mixtos	61
5.1	Modelos lineales mixtos	61
5.2	Un solo efecto aleatorio	62
5.2.1	Elección de previas	63
5.2.2	Efectos aleatorios	64
5.3	Datos longitudinales	64
5.3.1	Intercepto aleatorio	64
5.3.2	Pendiente e intercepto aleatorios	65
5.3.3	Predicción	65
5.4	Modelo clásico con matriz Z	66
5.4.1	Regresión ridge revisitada	67
5.5	Modelos lineales generalizados mixtos	67
5.6	GLMM Poisson	68
5.7	GLMM binomial	68
5.7.1	Mejora de la aproximación	69
6	Análisis de supervivencia	71
6.1	Introducción	71

6.2	Modelos semiparamétricos	72
6.2.1	Riesgo basal constante por tramos	72
6.2.2	Riesgos proporcionales estratificados	73
6.3	Modelos de tiempo de fallo acelerado	73
6.3.1	Ejemplo: cáncer de laringe	74
6.4	Diagnóstico del modelo	74
6.5	Datos censurados por intervalo	75
6.5.1	Ejemplo: emergencia dental	75
6.6	Modelos de fragilidad	76
6.6.1	Ejemplo: infecciones renales	76
6.7	Modelado conjunto longitudinal y de tiempo al evento	77
6.7.1	Ejemplo: ensayo clínico de sida	77
7	Modelos de caminata aleatoria para métodos de suavizado	79
7.1	Introducción	79
7.2	<i>Splines</i> de suavizado	79
7.2.1	Priori RW para ubicaciones equiespaciadas	80
7.2.2	Elección de las distribuciones a priori de las varianzas	81
7.2.3	Caminatas aleatorias en ubicaciones no equiespaciadas	81
7.3	<i>Splines</i> de placa delgada	83
7.3.1	Retículas regulares	83
7.3.2	Ubicaciones irregulares	83
7.4	Modelo espacial de Besag	84
7.5	<i>Splines</i> de regresión penalizados (P-splines)	84
7.6	Suavizado adaptativo con <i>splines</i>	85
7.7	Regresión no paramétrica generalizada	86
7.7.1	Respuestas binomial y Poisson	86
7.7.2	Precipitación en Tokio	87
7.8	Conjuntos de excursión con incertidumbre	87
7.8.1	Datos fósiles	87
8	Regresión con procesos gaussianos	89
8.1	Introducción	89
8.1.1	Ejemplo de isótopos en fósiles	90
8.2	Priors de complejidad penalizada	91
8.3	Bandas creíbles para la suavidad	92
8.4	Campos no estacionarios	92
8.5	Interpolación con incertidumbre	93
8.6	Respuesta de supervivencia	94
9	Modelos aditivos y aditivos generalizados	95
9.1	Modelos aditivos	95
9.1.1	Datos simulados	95
9.1.2	Guía de alquileres de Múnich	96
9.2	Modelos aditivos generalizados	97
9.2.1	Respuesta binaria: cifosis	97
9.2.2	Respuesta de conteo: huevos de caballa	98

Tabla de contenidos

9.3	Modelos aditivos generalizados mixtos	99
9.3.1	Huevos de lenguado en el canal de Bristol	99
10	Regresión con error en las variables	101
10.1	Introducción	101
10.2	Modelos con error clásico	102
10.2.1	Modelo lineal sencillo con heterocedasticidad	102
10.2.2	Modelo de exposición con mediciones replicadas	103
10.3	Modelos con error de Berkson	105
10.3.1	Bronquitis y exposición al polvo	105
11	Temas diversos en INLA	107
11.1	<i>Splines</i> como modelos mixtos	107
11.1.1	Bases de potencia truncada	107
11.1.2	<i>Splines</i> de O'Sullivan	108
11.1.3	Ingresos de trabajadores canadienses	108
11.2	Análisis de varianza para datos funcionales	109
11.2.1	Imagen por tensor de difusión	109
11.3	Valores extremos	111
11.3.1	Caudales máximos del río Calder	111
11.4	Estimación de densidades con INLA	112

Presentación

Esta es una traducción al español de *Bayesian Regression Modeling with INLA*, de Xiaofeng Wang, Yu Ryan Yue y Julian J. Faraway, publicado por CRC Press en 2018.

La traducción busca conservar la redacción, la estructura matemática y el código R de la obra original. Los nombres de funciones, objetos y argumentos permanecen en inglés para que los ejemplos puedan copiarse y ejecutarse. Se han corregido únicamente errores inequívocos introducidos por el reconocimiento óptico de caracteres; los posibles errores presentes en el original se señalan mediante notas editoriales.

Esta primera entrega comprende el prefacio y el capítulo 1. El documento fuente está preparado como libro Quarto para producir HTML y PDF a partir de los mismos archivos.

Nota sobre derechos

Esta traducción se preparó a partir de los archivos proporcionados por el usuario. No sustituye la edición original y debe utilizarse respetando los derechos de autor y las condiciones de la editorial.

Prefacio

INLA son las siglas de *Integrated Nested Laplace Approximations* (aproximaciones de Laplace anidadas integradas). Es un método para ajustar una amplia clase de modelos bayesianos. Históricamente, era difícil ajustar cualquier modelo bayesiano que no fuese de los más sencillos. Durante los últimos veinte años se ha desarrollado una clase de métodos computacionales bayesianos basados en una técnica de simulación denominada Monte Carlo mediante cadenas de Markov (MCMC), que ha alcanzado una amplia aceptación en estadística. Entre los paquetes populares que emplean estos métodos se encuentran BUGS, JAGS y STAN. A pesar de las impresionantes mejoras, estos paquetes padecen dos problemas. En primer lugar, son lentos. Para algunos problemas de datos más complejos o de mayor tamaño, MCMC puede resultar inviablemente lento, incluso si se está dispuesto a esperar días. Pero aun en problemas más modestos, la capacidad de ajustar modelos con rapidez es crucial para el análisis exploratorio de datos. INLA es un método de aproximación. Por lo general, sus aproximaciones son más que adecuadas; recuérdese además que los métodos de simulación también son inevitablemente aproximados si han de terminar en un tiempo finito. INLA no tarda más que unos cuantos segundos en ajustar los modelos que aparecen en este libro.

La otra dificultad práctica de los métodos MCMC es que exigen una experiencia considerable. Es necesario aprender un lenguaje de programación especializado para especificar los modelos. También hay que comprender los diagnósticos que determinan si el modelo se ajustó correctamente o si el proceso de simulación falló. Para utilizarlos con éxito hace falta cierta destreza. A pesar de las mejoras continuas en este ámbito, esto ha sido un obstáculo para una adopción más amplia de estos métodos en la comunidad científica.

INLA también tiene algunas desventajas. Aunque no es necesario aprender un lenguaje de programación específico, pues los modelos pueden especificarse y analizarse con R, su uso tampoco es del todo sencillo. De hecho, esa es la razón por la que conviene leer este libro. Además, INLA solo se aplica a una clase denominada modelos gaussianos latentes. Un vistazo al índice mostrará que esta clase es muy amplia. No obstante, habrá modelos que no puedan ajustarse con INLA pero sí mediante MCMC.

Hacemos algunas suposiciones acerca de usted, quien lee. Esperamos que posea conocimientos básicos de teoría y práctica estadística, y que ya sepa algo de metodología bayesiana. Este no es un libro teórico: centramos la exposición en ejemplos. Esperamos que el libro resulte accesible para científicos que ya utilicen algo de estadística. También suponemos cierto conocimiento de R. Proporcionamos código completamente funcional para todos los ejemplos, por lo que quizá pueda adaptarlo a sus necesidades aun sin dominar R. Con todo, hará falta alguna experiencia con R para aprovechar plenamente el material. Si necesita contenidos más introductorios, le remitimos a textos más amplios y accesibles.

Este libro trata sobre modelos de regresión y no presenta las extensas capacidades de INLA para el análisis de datos espaciales. A quienes se interesen específicamente por datos espaciales les recomendamos Blangiardo y Cameletti (2015).

Prefacio

Hemos reunido los datos y las funciones adicionales empleadas en el texto en un paquete de R que, al momento de publicarse la obra, podía encontrarse en:

<https://github.com/julianfaraway/brinla>

Nuestro primer agradecimiento es para Håvard Rue y sus colaboradores por desarrollar la teoría y producir el software de INLA. Agradecemos también a Finn Lindgren, Daniel Simpson y Egil Ferkingstad sus valiosos consejos.

1 Introducción

INLA puede ser bastante complejo, por lo que comenzaremos con un ejemplo sencillo de regresión para ilustrar sus características más básicas. No pretendemos ofrecer una introducción exhaustiva a los métodos bayesianos. En cambio, repasaremos la teoría bayesiana que aparecerá más adelante en el libro. También explicaremos por qué podría preferirse INLA frente a sus alternativas.

1.1. Inicio rápido

1.1.1. Ley de Hubble

Comencemos a trabajar con INLA mediante un ejemplo sencillo. Supongamos que queremos conocer la edad del universo. Al principio ocurrió el *big bang*. Las galaxias se alejaron del centro del universo a velocidad constante. Si medimos la velocidad de otras galaxias respecto de nosotros y su distancia hasta nosotros, podemos estimar la edad del universo. Usamos la ley de Hubble, que establece:

$$y = \beta x,$$

donde y es la velocidad relativa entre nosotros y otra galaxia, y x es la distancia desde nosotros hasta esa galaxia. A β se le denomina constante de Hubble. Podemos estimar la edad del universo como β^{-1} .

El telescopio espacial Hubble ha permitido reunir los datos indispensables para responder esta pregunta. Utilizamos datos de 24 galaxias presentados por Freedman et al. (2001). Los mismos datos también se analizan en Wood (2006). Consulte el apéndice A de la edición original para instalar INLA y el paquete R del libro. Los datos se encuentran en dicho paquete, llamado **brinla**.

```
data(hubble, package = "brinla")
```

A lo largo del libro resaltamos el código R de esta manera. Puede escribirlo en la consola de R o copiarlo desde los guiones de cada capítulo. También puede acceder a los datos y funciones mediante `library(brinla)`. Hemos preferido `data()` para dejar clara la procedencia de los datos.

Graficamos los datos como se muestra en la Figura 1.1.

Observamos que los puntos no están todos sobre una recta, por lo que debe existir algún error de medición. Esto no sorprende, dada la dificultad de observar objetos tan lejanos. Aun así, se aprecia una relación aproximadamente lineal entre las variables, congruente con la ley de Hubble. Incorporamos el error mediante el modelo

$$y_i = \beta x_i + \varepsilon_i, \quad i = 1, \dots, 24.$$




Figura 1.1: Distancia y velocidad de 24 galaxias respecto de nuestra ubicación.

Por ahora solo suponemos que los errores tienen media cero y varianza σ^2 .

1.1.2. Análisis estándar

El método de mínimos cuadrados tiene ya casi 200 años y puede aplicarse para estimar β . El modelo no contiene intercepto, por lo que incluimos -1 en su fórmula.

```
lmod <- lm(y ~ x - 1, data = hubble)
coef(lmod)
```

```
      x
76.581
```

Esta es nuestra estimación de β , la constante de Hubble. Debemos convertir las unidades de los datos a una forma más conveniente. Hay 60 segundos por minuto, 60 minutos por hora, 24 horas por día y 365.25 días por año; un megapársec (Mpc) equivale a 3.09×10^{19} km. La siguiente función transforma la constante de Hubble en la edad del universo, expresada en miles de millones de años, y la aplicamos a nuestra estimación:

```
hubtoage <- function(x) 3.09e+19/(x * 60^2 * 24 * 365.25 * 1e+09)
hubtoage(coef(lmod))
```

```
x
12.786
```

La estimación puntual de la edad del universo es de 12.8 miles de millones de años. Sabemos que existe incertidumbre y quizá deseemos expresarla mediante un intervalo de confianza. Para ello necesitamos una suposición distribucional sobre los errores: suponemos que siguen una distribución gaussiana. Hay otras suposiciones. Consideramos correcta la forma estructural del modelo, con base en la ley de Hubble y en el aparente respaldo de los datos. También hemos supuesto que los errores tienen varianza constante. Puede que esto no sea completamente cierto, pero lo aceptaremos para mantener la sencillez.

Construimos un intervalo de confianza del 95 % para la constante de Hubble:

```
(bci <- confint(lmod))
```

```
      2.5% 97.5%
x 68.379 84.783
```

El intervalo es bastante amplio. Podemos transformarlo a un intervalo para la edad del universo:

```
hubtoage(bci)
```

```
      2.5% 97.5%
x 14.320 11.549
```

La inversión necesaria para calcular la edad cambia el orden de los límites. El intervalo de confianza del 95 % va de 11.5 a 14.3 miles de millones de años.

1.1.3. Análisis bayesiano

Podríamos darnos por satisfechos con el análisis anterior: tenemos una estimación puntual y una expresión de su incertidumbre. Sin embargo, al examinar los resultados con mayor detenimiento quizá sintamos cierta insatisfacción y estemos dispuestos a considerar otro método.

Resulta tentador interpretar el intervalo de confianza como una afirmación de que existe un 95 % de probabilidad de que la edad del universo esté entre 11.5 y 14.3 miles de millones de años. Pero esto no es en absoluto lo que sostiene la teoría utilizada para construirlo. Esta teoría —denominada a veces frecuentista y otras veces inferencia clásica— considera que los parámetros son cantidades fijas, aunque por lo general desconocidas. Por ello, dentro de esta teoría carece de sentido asignar probabilidades a los parámetros. El 95 % de confianza se refiere al intervalo, no al parámetro: se afirma que el procedimiento produce intervalos que cubren el verdadero valor del parámetro en el 95 % de los casos.

Podría objetarse que los datos ya se observaron y se conocen, por lo que el intervalo dejó de ser aleatorio. Para responder hay que construir un argumento más elaborado. Imaginamos un número ilimitado de universos alternativos cuyas galaxias se generan según el modelo lineal anterior. Para

1 Introducción

cada universo calculamos un intervalo de confianza del mismo modo. En el 95 % de esos universos, el intervalo contendrá la verdadera edad del universo.

La mayoría de las personas no se detiene en esta peculiar naturaleza del intervalo de confianza y lo interpreta como una afirmación probabilística sobre la edad del universo. En la práctica, esto casi nunca importa demasiado, aunque en ocasiones sí marca una diferencia.

En la estadística bayesiana consideramos aleatorios los parámetros. Antes de ajustar el modelo expresamos nuestra incertidumbre mediante una probabilidad previa. Después usamos el teorema de Bayes para calcular una probabilidad posterior sobre los parámetros, combinando la previa con la verosimilitud de los datos bajo el modelo. Más adelante explicaremos exactamente cómo se hace. Este método permite formular afirmaciones probabilísticas directas sobre la edad del universo y ofrece otras ventajas.

1.1.4. INLA

Los cálculos bayesianos suelen ser mucho más difíciles que los frecuentistas. Esta es la razón principal por la que, históricamente, los métodos clásicos se prefirieron a los bayesianos. Ahora que la computación es potente y económica, podemos realizar esos cálculos con mayor facilidad. En unos cuantos modelos sencillos, como el ejemplo de Hubble, los cálculos pueden hacerse de manera exacta. En problemas más complejos debemos escoger entre dos clases de metodología computacional: simulación o aproximación.

INLA, siglas de *Integrated Nested Laplace Approximation*, es un método de aproximación. Veamos cómo funciona en el ejemplo de Hubble. Primero cargamos el paquete:

```
library(INLA)
```

Para ajustar un modelo bayesiano debemos especificar algo más que su forma estructural, aquí $y \sim x - 1$; -1 indica que debe omitirse el intercepto, incluido por defecto. También debemos especificar las distribuciones previas de los parámetros. En este modelo tenemos dos: β y σ . En ocasiones podemos confiar en la opción predeterminada, que procura ser no informativa; así lo haremos para σ . Los valores predeterminados y la elección de previas se estudiarán con detalle más adelante. Por ahora nos concentraremos en β .

INLA se aplica a una amplia clase denominada modelos gaussianos latentes. Pertenecer a esta clase exige que ciertos parámetros tengan distribuciones previas gaussianas. Más adelante veremos cuáles deben ser gaussianos; en nuestro modelo necesitamos una previa gaussiana para β . Por defecto tiene media cero, que conservaremos. INLA suele expresar la dispersión mediante la precisión, inversa de la varianza. Valores grandes representan mucha certeza. Aquí sabemos muy poco, por lo que elegimos una precisión muy pequeña. El significado de «muy pequeña» depende de la escala de los datos. Estandarizarlos puede evitar el problema, pero en este ejemplo exigiría deshacer después la estandarización al calcular la edad. Por ello mantenemos la escala original y elegimos una precisión suficientemente pequeña.

```
imod <- inla(  
  y ~ x - 1,  
  family = "gaussian",
```

```
control.fixed = list(prec = 1e-09),
data = hubble
)
```

Primero indicamos la parte estructural con la notación usual de modelos de R. Después fijamos una distribución para la respuesta; elegimos la gaussiana, aunque la respuesta no tiene que ser gaussiana para que el modelo pertenezca a la clase latente gaussiana. Podríamos elegir binomial, Poisson o muchas otras. A continuación especificamos la previa de β , el parámetro «fijo». Este término resulta algo engañoso en un contexto bayesiano, pues los parámetros no suelen estar fijos; procede de los modelos de efectos mixtos, estudiados en el capítulo 5. Bajo esa terminología igualmente problemática, σ^2 es el componente aleatorio, para el cual usamos la previa predeterminada. Para β conservamos la media predeterminada cero y fijamos una precisión de 10^{-9} . Finalmente indicamos dónde se encuentran los datos.

El modelo y el conjunto de datos son pequeños, de modo que el cálculo es prácticamente instantáneo. Se obtienen muchas cantidades; aquí nos concentramos en la distribución posterior de β .

```
(ibci <- imod$summary.fixed)
```

	mean	sd	0.025quant	0.5quant	0.975quant	mode	kld
x	76.581	3.7638	69.152	76.581	84.0	76.581	1.406e-11

Se proporcionan varios estadísticos de resumen. `kld` es un diagnóstico de la precisión de la aproximación INLA; valores pequeños, como este, son favorables. Si reproduce el ejemplo, no espere exactamente los mismos números, por razones explicadas en la sección 2.4 de la obra original. También podemos graficar la densidad posterior de β . Los comandos necesarios para extraer y representar elementos de la salida de INLA pueden ser complejos, por lo que posponemos su explicación.

```
plot(imod$marginals.fixed$x, type = "l", xlab = "beta",
     ylab = "density", xlim = c(60, 100))
abline(v = ibci[c(3, 5)], lty = 2)
```

La densidad posterior expresa nuestra incertidumbre sobre la constante de Hubble después de incorporar los datos de las 24 galaxias. El valor más probable ronda 75 y es improbable que sea menor que 70 o mayor que 90. La media, la mediana y la moda coinciden aquí con la estimación de mínimos cuadrados, 76.581.

Podemos expresar la incertidumbre mediante un intervalo que contenga el 95 % de la probabilidad. Una forma sencilla consiste en usar los percentiles 2.5 y 97.5, que producen [69.2, 84.0]. Se denomina intervalo de credibilidad para distinguirlo de un intervalo de confianza. Ahora sí afirmamos que hay una probabilidad del 95 % de que la constante de Hubble se encuentre dentro del intervalo.

Los resultados pueden transformarse a la escala de la edad del universo:

```
hubtoage(ibci[c(1, 3, 4, 5, 6)])
```

1 Introducción




Figura 1.2: Densidad posterior de β (izquierda) y de la edad del universo (derecha). Las líneas discontinuas muestran intervalos de credibilidad del 95 %.

	mean	0.025quant	0.5quant	0.975quant	mode
x	12.786	14.160	12.786	11.657	12.786

Omitimos el error estándar porque transformarlo correctamente requiere más trabajo. La densidad y su intervalo se muestran en la Figura 1.2.

```
ageden <- inla.tmarginal(hubtoage, imod$marginals.fixed$x)
plot(ageden, type = "l", xlab = "Age in billions of years",
     ylab = "density")
abline(v = hubtoage(ibci[c(3, 5)]), lty = 2)
```

El intervalo de credibilidad del 95 % va de 11.7 a 14.2 miles de millones de años, ligeramente distinto del intervalo de confianza anterior.

Usamos una previa no informativa, pero podríamos incorporar información previa. Sabemos, por ejemplo, que el universo se expande y esperamos que la constante de Hubble sea positiva. Antes del lanzamiento del telescopio espacial Hubble se pensaba que la edad del universo estaba entre 10 y 20 miles de millones de años. Llevemos esa información a la escala de la constante, recordando que `hubtoage()` funciona en sentido inverso por la naturaleza de la conversión:

```
hubtoage(c(10, 15, 20))
```

```
[1] 97.916 65.277 48.958
```

Esto sugiere una media previa de, por ejemplo, 65. Supongamos que al expresar la incertidumbre mediante $[a, b]$ se piensa, al menos implícitamente, en un intervalo de confianza o credibilidad del 95 %. Su anchura sería aproximadamente cuatro desviaciones estándar. Como aquí la anchura es 49, resulta razonable comenzar con una desviación estándar cercana a 12.

```
imod <- inla(
  y ~ x - 1,
  family = "gaussian",
  control.fixed = list(mean = 65, prec = 1/(12^2)),
  data = hubble
)
(ibci <- imod$summary.fixed)
```

	mean	sd	0.025quant	0.5quant	0.975quant	mode	kld
x	75.479	3.7292	67.981	75.522	82.729	75.596	1.1216e-11

Al convertir a la escala de la edad se obtiene una predicción un poco mayor, pues la media previa de 15 mil millones de años supera la estimación de mínimos cuadrados. Aun así, los resultados no difieren mucho. Preferimos que no sean demasiado sensibles a la elección de previa. Aunque aceptemos su inevitable subjetividad, es deseable coincidir con analistas que elijan otras previas. Con una cantidad razonable de datos, la previa tendrá poco efecto. El teorema de Bernstein–von Mises ofrece cierto respaldo teórico a esta observación empírica (véase Le Cam 2012).

¿Qué ocurre si la previa contradice por completo a los datos? Según la cronología de Ussher, el universo fue creado el 22 de octubre de 4004 a. C. Otros autores contemporáneos, entre ellos Isaac Newton, discreparon de Ussher, pero sus estimaciones se situaban a unos pocos cientos de años de esa fecha. Bajo dicha cronología, la constante de Hubble sería:

```
(uhub <- hubtoage((2016 + 4004 - 1)/1e+09))
```

```
[1] 162678504
```

Esto produce un valor enorme. El texto original propone usarlo como media previa y suponer una variación del 5 % en las estimaciones de la edad. Sin embargo, el bloque de código impreso repite por error la previa anterior (`mean = 65, prec = 1/(12^2)`); se conserva a continuación para mantener fidelidad documental.

```
imod <- inla(
  y ~ x - 1,
  family = "gaussian",
  control.fixed = list(mean = 65, prec = 1/(12^2)),
  data = hubble
)
(ibci <- imod$summary.fixed)
```

El resultado vuelve a ser muy similar al de la previa no informativa. La distribución normal asigna peso a toda la recta real. Aunque las probabilidades de valores muy alejados de la media sean minúsculas, no son cero, lo que permite que los datos superen una previa inusual.

En algunos casos, la previa puede ser tan incompatible con los datos que surjan dificultades computacionales y resultados extraños. Se habla entonces de conflictos entre datos y previa, aunque también debe considerarse la posibilidad de que el propio modelo sea muy erróneo; véase Evans y Moshonov (2006). Antes de explorar más aplicaciones de INLA necesitamos desarrollar algo de teoría.

1.2. Teoría de Bayes

No intentaremos ofrecer aquí una introducción completa a la teoría bayesiana. Remitimos a Gelman et al. (2014) y Carlin y Louis (2008). Solo haremos un recorrido breve por las ideas y métodos necesarios más adelante. Quien ya tenga experiencia bayesiana puede pasar al capítulo siguiente.

Partimos de un modelo paramétrico $p(\mathbf{y} \mid \theta)$ para los datos $\mathbf{y}$, con parámetros θ . Proponemos el modelo de acuerdo con la estructura de los datos, la información sobre su recolección y el conocimiento de su contexto. Existe incertidumbre sobre los parámetros, que esperamos reducir con los datos, y casi siempre también sobre el propio modelo. Rara vez creemos que sea completamente verdadero; esperamos que constituya una aproximación eficaz a la realidad para el propósito previsto. Por ello es razonable considerar modelos alternativos y comprobar si el elegido resulta adecuado para los datos observados.

En vez de ver $p(\mathbf{y} \mid \theta)$ como función de $\mathbf{y}$, podemos verla como función de θ . Esta verosimilitud $L(\theta)$ representa nuestra incertidumbre acerca de θ , pero es importante entender que no constituye una densidad de probabilidad para ese parámetro.

En el enfoque frecuentista buscamos estimar θ . La forma natural y más habitual consiste en hallar los valores más verosímiles maximizando $L(\theta)$; se obtiene así la estimación de máxima verosimilitud (MLE). Esta posee muchas propiedades favorables y permite derivar cantidades útiles como errores estándar e intervalos de confianza. En casos sencillos se calcula explícitamente; por lo general requiere optimización numérica. En muchos modelos comunes estos métodos están bien comprendidos y son eficientes, aunque en modelos más complejos pueden volverse problemáticos. Pese a ello, la principal razón para preferir métodos bayesianos no es computacional, pues suelen ser más lentos: las respuestas de un análisis bayesiano son conceptualmente diferentes.

Para el frecuentismo, θ es fijo pero desconocido y los datos sirven para estimarlo. Para el bayesianismo, los parámetros son variables aleatorias. Antes de observar los datos expresamos la incertidumbre mediante una densidad previa $\pi(\theta)$. Actualizamos esa incertidumbre con los datos y el modelo para producir la densidad posterior $p(\theta \mid \mathbf{y})$. El teorema de Bayes proporciona la transformación:

$$p(\theta \mid \mathbf{y}) = \frac{p(\mathbf{y} \mid \theta)\pi(\theta)}{p(\mathbf{y})}.$$

En palabras,

$$\text{Posterior} \propto \text{Verosimilitud} \times \text{Previa}.$$

Aunque el concepto es sencillo, debemos calcular la constante normalizadora

$$p(\mathbf{y}) = \int p(\mathbf{y} \mid \theta)\pi(\theta) d\theta,$$

la probabilidad marginal de los datos bajo el modelo. Integrales como esta explican por qué la sencillez conceptual del teorema exige más trabajo del que parece.

1.3. Distribuciones previas y posteriores

Especificar la previa es una parte importante y quizá la más débil de un análisis bayesiano, pues sus críticos pueden cuestionar razonablemente cualquier elección. Cuando las conclusiones son polémicas, defender una previa particular puede ser difícil. Cabe responder que la elección del modelo también suele ser subjetiva y no siempre admite una justificación firme, de modo que un análisis frecuentista tampoco puede pretender objetividad total. Casi todo análisis contiene cierta subjetividad; el enfoque bayesiano simplemente hace explícitas sus decisiones.

La mejor motivación para una previa es el conocimiento sustantivo sobre θ . A veces procede de la opinión experta, que quizá deba formularse matemáticamente, y otras de experiencias anteriores con datos similares. Incluso puede utilizarse como previa la posterior de un experimento previo. Estas previas se denominan informativas o sustantivas. Si la información está disponible, sin duda debería aprovecharse. Cuando no lo está, necesitamos otra base para decidir.

Una opción especialmente cómoda es la previa conjugada: previa y posterior pertenecen a la misma familia y existe una fórmula explícita para los parámetros posteriores en función de los parámetros previos y los datos. Por ejemplo, para una muestra normal univariada, una previa normal sobre la media —con varianza conocida— produce una posterior normal. Antes de disponer de cómputo rápido, esta elección era muy recomendable. Sin embargo, solo existe para un puñado de modelos sencillos y su conveniencia no constituye una razón sustantiva para preferirla frente a otras alternativas razonables.

Cuando no se dispone de información firme, puede desearse una elección «segura» sin consecuencias fuertes. Ese deseo es comprensible, pero sorprendentemente difícil de satisfacer. La opción aparentemente más directa es la previa plana:

$$\pi(\theta) \propto 1.$$

No favorece en apariencia ningún valor particular, pero no es una densidad propia, salvo que θ tenga rango finito, porque no integra a un valor finito. A menudo podemos proceder normalizando la verosimilitud como densidad; a veces el resultado es satisfactorio y otras veces irrazonable. Resulta difícil delimitar exactamente cuándo falla, por lo que conviene ser escéptico ante posteriores derivadas de previas planas.

Además, la planitud depende de la escala. Si σ es la desviación estándar y σ^2 la varianza de una normal, elegir $\pi(\sigma) \propto 1$ no equivale a elegir $\pi(\sigma^2) \propto 1$. Ser plana en una escala implica ser informativa en otra. Esta falta de invariancia afecta a otros intentos de obtener previas no informativas. Una posible solución es la previa de Jeffreys:

$$\pi(\theta) \propto |I(\theta)|^{1/2}.$$

Es invariante ante reparametrizaciones, pero produce resultados poco razonables en algunos modelos y no es una solución universal. Las previas objetivas intentan reducir la subjetividad, aunque eliminar el juicio humano parece irreal. En algunas clases de problemas se han consolidado elecciones habituales. Seguir las protege de ciertas críticas de arbitrariedad, pero pueden ser meras costumbres sin justificación más sólida.

1 Introducción

INLA ofrece un menú limitado de previas preprogramadas, aunque permite definir otras. Además, veremos que al menos algunos parámetros están restringidos a una previa gaussiana. Para aquellos donde sí existe elección, Simpson et al. (2017) formula principios generales de construcción implementados en INLA.

Aunque una postura bayesiana muy ortodoxa exige elegir la previa una sola vez antes de ver los datos, hay buenas razones para experimentar con alternativas razonables. Si las conclusiones son cualitativamente semejantes, aumenta nuestra confianza; si resultan muy sensibles, debemos moderar nuestras afirmaciones. A esta propiedad se la denomina *sensibilidad a la previa*, y deseamos que sea pequeña.

Las posteriores son menos problemáticas, pues quedan completamente determinadas por la previa y la verosimilitud. No obstante, comprenderlas no siempre es sencillo. $p(\theta \mid \mathbf{y})$ suele ser multivariante y, a veces, de dimensión muy elevada. Como es difícil visualizarla, a menudo examinamos la distribución marginal de un parámetro θ_i :

$$p(\theta_i \mid \mathbf{y}) = \int p(\theta \mid \mathbf{y}) d\theta_{-i},$$

donde θ_{-i} denota θ sin su componente i . Esto requiere integración multidimensional. En una normal multivariante es sencillo; en otras situaciones puede ser exigente.

Es buena práctica graficar las posteriores marginales. También pueden resumirse con media, mediana y moda. En distribuciones aproximadamente simétricas apenas difieren; en distribuciones sesgadas conviene entender sus distinciones y observar la densidad. La dispersión puede resumirse mediante la desviación estándar o cuantiles seleccionados.

Los cuantiles 2.5 y 97.5 forman un intervalo de credibilidad del 95%. A diferencia del intervalo de confianza frecuentista, este sí afirma que el parámetro se encuentra en el intervalo con una probabilidad especificada. Los intervalos de credibilidad no son únicos: los cuantiles son fáciles de calcular, pero también puede buscarse el intervalo más corto que contenga la probabilidad indicada. Se denomina intervalo de máxima densidad posterior (HPD) y puede calcularse con `inla.hpdmarginal()`.

1.4. Comprobación del modelo

La distribución predictiva de una observación futura z es

$$p(z \mid \mathbf{y}) = \int p(z \mid \theta) p(\theta \mid \mathbf{y}) d\theta.$$

Además de servir para predecir, permite comprobar el modelo. La ordenada predictiva condicional (CPO), introducida por Pettit (1990), se define como

$$\text{CPO}_i = p(y_i \mid \mathbf{y}_{-i}),$$

donde $\mathbf{y}_{-i}$ contiene todos los datos salvo la observación i . La CPO mide la probabilidad o densidad del valor observado y_i ; valores especialmente pequeños señalan observaciones inusuales que el

modelo no explica bien. Algunas observaciones son tan influyentes que alteran mucho el ajuste; por ello se excluye la propia observación al calcular la CPO. Parecería necesario reajustar el modelo para cada caso, pero existen atajos eficaces que reducen notablemente el costo (Held, Schrödle, y Rue 2010).

La transformación integral de probabilidad (PIT), introducida por Dawid (1984), es semejante:

$$\text{PIT}_i = P(Y_i < y_i \mid \mathbf{y}_{-i}).$$

Tiene mayor sentido para una respuesta continua. Con un buen modelo, las PIT del conjunto de datos deberían distribuirse aproximadamente de manera uniforme. Valores cercanos a cero o uno indican observaciones mucho menores o mayores, respectivamente, de lo esperado. INLA también dispone de formas económicas de calcularlas.

1.5. Selección del modelo

A veces debemos elegir entre varios modelos propuestos. Necesitamos entonces un criterio que mida su concordancia con los datos. El más conocido es el criterio de información de Akaike:

$$\text{AIC} = -2 \log p(\mathbf{y} \mid \hat{\theta}_{\text{MLE}}) + 2k,$$

donde k es el número de parámetros. Se prefieren valores pequeños. La primera parte mide el ajuste; sin la segunda, los modelos grandes siempre serían favorecidos. La penalización prefiere modelos pequeños. Desde una perspectiva bayesiana hay dos problemas: el criterio se basa en la MLE y el conteo k resulta problemático en modelos jerárquicos, cuyo número efectivo de parámetros no es evidente.

Para modelos bayesianos podemos preferir el criterio de información de la devianza (DIC) de Spiegelhalter et al. (2002), inspirado en AIC. Definimos la devianza:

$$D(\theta) = -2 \log p(\mathbf{y} \mid \theta).$$

En un modelo bayesiano es una variable aleatoria, por lo que usamos la devianza esperada $\bar{D} = E[D(\theta)]$ bajo la posterior como medida de ajuste. El número efectivo de parámetros es

$$p_D = E[D(\theta)] - D[E(\theta)] = \bar{D} - D(\bar{\theta}),$$

y entonces

$$\text{DIC} = \bar{D} + p_D.$$

Se calcula para cada modelo y se elige el menor; véase Spiegelhalter et al. (2014). Una alternativa es el criterio de información de Watanabe–Akaike (WAIC) (Watanabe 2010), construido con un enfoque más plenamente bayesiano. Gelman et al. (2014) sostiene que WAIC es preferible a DIC y

explica por qué el denominado criterio de información bayesiano (BIC) no es comparable con los anteriores.

Finalmente, cabe preguntar por qué elegir un solo modelo cuando podemos aprovechar la información de todos. Podemos asignar una probabilidad previa a cada uno, actualizarla a una probabilidad posterior y combinar la información para realizar inferencias o predicciones. Esta idea se denomina promediado bayesiano de modelos (Draper 1995).

1.6. Contraste de hipótesis

En el enfoque frecuentista, la hipótesis nula H_0 suele ser un solo punto y la alternativa H_1 , todo lo demás. Se propone un estadístico y se calcula, bajo H_0 , la probabilidad de observar un valor igual o más extremo que el obtenido: el valor p . Aunque se interpreta así con frecuencia, no es la probabilidad de que H_0 sea verdadera. La práctica común declara un resultado «estadísticamente significativo» y rechaza H_0 si $p < 0.05$; si no es pequeño, no se rechaza.

Este procedimiento se denomina contraste de significación de la hipótesis nula (NHST). Existe un debate enorme que no repetiremos. Pese a las críticas, el NHST está firmemente arraigado en la práctica científica. Quien analiza datos necesita publicar y lograr que se acepten sus resultados, de modo que no puede ignorarlo. Conviene desarrollar respuestas comparables dentro del marco bayesiano, aunque su motivación sea distinta.

Supongamos que deseamos comparar H_0 y H_1 , con probabilidades previas $p(H_0)$ y $p(H_1)$. Entonces

$$\frac{p(H_0 | \mathbf{y})}{p(H_1 | \mathbf{y})} = \frac{p(\mathbf{y} | H_0) p(H_0)}{p(\mathbf{y} | H_1) p(H_1)}.$$

El primer cociente del lado derecho es el factor de Bayes y el segundo, las *odds* previas. Las *odds* posteriores son su producto. Puede ser difícil especificar las *odds* previas, pero el factor de Bayes indica cuánto las modifican los datos. Podemos informarlo y permitir que cada lector decida según sus propias *odds*. Para calcularlo necesitamos las probabilidades marginales de cada modelo, precisamente las constantes normalizadoras empleadas al obtener las posteriores.

El factor de Bayes evita comprometerse con previas sobre las hipótesis, pero aún requiere previas para ajustar ambos modelos, cuidadosamente elegidas para no favorecer a ninguno. A pesar de su atractivo filosófico, nunca se ha generalizado realmente en las publicaciones científicas.

Con frecuencia H_0 impone $\theta_k = 0$. Si la previa es continua, la posterior también lo será y $P(\theta_k = 0) = 0$. Podríamos usar una previa que asigne masa positiva al cero, pero habría que decidir cuánta y afrontar cálculos difíciles que mezclan componentes discretos y continuos. Además, en muchas aplicaciones no es razonable creer que un parámetro continuo sea exactamente igual a un valor específico.

Una solución es calcular $P(|\theta_k| < c)$, escogiendo c tan grande como sea posible sin dejar de considerar despreciable a θ_k . El problema es justificar c . Podríamos publicar la posterior marginal para que cada lector decida, aunque las publicaciones suelen exigir conclusiones más firmes.

Podemos tomar prestada una idea frecuentista: contrastar $H_0 : \theta_k = 0$ comprobando si cero pertenece a un intervalo. Con una posterior relativamente simétrica y media positiva, un análogo del valor p es

$$p = 2P(\theta_k < 0),$$

usando la otra cola si la media es negativa. En realidad solo mide la posición del cero en la posterior, pero se parece a un valor p y no sería irrazonable utilizarlo de forma análoga.

1.7. Computación bayesiana

La teoría es clara, pero calcular la posterior y otras cantidades de interés no siempre resulta fácil. Existen tres vías principales.

1.7.1. Cálculo exacto

Una previa conjugada produce una posterior de la misma familia y suele permitir expresar explícitamente sus parámetros a partir de la previa y de alguna función de los datos. Solo hay un número reducido de previas conjugadas para modelos bastante sencillos, por lo general sin covariables. Los modelos complejos reúnen parámetros de distintos tipos y varias previas, a menudo de familias diferentes, por lo que no puede alcanzarse la conjugación.

Históricamente, estos eran casi los únicos modelos que admitían un análisis bayesiano completo, lo que limitó seriamente su adopción. Con la computación actual podemos considerar muchos más modelos y la conjugación ha quedado como una cuestión secundaria: cómoda para exámenes de licenciatura, pero de utilidad práctica limitada.

Como la posterior es proporcional al producto de verosimilitud y previa, para hallar su moda basta maximizar dicho producto sin conocer la constante normalizadora. Se obtiene el estimador máximo a posteriori (MAP). Con una previa plana coincide con la MLE. El método solo requiere optimización numérica, pero entrega una estimación puntual sin evaluar incertidumbre; es, como mucho, una solución parcial.

1.7.2. Muestreo

Los métodos basados en muestreo buscan generar muestras de la distribución posterior. Aunque existen varios esquemas para modelos sencillos, los principales generan una cadena de Markov cuya distribución estacionaria es la posterior. La idea se remonta a Metropolis et al. (1953) y Hastings (1970), y se difundió en estadística tras Gelfand y Smith (1990). En conjunto se denominan métodos MCMC. Como este libro trata sobre un competidor de MCMC, no explicaremos su funcionamiento, sino solo las etapas generales de un análisis.

Después de elegir modelo y previa y preparar los datos, podríamos derivar e implementar un método MCMC, pero lo habitual es usar un paquete que admita nuestra elección. Si nos limitamos a programas escritos en R o invocables desde R, hay muchas posibilidades.

1 Introducción

La vista de tareas bayesiana de CRAN enumera paquetes que implementan MCMC para clases concretas de modelos. Suelen llamarse desde R, aunque sus partes costosas estén escritas en un lenguaje compilado, normalmente C. Esto evita aprender otro lenguaje y mejora la velocidad, pero restringe el usuario a una clase estrecha de modelos y previas. Un ejemplo relativamente general es `MCMCglmm` (Hadfield 2010), capaz de manejar una buena parte de los modelos de este libro.

También existen programas generales que ajustan una amplia gama de modelos. Emplean un lenguaje especializado para especificar modelo y previa; se ejecutan por separado, aunque pueden invocarse desde R y devolver resultados. BUGS (*Bayesian inference Using Gibbs Sampling*), presentado en 1989, fue el primero; Lunn et al. (2012) ofrece una introducción. Evolucionó a WinBUGS y OpenBUGS. JAGS (*Just Another Gibbs Sampler*) es otra variante (Plummer 2003). Más tarde apareció STAN (Stan Development Team 2016). BayesX (Umlauf et al. 2015) es algo más específico y utiliza parcialmente MCMC.

Un análisis MCMC comprende varias etapas:

1. Escribir código que especifique el modelo, la previa y la forma de transferir los datos. Para quien acostumbra ajustar modelos con una sola instrucción en R, esto exige aprendizaje y experiencia considerables.
2. Elegir valores iniciales para la cadena. En principio, el inicio no debería importar demasiado, pero valores inverosímiles o desafortunados pueden impedir la convergencia. Es aconsejable experimentar con varios inicios y saber reconocer una cadena problemática. STAN utiliza cuatro conjuntos de valores iniciales aleatorios, precaución sensata con cualquier paquete.
3. Ejecutar la cadena hasta alcanzar un estado estacionario. Las observaciones anteriores se descartan como valores de *burn-in* o calentamiento. Existen diagnósticos para decidir si se alcanzó la estacionariedad, aunque una cadena puede no visitar regiones plausibles del espacio y aun así parecer satisfactoria.
4. Tener en cuenta la correlación positiva entre observaciones sucesivas. La muestra debe ser mayor que una muestra independiente. En ocasiones se «adelgaza», conservando solo cada n -ésima observación; esto ahorra almacenamiento, pero no es una necesidad estadística.
5. Recordar que el resultado es una muestra de la posterior, no la posterior misma. En principio permite estimar cualquier funcional; en la práctica hay que equilibrar costo y precisión. Estimar una media requiere menos simulaciones que estimar un cuantil extremo.

El aumento de la velocidad de cómputo y las mejoras de MCMC han ampliado la gama de modelos y tamaños de datos abordables. Aun así, algunas combinaciones fallan o exigen tiempos irrazonables. Incluso cuando un modelo puede ajustarse con paciencia, experimentar con muchos modelos puede resultar prohibitivo, lo que obstaculiza el estilo moderno de análisis.

Debe reconocerse el enorme éxito de MCMC, pero conserva dos desventajas principales: es difícil de usar y es lento.

1.7.3. Aproximación

Las soluciones exactas se limitan casi siempre a modelos estrechos y sencillos con conjugación. Las soluciones aproximadas recurren a integración numérica. La principal dificultad es la elevada dimensión. En el capítulo siguiente se explica cómo la cuadratura y, en particular, la aproximación

de Laplace producen aproximaciones precisas. En estadística, estos métodos parten del trabajo seminal de Tierney y Kadane (1986). Además de INLA existen métodos como Bayes variacional.

La ventaja de INLA frente a MCMC es su velocidad. En problemas grandes puede encontrar una solución donde MCMC tardaría demasiado. En problemas pequeños permite una construcción y comprobación de modelos más exploratoria e interactiva. En análisis frecuentistas la MLE suele obtenerse rápidamente, lo que permite dedicar atención a diagnósticos y a explorar el espacio de modelos. Esta exploración es crucial: acertar con el modelo importa más que el método de inferencia. Si cada ajuste cuesta demasiado, reduciremos la exploración. INLA es suficientemente rápido para explorar con libertad.

INLA también es más fácil de usar. No hay otro lenguaje que aprender ni que navegar por los difíciles diagnósticos MCMC. En su mayor parte es no aleatorio, de modo que los análisis son más reproducibles. El resultado de MCMC es aleatorio; fijar la semilla lo reproduce, pero una réplica verdaderamente independiente será diferente. Una muestra grande mitiga el problema, pero no lo elimina.

No conviene exagerar las ventajas de INLA. Los paquetes MCMC más generales cubren una gama de modelos más amplia de lo que INLA podrá abarcar. INLA se aplica a una clase extensa, pero limitada. Además, cuando los datos importan de verdad, es prudente asegurarse de que el análisis no dependa de una peculiaridad del programa empleado. Una vez elegido un modelo con INLA, vale la pena repetir el ajuste mediante MCMC. Si los resultados coinciden, tendremos mayor confianza cualitativa; si discrepan, será interesante averiguar por qué.

2 Teoría de INLA

La metodología de aproximaciones de Laplace anidadas integradas (INLA) fue presentada por primera vez por Rue, Martino, y Chopin (2009), seguida por los desarrollos de Martins et al. (2013) y la revisión más reciente de Rue et al. (2017). Es un enfoque determinista para realizar inferencia bayesiana aproximada en modelos gaussianos latentes (LGM). En la mayoría de los casos, INLA es más rápido y preciso que las alternativas MCMC para estos modelos. El paquete INLA de R permite realizar inferencia bayesiana rápida y confiable en aplicaciones prácticas.

En este capítulo revelaremos los «secretos» del éxito de INLA. Requiere tres componentes esenciales: el marco de los LGM, un campo aleatorio gaussiano de Markov (GMRF) y la aproximación de Laplace. Los introduciremos de arriba abajo. Comenzaremos por los LGM y los modelos estadísticos que pueden expresarse de ese modo; después estudiaremos los GMRF, procesos gaussianos computacionalmente eficientes dentro de esta formulación; finalmente veremos cómo INLA utiliza la antigua técnica de aproximación de Laplace para integrar y producir inferencia bayesiana rápida y precisa.

La teoría no es sencilla y algunas personas quizá prefieran omitir en una primera lectura la sección sobre la aproximación de Laplace. Aun así, vale la pena entender los LGM y GMRF, pues permiten distinguir qué modelos pueden abordarse con INLA y cuáles son imposibles o poco prácticos.

2.1. Modelos gaussianos latentes (LGM)

INLA se restringe a los denominados modelos gaussianos latentes. Tienen una amplia gama de aplicaciones y, de hecho, la mayoría de los modelos bayesianos estructurados adoptan esta forma. Aquí nos concentramos en modelos de regresión, el subconjunto más utilizado. Otros LGM habituales incluyen modelos dinámicos, espaciales y espacio-temporales (Rue, Martino, y Chopin 2009; Blangiardo y Cameletti 2015).

Un ejemplo sencillo es el modelo lineal generalizado bayesiano (GLM), estudiado con detalle en el capítulo 4. Su predictor lineal es

$$\eta_i = \beta_0 + \beta_1 x_i, \quad i = 1, \dots, n,$$

donde β_0 es el intercepto, x_i la covariable y β_1 la pendiente o efecto lineal. Se supone que y_i sigue una distribución de la familia exponencial y que su media condicional μ_i se relaciona con η_i mediante una función de enlace $g(\cdot)$, de modo que $\eta_i = g(\mu_i)$. INLA ofrece numerosas verosimilitudes; la gaussiana es la predeterminada. La lista puede consultarse así:

```
library(INLA)
names(inla.models())$likelihood
```

2 Teoría de INLA

Aunque la verosimilitud no tiene que ser gaussiana, en un LGM cada predictor latente η_i debe seguir una distribución normal condicionada a sus hiperparámetros. Debemos, por tanto, usar previas gaussianas

$$\beta_0 \sim N(\mu_0, \sigma_0^2), \quad \beta_1 \sim N(\mu_1, \sigma_1^2),$$

lo que implica

$$\eta_i \sim N(\mu_0 + \mu_1 x_i, \sigma_0^2 + \sigma_1^2 x_i^2).$$

Mediante álgebra lineal puede mostrarse que $\eta = (\eta_1, \dots, \eta_n)^T$ es un proceso gaussiano con vector de medias μ y matriz de covarianzas Σ . Las varianzas σ_0^2 y σ_1^2 son hiperparámetros que pueden fijarse o estimarse asignándoles hiperprevias.

Podemos adoptar una forma aditiva más general:

$$\eta_i = \beta_0 + \sum_{j=1}^p \beta_j x_{ji} + \sum_{k=1}^K f_k(z_{ki}). \quad (2.1)$$

Las covariables y los componentes $f_k(\cdot)$ permiten relajar la relación lineal, introducir efectos aleatorios o ambas cosas. Los efectos suaves no lineales pueden representarse mediante términos paramétricos —por ejemplo, cuadráticos— o modelos no paramétricos como caminatas aleatorias, P-splines y procesos gaussianos. Para representar sobredispersión causada por heterogeneidad no observada o correlación en datos longitudinales, pueden introducirse efectos aleatorios con distribuciones normales independientes de media cero.

En muchas aplicaciones el predictor es una suma de efectos aleatorios, efectos lineales y efectos suaves, como en (2.1). Estos modelos se denominan modelos aditivos generalizados (GAM). Para que η sea gaussiano, cada efecto lineal y cada componente deben recibir una previa normal univariante o multivariante. Existe una clase particularmente flexible y eficiente, los GMRF, que permite modelar muchos de estos efectos.

Formulemos ahora un LGM jerárquico genérico en tres etapas. Sea $\mathbf{y} = (y_1, \dots, y_n)^T$. En la primera etapa, condicionados a η y a los hiperparámetros θ_1 , suponemos independencia y una distribución de la familia exponencial:

$$\pi(\mathbf{y} \mid \eta, \theta_1) = \prod_{i=1}^n \pi(y_i \mid \eta_i, \theta_1).$$

En la segunda etapa, η es un campo gaussiano latente con densidad

$$\pi(\eta \mid \theta_2) \propto |\mathbf{Q}_{\theta_2}|^{1/2} \exp\left(-\frac{1}{2} \eta^T \mathbf{Q}_{\theta_2} \eta\right),$$

donde $\mathbf{Q}_{\theta_2}$ es una matriz semidefinida positiva dependiente de los hiperparámetros; su determinante generalizado es el producto de sus valores propios no nulos. Se denomina matriz de precisión y describe la dependencia de los datos. Su inversa, cuando existe, es una matriz de covarianzas.

En la tercera etapa asignamos una previa $\pi(\theta)$ a $\theta = (\theta_1, \theta_2)$. Puede ser conjunta o un producto de distribuciones. La posterior conjunta es

$$\begin{aligned}\pi(\eta, \theta | \mathbf{y}) &\propto \pi(\theta) \pi(\eta | \theta) \prod_{i=1}^n \pi(y_i | \eta_i, \theta_1) \\ &\propto \pi(\theta) |\mathbf{Q}_\theta|^{1/2} \exp \left[-\frac{1}{2} \eta^T \mathbf{Q}_\theta \eta + \sum_i \log \pi(y_i | \eta_i, \theta_1) \right].\end{aligned}\quad (2.2)$$

La inferencia bayesiana se deriva de esta expresión. INLA aplica la aproximación de Laplace anidada descrita más adelante para obtener distribuciones posteriores aproximadas de cada parámetro desconocido.

No todos los LGM pueden ajustarse eficientemente con INLA. En general se requieren además estas condiciones:

1. El número de hiperparámetros debe ser pequeño, normalmente entre 2 y 5 y no mayor que 20.
2. Cuando n es grande, de 10^4 a 10^6 , η debe ser un GMRF.
3. Cada y_i debe depender solo de un componente del campo, por ejemplo η_i .

Estas condiciones son importantes tanto por razones computacionales como para asegurar la precisión de las aproximaciones. Las dos primeras deben cumplirse estrictamente; la última puede relajarse hasta cierto punto (Martins et al. 2013).

2.2. Campos aleatorios gaussianos de Markov (GMRF)

Para que INLA trabaje eficientemente, el campo latente no solo debe ser gaussiano, sino también un GMRF. Consideremos un caso sencillo: η_i sigue un proceso autorregresivo de primer orden, AR(1). Si el valor actual depende del inmediatamente anterior,

$$\begin{cases} \eta_1 \sim N(0, \sigma_\eta^2 / (1 - \rho^2)), \\ \eta_i | \eta_1, \dots, \eta_{i-1} \sim N(\rho \eta_{i-1}, \sigma_\eta^2), \quad i = 2, \dots, n. \end{cases}$$

El parámetro $|\rho| < 1$ es la correlación entre η_i y η_{i-1} . La distribución marginal de cada η_i es gaussiana de media cero y varianza $\sigma_\eta^2 / (1 - \rho^2)$, mientras que

$$\text{Cov}(\eta_i, \eta_j) = \frac{\sigma_\eta^2 \rho^{|i-j|}}{1 - \rho^2},$$

que decrece con $|i - j|$. Por ello, $\eta \sim N(\mathbf{0}, \Sigma)$ y Σ es una matriz densa de $n \times n$. Los cálculos con matrices densas son costosos, lo que parecería hacer poco conveniente un AR(1) para datos grandes.

Por fortuna, el AR(1) posee una matriz de precisión dispersa. A partir de

$$\pi(\eta) = \pi(\eta_1)\pi(\eta_2 | \eta_1) \cdots \pi(\eta_n | \eta_{n-1}, \dots, \eta_1)$$

se obtiene una normal multivariante con

$$\mathbf{Q} = \sigma_\eta^{-2} \begin{pmatrix} 1 & -\rho & & & \\ -\rho & 1 + \rho^2 & -\rho & & \\ & \ddots & \ddots & \ddots & \\ & & -\rho & 1 + \rho^2 & -\rho \\ & & & -\rho & 1 \end{pmatrix}.$$

Solo son distintos de cero los elementos de la diagonal principal y de las diagonales inmediatamente superior e inferior. La razón es que, dadas las demás variables, η_i solo depende de su vecina inmediata. En otras palabras, η_i y η_j son condicionalmente independientes cuando $|i - j| > 1$. Por ejemplo,

$$\pi(\eta_2, \eta_4 | \eta_1, \eta_3) = \pi(\eta_2 | \eta_1)\pi(\eta_4 | \eta_3).$$

La correlación condicional entre η_i y η_j está dada por $-Q_{ij}/\sqrt{Q_{ii}Q_{jj}}$; por tanto, un cero en Q_{ij} expresa independencia condicional. En procesos AR de orden superior, la precisión es menos dispersa porque cada variable depende de más valores anteriores.

En general, η es un GMRF si posee una densidad normal multivariante y una estructura adicional de independencia condicional, denominada propiedad de Markov. Los GMRF se utilizan extensamente en numerosos campos (Rue y Held 2005). Sus distintas estructuras representan nuestras creencias sobre la dependencia local entre variables, pero todas comparten una matriz de precisión dispersa.

Esto produce un beneficio computacional enorme. Invertir la covarianza densa de un AR(1) cuesta $O(n^3)$, mientras que factorizar su precisión tridiagonal cuesta $O(n)$. La memoria también se reduce de $O(n^2)$ a $O(n)$, lo que facilita modelos mucho mayores.

Al construir modelos aditivos como (2.1), aparece parte de la «magia» de INLA: su distribución conjunta también es un GMRF y la matriz de precisión resulta de sumar las precisiones de covariables y componentes. Esta distribución debe formarse muchas veces porque depende de θ , pero puede manipularse como un GMRF cuya precisión es fácil de calcular. La dispersión de la matriz aumenta aún más la eficiencia.

2.3. Aproximación de Laplace e INLA

La aproximación de Laplace se utiliza para aproximar

$$I_n = \int_a^b \exp\{nf(x)\} dx, \quad n \rightarrow \infty.$$

Sea x_0 la moda de $f(x)$. Una expansión de Taylor alrededor de x_0 , donde $f'(x_0) = 0$, produce

$$\begin{aligned}
 I_n &\approx \exp\{nf(x_0)\} \int_a^b \exp\left\{\frac{n}{2}(x-x_0)^2 f''(x_0)\right\} dx \\
 &\approx \exp\{nf(x_0)\} \sqrt{\frac{2\pi}{-nf''(x_0)}}.
 \end{aligned}$$

La integral intermedia es gaussiana. Si $nf(x)$ se interpreta como una suma de log-verosimilitudes y x como el parámetro desconocido, la aproximación será exacta cuando $n \rightarrow \infty$, siempre que se cumpla el teorema central del límite. Se extiende de inmediato a integrales multidimensionales con una tasa de error favorable.

Veamos cómo constituye la piedra angular de INLA. Supongamos dos conteos, $y_1 = 1$ y $y_2 = 2$, con distribución Poisson de media λ_i . Usamos enlace logarítmico, $\lambda_i = \exp(\eta_i)$, y un AR(1) para η_i . La posterior es

$$\pi(\eta \mid \mathbf{y}) \propto \exp\left(-\frac{1}{2}\eta^T \mathbf{Q}_\theta \eta\right) \exp(\eta_1 + 2\eta_2 - e^{\eta_1} - e^{\eta_2}),$$

con hiperparámetros de escala y autocorrelación. Si por ahora se consideran constantes, queremos aproximar las marginales de η_1 y η_2 . Aplicar directamente una aproximación gaussiana bidimensional no representa bien su ubicación ni su asimetría. El desempeño mejora mediante una secuencia de aproximaciones condicionadas:

$$\tilde{\pi}(\eta_1 \mid \mathbf{y}) = \frac{\pi(\eta \mid \mathbf{y})}{\tilde{\pi}_G(\eta_2 \mid \eta_1, \mathbf{y})} \Big|_{\eta_2 = \eta_2^*(\eta_1)},$$

donde el denominador es una aproximación gaussiana a la condicional completa. Cada condicional se acerca mucho más a una gaussiana que la distribución conjunta. Esta es la idea clave: aplicar Laplace solo a densidades casi gaussianas y sustituir dependencias complejas por condicionamiento.

En un LGM general, el objetivo consiste en aproximar las marginales $\pi(\eta_i \mid \mathbf{y})$ y $\pi(\theta_j \mid \mathbf{y})$. INLA divide el problema en tres tareas: aproximar la posterior conjunta de los hiperparámetros, aproximar las marginales condicionales de cada η_i dados los hiperparámetros y explorar la aproximación de $\pi(\theta \mid \mathbf{y})$ para integrarla numéricamente. El resultado tiene la forma

$$\tilde{\pi}(\eta_i \mid \mathbf{y}) = \int \tilde{\pi}(\eta_i \mid \theta, \mathbf{y}) \tilde{\pi}(\theta \mid \mathbf{y}) d\theta. \quad (2.3a)$$

$$\tilde{\pi}(\theta_j \mid \mathbf{y}) = \int \tilde{\pi}(\theta \mid \mathbf{y}) d\theta_{-j}. \quad (2.3b)$$

2.3.1. Aproximación de $\pi(\theta \mid \mathbf{y})$

La aproximación de Laplace a la posterior conjunta de los hiperparámetros es

$$\tilde{\pi}(\theta \mid \mathbf{y}) \propto \frac{\pi(\eta, \theta \mid \mathbf{y})}{\tilde{\pi}_G(\eta \mid \theta, \mathbf{y})} \bigg|_{\eta=\eta^*(\theta)}. \quad (2.4)$$

donde $\tilde{\pi}_G$ es una aproximación gaussiana a la condicional completa, obtenida haciendo coincidir la moda y la curvatura, y $\eta^*(\theta)$ es la moda para un valor dado de los hiperparámetros. Será exacta si la condicional es gaussiana. Adopta la forma

$$\tilde{\pi}_G(\eta \mid \theta, \mathbf{y}) \propto |\mathbf{R}_\theta|^{1/2} \exp \left[-\frac{1}{2}(\eta - \mu_\theta)^T \mathbf{R}_\theta (\eta - \mu_\theta) \right]. \quad (2.5)$$

con $\mathbf{R}_\theta = \mathbf{Q}_\theta + \text{diag}(\mathbf{c}_\theta)$, donde $\mathbf{c}$ contiene las segundas derivadas negativas de la log-verosimilitud en la moda. Sigue siendo un GMRF con la misma estructura de dependencia: las observaciones solo desplazan la media y modifican la diagonal de la precisión. Esto hace barata su evaluación para cada θ y suele producir una buena aproximación.

Las transformaciones estabilizadoras de varianza reducen colas largas y asimetrías. Para un AR(1), INLA transforma la precisión marginal κ y la correlación ρ como

$$\theta_1 = \log \kappa, \quad \theta_2 = \log \frac{1 + \rho}{1 - \rho},$$

y utiliza la Hessiana en la moda para construir combinaciones lineales casi independientes de los hiperparámetros.

2.3.2. Aproximación de $\pi(\eta_i \mid \theta, \mathbf{y})$

Hay tres opciones con distintos compromisos entre velocidad y precisión:

- **Gaussiana:** usa directamente las marginales de (2.5). Solo exige calcular varianzas marginales a partir de la precisión dispersa. Es rápida y a menudo razonable, pero puede errar en ubicación o asimetría.
- **Laplace completa:** vuelve a aplicar Laplace al cociente entre la posterior conjunta y una aproximación gaussiana condicional de η_{-i} . Es más precisa, pero obliga a localizar muchas modas y factorizar repetidamente matrices de $(n-1) \times (n-1)$.
- **Laplace simplificada:** expande numerador y denominador hasta tercer orden, corrigiendo ubicación y asimetría con un costo mucho menor.

Se eligen mediante `strategy` dentro de `control.inla`:

```
inla(..., control.inla = list(strategy = "laplace"), ...)
```

Los valores posibles son "gaussian", "simplified.laplace" y "laplace"; la aproximación simplificada es la predeterminada.

2.3.3. Exploración de $\tilde{\pi}(\theta \mid \mathbf{y})$

Para integrar la incertidumbre en (2.3a) no es necesaria una exploración exhaustiva, sino buenos puntos de evaluación. Primero se localiza la moda θ^* y se calcula la Hessiana negativa $\mathbf{H}$. Si $\mathbf{H}^{-1} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^T$, se estandariza el espacio mediante

$$\mathbf{z} = (\mathbf{V}\mathbf{\Lambda}^{1/2})^{-1}(\theta - \theta^*).$$

Con muy pocos hiperparámetros se construye una cuadrícula que cubra la mayor parte de la masa. Una cuadrícula relativamente gruesa basta para obtener marginales precisas, pero su costo crece exponencialmente: tres puntos por dimensión cuestan $O(3^m)$. En el extremo opuesto, el enfoque Bayes empírico usa solo la moda. Es muy rápido y suele dar resultados razonables cuando la variabilidad del campo latente no está dominada por la de los hiperparámetros, pero subestima la incertidumbre.

Una alternativa intermedia usa un diseño compuesto central (CCD). Guiado por la moda y la Hessiana, selecciona puntos que aproximan la función desconocida mediante una superficie de segundo orden. Requiere mucho menos cómputo que la cuadrícula y aún captura la variabilidad cuando la dimensión es demasiado grande.

Las estrategias "grid", "eb" y "ccd" se especifican con `int.strategy`:

```
inla(..., control.inla = list(int.strategy = "grid"), ...)
```

La opción automática predeterminada usa la cuadrícula cuando $m \leq 2$ y CCD cuando $m > 2$; Bayes empírico solo se utiliza si se solicita expresamente.

2.3.4. Aproximación de $\pi(\theta_j \mid \mathbf{y})$

Con dimensión pequeña podrían sumarse directamente los demás hiperparámetros, pero cada evaluación exige calcular (2.5) y el costo vuelve a crecer exponencialmente. Otra aproximación de Laplace condicional también resulta costosa. INLA aprovecha los puntos ya evaluados al explorar la posterior conjunta.

Una normal multivariante ajustada a la moda y curvatura no exige cómputo adicional, pero las marginales reales pueden ser asimétricas. Durante mucho tiempo INLA corrigió esta carencia mediante mezclas normales con escalas distintas por eje y dirección, seguidas por integración numérica. El procedimiento era preciso y rápido, pero la integración multidimensional podía volverse inestable con muchos hiperparámetros y generar picos artificiales.

Martins et al. (2013) propuso un algoritmo sin integración. Cada marginal estandarizada se aproxima directamente mediante dos mitades normales con escalas σ_{j+} y σ_{j-} distintas según el signo. Las escalas se estiman sin integración. Pierde algo de precisión respecto de una cuadrícula intensiva, pero entrega resultados sensatos con costo casi nulo y es el método predeterminado. Para refinar con la cuadrícula puede usarse:

```
result.refinado <- inla.hyperpar(result)
```

2.3.5. Ejemplo: datos simulados

Consideremos

$$y_i \mid \eta_i \sim \text{Poisson}(E_i \lambda_i), \quad \lambda_i = \exp(\eta_i),$$

donde E_i es una exposición y η sigue un AR(1) con correlación $\rho = 0.8$ y precisión de innovación $\tau = 10$. Simulamos:

```
set.seed(1)
n <- 50
rho <- 0.8
prec <- 10
E <- sample(c(5, 4, 10, 12), size = n, replace = TRUE)
eta <- arima.sim(list(order = c(1, 0, 0), ar = rho),
                  n = n, sd = sqrt(1/prec))
y <- rpois(n, E * exp(eta))
```

INLA reparametriza τ y ρ , asigna una previa log-gamma al primer parámetro transformado y una normal al segundo. El modelo se ajusta así:

```
datos <- list(y = y, x = 1:n, E = E)
formula <- y ~ f(x, model = "ar1")
result.sla <- inla(formula, family = "poisson", data = datos, E = E)
```

La fórmula define la dependencia de la respuesta mediante el componente AR(1) incluido con `f()`. Podemos comparar la aproximación simplificada predeterminada con una gaussiana de Bayes empírico:

```
result.gau <- inla(
  formula, family = "poisson", data = datos, E = E,
  control.inla = list(strategy = "gaussian", int.strategy = "eb")
)
```

y con la Laplace completa e integración precisa:

```
result.la <- inla(
  formula, family = "poisson", data = datos, E = E,
  control.inla = list(
    strategy = "laplace", int.strategy = "grid",
    dz = 0.1, diff.logdens = 20
  )
)
```

dz es el paso en la escala estandarizada y `diff.logdens` la diferencia de log-densidad que detiene la integración. En el ejemplo, la Laplace simplificada casi se superpone con la completa; integrar θ aumenta correctamente la incertidumbre y representa la asimetría, mientras que la gaussiana de Bayes empírico resulta más estrecha.

La desviación estándar marginal verdadera del AR(1) es

```
marg.prec <- prec * (1 - rho^2)
(marg.sd <- 1/sqrt(marg.prec))
```

```
[1] 0.5270463
```

Las posteriores de ρ y de la desviación estándar marginal se centran alrededor de sus valores verdaderos. Refinarlas mediante `inla.hyperpar(result.sla)` aumenta ligeramente la incertidumbre sin cambiar su forma general.

2.4. Problemas de INLA

2.4.1. Reproducibilidad

INLA es computacionalmente intensivo y procura aprovechar el equipo disponible. En su funcionamiento normal utiliza la interfaz paralela OpenMP. En teoría, varios núcleos podrían reducir el tiempo por un factor igual a su número; en la práctica la mejora es menor, aunque bienvenida. La consecuencia no deseada es que ejecuciones repetidas pueden producir pequeñas diferencias. Algunos cálculos son sensibles a perturbaciones en los valores iniciales, de modo que a veces la variación se amplifica.

No debería preocuparnos demasiado: suele ser mucho menor que la incertidumbre paramétrica y del modelo. Presentar muchas cifras significativas crea una falsa ilusión de precisión; rara vez una estimación es fiable más allá de la segunda o tercera cifra.

Esta variación difiere de la producida por MCMC. La variabilidad de simulación puede ser considerable y solo se reduce aumentando sustancialmente el tamaño de la simulación. La debida a OpenMP es mucho menor y no depende de la semilla aleatoria.

Cuando se necesita reproducibilidad bit a bit, puede usarse:

```
inla(..., num.threads = 1)
```

Esto fuerza un solo procesador. Ejecutar en otro equipo todavía puede producir diferencias. Las respuestas con uno o varios hilos son igualmente válidas; la única ventaja de un hilo es la reproducibilidad exacta. El libro usa el multiprocesamiento predeterminado y acepta el intercambio entre reproducibilidad bit a bit y velocidad.

2.4.2. Precisión de la aproximación

La integración numérica exige decidir dónde y cuántas veces evaluar una función; la optimización requiere valores iniciales, longitudes de paso, criterios de terminación y más. La precisión puede aumentarse ajustando esos parámetros a costa de tiempo. Los valores predeterminados pueden consultarse mediante:

```
inla.set.control.inla.default()
```

Si preocupa la precisión, puede usarse un cálculo más exigente y reproducible:

```
inla(
  ...,
  control.inla = list(
    strategy = "laplace", int.strategy = "grid",
    dz = 0.1, diff.logdens = 20
  ),
  num.threads = 1
)
```

Si el ajuste predeterminado es rápido, quizá pueda costearse este cálculo de lujo. En el resto del libro se mantienen los valores predeterminados salvo razones especiales.

2.4.3. Fallos

Cualquier procedimiento estadístico puede fallar. En métodos sencillos y establecidos conocemos mejor los modos y señales de fallo; en uno complejo como INLA hay más posibilidades y el diagnóstico es más difícil.

La forma más benigna es un error sintáctico. Como sucede a veces en R, el mensaje puede informar la dificultad inmediata y no su causa. Conviene buscar en internet palabras clave del mensaje, revisar la ayuda, las preguntas frecuentes y el archivo de la lista de correo de INLA.

Un nivel posterior aparece cuando las instrucciones son sintácticamente correctas, pero el programa termina con error. Añadir `verbose = TRUE` puede revelar el progreso y sugerir la causa. A veces no hay datos suficientes para estimar el modelo: es difícil estimar una varianza con una sola observación. Debe considerarse si los datos son suficientemente ricos para cada parámetro. Una previa más informativa puede permitir el ajuste; si los datos son insuficientes, hacen falta supuestos más fuertes.

Simplificar es una estrategia útil de depuración. Retire covariables o efectos aleatorios para identificar el componente problemático. Con datos enormes pruebe una submuestra. En general, comience con un conjunto o modelo pequeño para estimar cuánto tardará el problema completo y saber si necesita un equipo mayor.

El fallo más insidioso ocurre cuando INLA devuelve sin queja una respuesta incorrecta. Su metodología requiere que la condicional completa del campo latente sea «casi» gaussiana, condición que

suele lograrse con réplicas o con el préstamo de información y suavizado de las previas GMRF. Consideremos un ejemplo que no la cumple:

$$y_i \sim \text{Bernoulli}(p_i), \quad p_i = \frac{e^{\eta_i}}{1 + e^{\eta_i}}, \quad \eta_i \sim N(\mu, \sigma^2),$$

con $\mu = \sigma^2 = 1$. Simulamos:

```
set.seed(1)
n <- 100
u <- rnorm(n)
eta <- 1 + u
p <- exp(eta)/(1 + exp(eta))
y <- rbinom(n, size = 1, prob = p)
```

Cada observación binaria posee un efecto aleatorio gaussiano independiente. No hay suavizado, préstamo de información ni réplicas, por lo que la condicional de η_i no es casi gaussiana. INLA tiende a subestimar σ^2 :

```
datos <- data.frame(y = y, x = 1:n)
result <- inla(
  y ~ 1 + f(x, model = "iid"), data = datos,
  family = "binomial", Ntrials = 1
)
```

En el resultado original, la media posterior de σ es 0.012, muy inferior al valor verdadero 1, aunque la media μ se estima razonablemente cerca de 1. Las condiciones asintóticas que justifican Laplace no se cumplen: los efectos independientes hacen que el número efectivo de parámetros sea del orden del número de datos, y la verosimilitud aporta poca información. Para una sola observación $y_i = 1$, la log-verosimilitud aumenta con η_i y se vuelve muy plana en valores grandes, lo que dificulta la inferencia (Ferkingstad y Rue 2015).

En una simulación conocemos la verdad; en una aplicación real no. Podemos adoptar varias precauciones:

- Cuando sea posible, calcule la MLE mediante otro comando o paquete de R y compárela con la moda posterior de INLA. Con previas planas, MAP y MLE deberían ser semejantes. Con previas informativas es natural una diferencia. La comparación valida el cálculo; la inferencia seguirá siendo bayesiana.
- Reimplemente el modelo mediante BUGS, JAGS o STAN cuando los resultados sean suficientemente importantes. Exige más programación y tiempo, pero puede ser el precio de asegurar la validez. El consejo también funciona al revés: compruebe con INLA un análisis iniciado mediante MCMC.
- Simule datos del modelo con parámetros conocidos y compruebe si INLA los recupera. Quizá deba simplificar el modelo o reducir los datos para repetir el experimento. La simulación aumenta la confianza, aunque no es infalible y conserva variabilidad muestral.

- Examine exhaustivamente los diagnósticos. Los datos pueden proceder de un modelo distinto al ajustado; entonces INLA no «falla», pero las conclusiones serán engañosas. Los diagnósticos bayesianos están menos desarrollados que sus equivalentes frecuentistas, pero deben utilizarse todos los medios disponibles.

Este apartado no pretende desalentar el uso de INLA. Las mismas precauciones se aplican a cualquier procedimiento estadístico complejo: son el precio que debe pagarse.

2.5. Extensiones

2.5.1. Aproximación de la verosimilitud marginal

La verosimilitud marginal $p(\mathbf{y})$ es útil para comparar modelos. Los factores de Bayes son cocientes de verosimilitudes marginales, y el DIC también está relacionado con ella. A partir de (2.4), una aproximación intuitiva es

$$\tilde{p}(\mathbf{y}) = \int \frac{\pi(\eta, \theta, \mathbf{y})}{\tilde{\pi}_G(\eta \mid \theta, \mathbf{y})} \Big|_{\eta=\eta^*(\theta)} d\theta.$$

Es la constante normalizadora de $\tilde{\pi}(\theta \mid \mathbf{y})$ y admite desviaciones de la gaussianidad al tratar esta densidad de manera no paramétrica. Puede fallar si la posterior de los hiperparámetros es multimodal; el problema afecta al enfoque INLA en general. Por fortuna, los LGM casi siempre generan posteriores unimodales.

2.5.2. Selección de modelos

INLA ofrece DIC y WAIC. Para DIC se necesita la esperanza posterior de la devianza y su evaluación en una ubicación posterior. INLA evalúa en la media posterior de η y la moda posterior de θ , no en la media de todos los parámetros, porque las marginales de los hiperparámetros pueden ser muy sesgadas y su media representar mal la ubicación. WAIC se calcula de manera semejante.

```
result <- inla(  
  ...,  
  control.compute = list(dic = TRUE, waic = TRUE)  
)
```

Los resultados quedan disponibles en `result$dic` y `result$waic`.

2.5.3. Comprobación del modelo

INLA proporciona dos medidas predictivas de dejar uno fuera: CPO y PIT. Ambas se basan en $p(y_i | \mathbf{y}_{-i})$. En vez de ajustar n veces, se aprovechan las relaciones

$$\pi(\eta_i | \mathbf{y}_{-i}, \theta) \propto \frac{\pi(\eta_i | \mathbf{y}, \theta)}{\pi(y_i | \eta_i, \theta)},$$

$$\pi(\theta | \mathbf{y}_{-i}) \propto \frac{\pi(\theta | \mathbf{y})}{p(y_i | \mathbf{y}_{-i}, \theta)},$$

y solo se requiere una integral unidimensional para la predictiva. Se activa mediante:

```
result <- inla(..., control.compute = list(cpo = TRUE))
```

CPO y PIT se encuentran en `result$cpo$cpo` y `result$cpo$pit`. Para mejorar la cuadrícula puede usarse `int.strategy = "grid"`; cuando importan las colas conviene `strategy = "laplace"` y aumentar `npoints`, por ejemplo a 21.

El objeto `result$cpo$failure` señala observaciones donde se incumplieron supuestos internos. Valores mayores que cero indican un problema; cuanto más cerca de uno, más grave. `inla.cpo(result)` vuelve a calcular eficientemente las medidas problemáticas, retirando la observación, ajustando y prediciéndola.

Conviene verificar siempre las CPO o PIT excepcionalmente pequeñas, aunque no hayan activado una alarma. La validación depende de las colas y estas son difíciles de aproximar. Antes de declarar un caso atípico, fuerce su reevaluación mediante `inla.cpo()`.

2.5.4. Combinaciones lineales del campo latente

Puede interesarnos no solo cada marginal, sino combinaciones lineales $\mathbf{v} = \mathbf{A}\eta$, donde $\mathbf{A}$ es de $k \times n$. Las funciones `inla.make.lincomb()` e `inla.make.lincombs()` definen una o varias combinaciones, que se pasan al argumento `lincomb` de `inla()`.

INLA ofrece dos enfoques. El primero amplía el campo a $(\eta, \mathbf{v})$ y ajusta el modelo con las aproximaciones ya descritas. Proporciona marginales de cada combinación, pero muchas combinaciones densifican la precisión y ralentizan el cálculo:

```
inla(..., control.inla = list(lincomb.derived.only = FALSE))
```

El segundo, predeterminado, realiza un posprocesamiento. Condicionado a hiperparámetros y datos, aproxima $\mathbf{v}$ por una gaussiana con media $\mathbf{A}\mu$ y covarianza $\mathbf{A}\mathbf{Q}^{-1}\mathbf{A}^T$, y después integra la incertidumbre en θ . No amplía el campo y es mucho más rápido, aunque el primer enfoque puede ser más preciso.

Con el método rápido puede calcularse también la matriz de correlaciones posteriores entre combinaciones:

```
inla(  
  ...,  
  control.inla = list(lincomb.derived.correlation.matrix = TRUE)  
)
```

La matriz puede usarse, por ejemplo, para construir una cópula gaussiana que aproxime la densidad conjunta de componentes del campo latente.

3 Regresión lineal bayesiana

La regresión lineal es uno de los métodos estadísticos más habituales para modelar la relación entre una variable dependiente escalar —o respuesta— y una o más variables explicativas. Estudia relaciones lineales y aditivas entre variables. Fue el primer tipo de regresión investigado rigurosamente y ha sido objeto de innumerables libros (Chatterjee y Hadi 2015). Aunque pueda parecer demasiado sencilla frente a técnicas más modernas que aparecerán después, sigue siendo una de las herramientas más útiles y potentes en aplicaciones prácticas. Este capítulo sirve como punto de partida para modelos más complejos. Comprender profundamente la regresión lineal estándar es importante, pues muchas técnicas sofisticadas son generalizaciones o extensiones suyas.

3.1. Introducción

Sean

$$\{x_{i1}, \dots, x_{ip}, y_i\}, \quad i = 1, \dots, n,$$

n unidades observadas, cada una con un vector de p predictores y una respuesta. El modelo lineal múltiple es

$$y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} + \varepsilon_i. \quad (3.1)$$

La relación se representa mediante el predictor $\mu = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$ y un término de perturbación o error ε . Los parámetros desconocidos se estiman con los datos. Cuando $p = 1$ obtenemos regresión lineal simple. La linealidad se refiere a los parámetros, no necesariamente a los predictores: $y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \beta_3 x_i^3 + \varepsilon_i$ sigue siendo un modelo lineal.

En forma matricial,

$$\mathbf{y} = \mathbf{X}\beta + \varepsilon, \quad (3.2)$$

donde $\mathbf{y}$ es de $n \times 1$, $\mathbf{X}$ contiene una columna de unos y los p predictores, y $\beta = (\beta_0, \dots, \beta_p)^T$. Comenzamos suponiendo errores independientes normales de media cero y varianza constante:

$$\varepsilon \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_n).$$

En estadística frecuentista se estiman los parámetros por máxima verosimilitud o mínimos cuadrados. La verosimilitud es

$$L(\beta, \sigma^2 \mid \mathbf{X}, \mathbf{y}) = (2\pi\sigma^2)^{-n/2} \exp \left[-\frac{1}{2\sigma^2} (\mathbf{y} - \mathbf{X}\beta)^T (\mathbf{y} - \mathbf{X}\beta) \right].$$

Si $\mathbf{X}^T \mathbf{X}$ tiene rango completo, las ecuaciones de puntuación producen

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y},$$

$$\hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n} (\mathbf{y} - \mathbf{X}\hat{\beta})^T (\mathbf{y} - \mathbf{X}\hat{\beta}).$$

$\hat{\beta}$ es insesgado y coincide con mínimos cuadrados, pero $\hat{\sigma}_{\text{MLE}}^2$ no lo es. El estimador insesgado habitual sustituye n por $n - p - 1$.

3.2. Inferencia bayesiana para la regresión lineal

En análisis bayesiano la inversa de la varianza, $\tau = \sigma^{-2}$, desempeña un papel importante y se denomina precisión. El modelo implica

$$\mathbf{y} \mid \beta, \tau \sim N(\mathbf{X}\beta, \tau^{-1} \mathbf{I}).$$

Suponiendo independencia previa entre β y τ ,

$$\pi(\beta, \tau \mid \mathbf{X}, \mathbf{y}) \propto L(\beta, \tau \mid \mathbf{X}, \mathbf{y}) \pi(\beta) \pi(\tau).$$

Solo ciertas previas restringidas producen posteriores cerradas. Si existe información previa debe incorporarse; si no existe, queríamos minimizar su influencia. Una previa no informativa como $\pi(\beta) \propto 1$ resulta atractiva, pero no es invariante ante transformaciones. El apéndice B de la obra original desarrolla esta cuestión; véase también Gelman et al. (2014).

INLA exige un modelo gaussiano latente y, por tanto, una previa gaussiana para β . Para τ suele elegirse una distribución difusa:

$$\beta \sim N_{p+1}(\mathbf{c}_0, \mathbf{V}_0), \quad \tau \sim \text{Gamma}(a_0, b_0).$$

Frecuentemente $\mathbf{V}_0$ es diagonal, equivalente a previas normales independientes para los coeficientes. Usamos la parametrización gamma con media a_0/b_0 y varianza a_0/b_0^2 . Esta previa es condicionalmente conjugada para la precisión.

Aunque la posterior conjunta no resulte manejable, un Gibbs por bloques alternaría entre

$$\pi(\beta \mid \mathbf{X}, \mathbf{y}, \tau) \quad \text{y} \quad \pi(\tau \mid \mathbf{X}, \mathbf{y}, \beta).$$

INLA evita la simulación y aproxima las marginales con gran precisión y rapidez. La marginal de τ se obtiene mediante

$$\tilde{\pi}(\tau \mid \mathbf{X}, \mathbf{y}) = \frac{\pi(\beta, \tau, \mathbf{X}, \mathbf{y})}{\tilde{\pi}_G(\beta \mid \tau, \mathbf{X}, \mathbf{y})} \Big|_{\beta=\beta^*(\tau)},$$

exacta cuando la condicional de β es gaussiana. Después,

$$\tilde{\pi}(\beta_j \mid \mathbf{X}, \mathbf{y}) \approx \sum_k \tilde{\pi}(\beta_j \mid \tau_k, \mathbf{X}, \mathbf{y}) \tilde{\pi}(\tau_k \mid \mathbf{X}, \mathbf{y}) \Delta_k.$$

Estas marginales permiten calcular medias, varianzas y cuantiles. Como subproductos, INLA obtiene DIC, verosimilitudes marginales y otras cantidades para comparar y validar modelos.

3.2.1. Ejemplo: contaminación atmosférica

Los datos `usair`, analizados por Everitt y Hothorn (2006), investigan determinantes de la contaminación en 41 ciudades estadounidenses. `S02` es el contenido de dióxido de azufre en microgramos por metro cúbico. Los posibles predictores son: temperatura anual negativa (`negtemp`), número de empresas manufactureras con al menos 20 trabajadores (`manuf`), población en miles (`pop`), velocidad anual del viento (`wind`), precipitación anual (`precip`) y días con precipitación (`days`). Los dos primeros predictores sustantivos se relacionan con la ecología humana y los cuatro restantes con el clima. `negtemp` usa el signo negativo para que valores altos de todas las variables representen un ambiente menos atractivo.

Antes de ajustar conviene explorar los datos. El siguiente código produce diagramas de dispersión, correlaciones y densidades marginales:

```
library(ggplot2)
library(GGally)
data(usair, package = "brinla")
ggpairs(
  usair[, -1],
  lower = list(continuous = "cor"),
  upper = list(continuous = "points", combo = "dot")
) + theme(axis.text = element_text(size = 6))
```

`manuf` y `pop` tienen correlación 0.955. Esta multicolinealidad vuelve los coeficientes muy sensibles a pequeñas modificaciones de datos o variables y genera grandes errores de muestreo. Por ahora conservaremos solo `manuf`; en una sección posterior utilizaremos regresión ridge.

Como referencia frecuentista ajustamos:

```
usair.formula1 <- S02 ~ negtemp + manuf + wind + precip + days
usair.lm1 <- lm(usair.formula1, data = usair)
round(coef(summary(usair.lm1)), 4)
round(summary(usair.lm1)$sigma, 4)
```

3 Regresión lineal bayesiana

Las estimaciones del original son 135.7714 para el intercepto, 1.7714 para `negtemp`, 0.0256 para `manuf`, -3.7379 para `wind`, 0.6259 para `precip` y -0.0571 para `days`; el error estándar residual es 15.79. `negtemp` y `manuf` son significativos, los otros tres no.

Las previas predeterminadas de INLA son normales muy difusas para los coeficientes y log-gamma para la precisión:

$$\beta_j \sim N(0, 10^6), \quad \log \tau \sim \log \text{Gamma}(1, 10^{-5}).$$

```
library(INLA)
usair.inla1 <- inla(
  usair.formula1, data = usair,
  control.compute = list(dic = TRUE, cpo = TRUE)
)
round(usair.inla1$summary.fixed, 4)
round(usair.inla1$summary.hyperpar, 4)
```

Las medias posteriores prácticamente reproducen las MLE: 135.4892, 1.7690, 0.0256, -3.7229, 0.6249 y -0.0567. El intervalo de credibilidad del 95 % de `negtemp` es (0.5111, 3.0247), por lo que con probabilidad muy alta se asocia positivamente con `S02`. A diferencia de aproximaciones frecuentistas asintóticas, las estimaciones bayesianas por intervalo suelen ser apropiadas en muestras pequeñas y se interpretan directamente como intervalos que contienen el parámetro con probabilidad 0.95.

`summary(usair.inla1)` presenta efectos fijos, hiperparámetros, log-verosimilitud marginal y DIC. Las marginales completas están en `marginals.fixed` y `marginals.hyperpar`. INLA incluye funciones para densidad, distribución, cuantiles, moda y esperanza: `inla.dmarginal()`, `inla.pmarginal()`, `inla.qmarginal()`, `inla.mmarginal()` e `inla.emarginal()`. `inla.rmarginal()` genera valores aleatorios y `inla.tmarginal()` transforma una marginal.

Por ejemplo, la esperanza posterior de σ es:

```
inla.emarginal(
  fun = function(x) 1/sqrt(x),
  marg = usair.inla1$marginals.hyperpar[[1]]
)
```

El resultado, 15.66331, es muy cercano a 15.79. El paquete `brinla` ofrece resúmenes directamente en la escala de desviación estándar:

```
library(brinla)
round(bri.hyperpar.summary(usair.inla1), 4)
bri.hyperpar.plot(usair.inla1)
```

La posterior de σ tiene media 15.6617, intervalo (12.5321, 19.7590) y ligera asimetría positiva.

Las previas pueden modificarse. Supongamos $\beta_0 \sim N(100, 100)$, $\beta_{\text{negtemp}} \sim N(2, 1)$ y $\beta_{\text{wind}} \sim N(-3, 1)$, y una previa normal para $\log \tau$:

```
usair.inla2 <- inla(
  usair.formula1, data = usair,
  control.compute = list(dic = TRUE, cpo = TRUE),
  control.fixed = list(
    mean.intercept = 100, prec.intercept = 1e-2,
    mean = list(negtemp = 2, wind = -3, default = 0),
    prec = 1
  ),
  control.family = list(
    hyper = list(prec = list(prior = "gaussian", param = c(0, 1)))
  )
)
```

Si cada coeficiente requiere distinta precisión, `prec` también debe ser una lista. Debe actuarse con cuidado y comparar las elecciones mediante los métodos de selección y comprobación siguientes.

3.3. Predicción

Para un nuevo vector $\tilde{\mathbf{x}}$ queremos predecir $\tilde{y}$. Sea $\theta = (\beta, \tau)$. La predictiva posterior es

$$p(\tilde{y} | \mathbf{y}) = \int p(\tilde{y} | \theta) p(\theta | \mathbf{y}) d\theta.$$

En la mayoría de los modelos no tiene forma analítica y un análisis MCMC usa simulación predictiva. Consideremos tres nuevos casos:

```
new.data <- data.frame(
  negtemp = c(-50, -60, -40),
  manuf = c(150, 100, 400),
  pop = c(200, 100, 300),
  wind = c(6, 7, 8),
  precip = c(10, 30, 20),
  days = c(20, 100, 40)
)
predict(usair.lm1, new.data, se.fit = TRUE)
```

Las predicciones frecuentistas son 33.727, 18.950 y 55.477, con errores estándar 14.937, 5.329 y 17.639.

INLA no necesita una función `predict`: predecir equivale a ajustar el modelo con respuestas faltantes. Se añaden filas con `S02 = NA` y se indica el enlace para ellas:

```
usair.combined <- rbind(
  usair,
  data.frame(SO2 = c(NA, NA, NA), new.data)
)
usair.link <- c(rep(NA, nrow(usair)), rep(1, nrow(new.data)))
usair.inla1.pred <- inla(
  usair.formula1, data = usair.combined,
  control.predictor = list(link = usair.link)
)
usair.inla1.pred$summary.fitted.values[
  (nrow(usair) + 1):nrow(usair.combined),
]
```

Las medias posteriores son 33.653, 18.927 y 55.404, con desviaciones 14.938, 5.330 y 17.644, en estrecha concordancia con mínimos cuadrados.

3.4. Selección y comprobación del modelo

3.4.1. Selección mediante DIC

A menudo buscamos un modelo reducido con el mejor subconjunto de variables. El enfoque frecuentista suele usar AIC. En el ejemplo:

```
library(MASS)
usair.step <- stepAIC(usair.lm1, trace = FALSE)
usair.step$anova
```

El procedimiento elimina `days`, dejando `negtemp`, `manuf`, `wind` y `precip`:

```
usair.formula2 <- SO2 ~ negtemp + manuf + wind + precip
usair.lm2 <- lm(usair.formula2, data = usair)
```

DIC generaliza AIC al contexto bayesiano sumando una medida de bondad de ajuste y otra de complejidad. Menor DIC indica mejor compromiso. INLA no ofrece selección escalonada automática por DIC, pero con cinco predictores puede realizarse eliminación manual:

```
usair.inla3 <- inla(
  usair.formula2, data = usair,
  control.compute = list(dic = TRUE, cpo = TRUE)
)
c(usair.inla1$dic$dic, usair.inla3$dic$dic)
```

Los DIC son 350.6494 y 348.5703, por lo que se prefiere el modelo reducido, coincidiendo con AIC. Las medias posteriores son 122.9366 para el intercepto, 1.6102 para `negtemp`, 0.0255 para `manuf`,

-3.6168 para `wind` y 0.5239 para `precip`. Los intervalos de `negtemp`, `manuf` y `precip` no contienen cero. Por ejemplo, manteniendo las demás covariables, una pulgada adicional de precipitación anual se asocia con un aumento esperado de 0.5239 microgramos de SO₂ por metro cúbico; su intervalo de credibilidad es (0.0706, 0.9766).

3.4.2. Comprobación predictiva posterior

La evaluación del ajuste es crítica. Una comprobación predictiva posterior usa una réplica y_i^* con densidad

$$p(y_i^* | \mathbf{y}) = \int p(y_i^* | \theta) p(\theta | \mathbf{y}) d\theta$$

y el valor predictivo posterior $P(y_i^* < y_i | \mathbf{y})$. Valores muy próximos a cero o uno pueden señalar observaciones incompatibles con el modelo (Meng 1994).

```
usair.inla3.pred <- inla(
  usair.formula2, data = usair,
  control.predictor = list(link = 1, compute = TRUE)
)
post.predicted.pval <- numeric(nrow(usair))
for (i in seq_len(nrow(usair))) {
  post.predicted.pval[i] <- inla.pmarginal(
    q = usair$SO2[i],
    marginal = usair.inla3.pred$marginals.fitted.values[[i]]
  )
}
hist(post.predicted.pval, breaks = 10,
      xlab = "Valor p predictivo posterior", main = "")
```

Muchos valores quedan cerca de los extremos. Sin embargo, aun bajo el modelo verdadero los valores predictivos posteriores no tienen por qué ser uniformes (Hjort, Dahl, y Steinbakk 2006; Marshall y Spiegelhalter 2007). `SO2` está sesgado a la derecha y `manuf` posee gran varianza y valores atípicos; por ello continuamos con otros diagnósticos.

3.4.3. Comprobación por validación cruzada

Las medidas de dejar uno fuera son

$$\text{CPO}_i = p(y_i | \mathbf{y}_{-i}), \quad \text{PIT}_i = P(Y_i < y_i | \mathbf{y}_{-i}).$$

PIT difiere del valor predictivo anterior porque excluye la observación i . INLA las calcula sin reajustar n veces al usar `control.compute = list(cpo = TRUE)`. Se encuentran en `result$cpo$cpo` y `result$cpo$pit`. Problemas numéricos potenciales aparecen en `result$cpo$failure`; aquí:

```
sum(usair.inla3$cpo$failure)
```

devuelve cero. Si el modelo está bien ajustado, PIT debe aproximarse a una uniforme (Diebold, Gunther, y Tay 1998; Gneiting, Balabdaoui, y Raftery 2007):

```
hist(usair.inla3$cpo$pit, breaks = 10, xlab = "PIT", main = "")
qqplot(
  qunif(ppoints(length(usair.inla3$cpo$pit))),
  usair.inla3$cpo$pit,
  xlab = "Cuantiles teóricos", ylab = "Cuantiles muestrales"
)
qqline(usair.inla3$cpo$pit,
  distribution = function(p) qunif(p), prob = c(.1, .9))
```

El histograma y el gráfico Q–Q son razonablemente uniformes y mucho mejores que el histograma predictivo posterior.

El producto de CPO actúa como «pseudo-verosimilitud marginal». Su logaritmo, LPML (Geisser y Eddy 1979), es

$$\text{LPML} = \sum_{i=1}^n \log \text{CPO}_i.$$

Es una alternativa estable a DIC; a diferencia de este, valores mayores son mejores:

```
LPML1 <- sum(log(usair.inla1$cpo$cpo))
LPML3 <- sum(log(usair.inla3$cpo$cpo))
c(LPML1, LPML3)
```

Los valores son -176.9495 y -175.6892, favoreciendo nuevamente al modelo reducido. Un diagrama punto a punto de CPO también coloca la mayoría de los casos por encima de la línea de igualdad cuando el modelo reducido mejora la predicción.

3.4.4. Análisis bayesiano de residuos

Para $y_i = \mathbf{x}_i^T \beta + \varepsilon_i$, los residuos bayesianos o realizados son

$$r_i = \varepsilon_i(\beta) = y_i - \mathbf{x}_i^T \beta. \quad (3.9)$$

A diferencia del residuo clásico, basado en una estimación puntual, poseen una distribución posterior inducida por las posteriores de β y σ^2 . Podemos muestrear parámetros, producir residuos y examinar sus medias o medianas. Graficarlos por índice, contra valores ajustados o predictores permite detectar atípicos, no normalidad o heterocedasticidad. La suma de cuadrados o valores absolutos ofrece una medida global (Chaloner y Brant 1988).

`brinla` facilita el análisis:

```
bri.lmresid.plot(usair.inla2)
bri.lmresid.plot(
  usair.inla2, usair$negtemp,
  xlab = "negtemp", smooth = TRUE
)
```

Los residuos fluctúan alrededor de cero. La observación 31, Providence, tiene un residuo 59.6927 y parece atípica: su S02 de 94 supera ampliamente al de ciudades comparables. La curva suave con intervalo de credibilidad, estimada mediante caminata aleatoria de orden 2, no presenta tendencia especial, respaldando los supuestos.

3.5. Regresión robusta

La inferencia normal es vulnerable a valores atípicos. Los errores t proporcionan una extensión robusta para colas más largas o puntos extremos (Lange, Little, y Taylor 1989). Si $Y \sim t(\mu, \sigma, \nu)$,

$$f(y \mid \mu, \sigma, \nu) = \frac{\Gamma((\nu + 1)/2)}{\sigma \sqrt{\nu\pi} \Gamma(\nu/2)} \left[1 + \frac{(y - \mu)^2}{\nu\sigma^2} \right]^{-(\nu+1)/2}.$$

Puede verse como mezcla: si $\eta_i \sim \text{Gamma}(\nu/2, \nu/2)$ y $y_i \mid \eta_i \sim N(\mu_i, \sigma^2/\eta_i)$, entonces $y_i \sim t(\mu_i, \sigma, \nu)$. El modelo de regresión usa $\mu_i = \beta_0 + \dots + \beta_p x_{ip}$ e INLA representa la precisión $\tau = \sigma^{-2}$.

Para reducir la influencia de Providence:

```
usair.inla4 <- inla(
  usair.formula2, family = "T", data = usair,
  control.compute = list(dic = TRUE, cpo = TRUE)
)
round(usair.inla4$summary.fixed, 4)
round(usair.inla4$summary.hyperpar, 4)
```

Las medias posteriores de intercepto, `negtemp`, `manuf`, `wind` y `precip` son 119.2344, 1.4588, 0.0266, -3.9300 y 0.4356. Los grados de libertad tienen media 10.9839. Frente al modelo normal, intercepto, `negtemp` y `precip` disminuyen y sus desviaciones aumentan, consecuencia de las colas pesadas: los extremos ejercen menor influencia.

3.6. Análisis de varianza

ANOVA reúne modelos para determinar diferencias o semejanzas entre grupos y se usa ampliamente en experimentos (Montgomery 2013). Es un caso particular de regresión con variables categóricas. Para un factor A con niveles $i = 1, \dots, a$:

$$y_{ij} = \mu_i + \varepsilon_{ij} = \mu_0 + \alpha_i + \varepsilon_{ij}, \quad \varepsilon_{ij} \sim N(0, \sigma^2).$$

Para identificar los $a + 1$ parámetros se impone una restricción. La parametrización de esquina, usada por INLA, fija $\alpha_1 = 0$; entonces μ_0 es la media del primer nivel.

En un factorial de dos factores,

$$y_{ijk} = \mu_0 + \alpha_i + \beta_j + \gamma_{ij} + \varepsilon_{ijk}, \quad (3.12)$$

con efectos principales e interacción. Como hay más parámetros que medias de celda, se fijan a cero los efectos del primer nivel y sus interacciones de referencia.

En la literatura frecuentista se distingue entre efectos fijos y aleatorios. En Bayes todos los parámetros son variables aleatorias y la diferencia se refleja en las previas. Un efecto «fijo» puede recibir una normal difusa de precisión conocida; uno «aleatorio», una normal cuya varianza recibe hiperprevia. Aquí tratamos efectos fijos; el capítulo 5 estudia los aleatorios.

Los datos `painrelief` proceden de un experimento sobre codeína y acupuntura para aliviar dolor dental posoperatorio en hombres. Se usó un diseño en bloques aleatorizados con dos factores binarios: cápsula de codeína o azúcar y puntos de acupuntura activos o inactivos. Treinta y dos sujetos se asignaron a ocho bloques de cuatro según su tolerancia al dolor. Una puntuación mayor indica más alivio.

```
data(painrelief, package = "brinla")
painrelief$PainLevel <- as.factor(painrelief$PainLevel)
painrelief$Codeine <- as.factor(painrelief$Codeine)
painrelief$Acupuncture <- as.factor(painrelief$Acupuncture)
painrelief.inla <- inla(
  Relief ~ PainLevel + Codeine * Acupuncture,
  data = painrelief
)
round(painrelief.inla$summary.fixed, 4)
```

Los efectos principales de codeína y acupuntura son claramente distintos de cero: medias 0.4625 y 0.5750, con intervalos completamente positivos. La interacción tiene media 0.1500 e intervalo $(-0.0186, 0.3183)$, por lo que no es significativa al 95 %. Los niveles de dolor más altos reciben en general mayores puntuaciones de alivio, salvo el nivel 4. `PainLevel` es un factor de confusión importante que debe incluirse.

3.7. Regresión ridge para multicolinealidad

La multicolinealidad hace imprecisos los coeficientes parciales, infla sus errores estándar y dificulta evaluar la importancia relativa de los predictores. La regresión por componentes principales sustituye predictores correlacionados por componentes no correlacionados (Jolliffe 1982). Ridge ofrece otra solución penalizando el tamaño de los coeficientes (Hoerl y Kennard 1970):

$$\min_{\beta} \left\{ (\mathbf{y} - \mathbf{X}\beta)^T (\mathbf{y} - \mathbf{X}\beta) + \lambda \beta^T \beta \right\},$$

con $\lambda > 0$. El estimador es

$$\hat{\beta}_{\text{ridge}} = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}.$$

Introduce sesgo creciente con λ , pero reduce varianzas. Coincide con la media posterior si, conocida σ^2 , asignamos independientemente $\beta_j \sim N(0, \sigma^2/\lambda)$. Una λ grande concentra la previa cerca de cero. Como la penalización opera sobre la norma, los predictores deben estandarizarse.

El ejemplo `frencheconomy` analiza importaciones (`IMPORT`), producción doméstica (`DOPROD`), formación de existencias (`STOCK`) y consumo (`CONSUM`) en miles de millones de francos entre 1949 y 1966. `DOPROD` y `CONSUM` tienen correlación 0.9989.

```
data(frencheconomy, package = "brinla")
round(cor(frencheconomy[, -1]), 4)
fe.scaled <- cbind(
  frencheconomy[, 1:2],
  scale(frencheconomy[, c(-1, -2)])
)
```

INLA implementa ridge compartiendo un efecto aleatorio mediante `copy`:

```
n <- nrow(fe.scaled)
fe.scaled$beta1 <- rep(1, n)
fe.scaled$beta2 <- rep(2, n)
fe.scaled$beta3 <- rep(3, n)
param.beta <- list(prec = list(param = c(1e-3, 1e-3)))

formula.ridge <- IMPORT ~
  f(beta1, DOPROD, model = "iid", values = 1:3,
    hyper = param.beta) +
  f(beta2, STOCK, copy = "beta1", fixed = TRUE) +
  f(beta3, CONSUM, copy = "beta1", fixed = TRUE)

frencheconomy.ridge <- inla(formula.ridge, data = fe.scaled)
```

Las medias ridge para `DOPROD`, `STOCK` y `CONSUM` son 5.1608, 0.7205 y 6.9279. En la regresión bayesiana estándar son 2.9951, 0.7197 y 9.1424, con desviaciones cercanas a 10.88 para los dos predictores colineales, frente a 5.25 con ridge. Como ambos se correlacionan fuertemente con `IMPORT`, el reparto ridge —aumento de `DOPROD` y reducción de `CONSUM`— resulta más plausible y preciso.

La comparación frecuentista usa:

```
library(MASS)
ridge2 <- lm.ridge(
  IMPORT ~ DOPROD + STOCK + CONSUM,
  data = fe.scaled, lambda = seq(0, 1, length = 100)
)
```

```
ridge2.final <- lm.ridge(
  IMPORT ~ DOPROD + STOCK + CONSUM,
  data = fe.scaled, lambda = ridge2$kHKB
)
ridge2.final
```

El criterio de Hoerl–Kennard–Baldwin produce 4.9560, 0.7176 y 7.1669, muy próximo a INLA.

3.8. Regresión con errores autorregresivos

En el modelo estándar $\varepsilon \sim N(\mathbf{0}, \sigma^2 \mathbf{I})$. En muchas aplicaciones las varianzas no son constantes o los errores están correlacionados. La generalización es

$$\varepsilon \sim N(\mathbf{0}, \Sigma),$$

con Σ simétrica definida positiva. Si fuera conocida, mínimos cuadrados generalizados minimizaría

$$(\mathbf{y} - \mathbf{X}\beta)^T \Sigma^{-1} (\mathbf{y} - \mathbf{X}\beta),$$

y daría

$$\hat{\beta} = (\mathbf{X}^T \Sigma^{-1} \mathbf{X})^{-1} \mathbf{X}^T \Sigma^{-1} \mathbf{y}.$$

Pero Σ posee $n(n+1)/2$ elementos distintos y debe estructurarse con pocos parámetros.

En series temporales, observaciones adyacentes tienden a parecerse. Ignorar la autocorrelación suele subestimar σ^2 y los errores estándar, invalidando la inferencia. Consideremos

$$y_t = \beta_0 + \beta_1 x_{t1} + \cdots + \beta_p x_{tp} + \varepsilon_t,$$

con errores estacionarios y $\text{Cor}(\varepsilon_t, \varepsilon_{t-s}) = \rho_s$. El AR(1) más común es

$$\varepsilon_t = \rho \varepsilon_{t-1} + \eta_t, \quad \eta_t \stackrel{\text{iid}}{\sim} N(0, \sigma_\eta^2).$$

Entonces $\sigma^2 = \sigma_\eta^2 / (1 - \rho^2)$ y $\rho_s = \rho^s$, que decae exponencialmente. AR(2) añade $\rho_2 \varepsilon_{t-2}$; también existen procesos MA y ARMA (Shumway y Stoffer 2011).

La función de autocorrelación muestral de residuos es $\hat{\rho}(s) = \hat{\gamma}(s) / \hat{\gamma}(0)$. La autocorrelación parcial en retardo s es la correlación directa una vez retirada la dependencia lineal de retardos intermedios. Un AR(s) tiene ACF decreciente exponencialmente y PACF con s picos no nulos. Estas gráficas ayudan a identificar la estructura. El estadístico Durbin–Watson es una prueba frecuentista tradicional; desde una perspectiva bayesiana se ha sugerido usarlo, junto con las gráficas, como comprobación rápida.

3.8.1. Ejemplo: desempleo en Nueva Zelanda

Los datos `nzunemploy` contienen tasas trimestrales de desempleo juvenil (15–19 años) y adulto entre marzo de 1986 y junio de 2011. En junio de 2008 se abolió el salario mínimo diferencial juvenil. Queremos estudiar la relación antes y después de la reforma.

```
data(nzunemploy, package = "brinla")
nzunemploy$time <- seq_len(nrow(nzunemploy))
nzunemploy$centeredadult <- with(nzunemploy, adult - mean(adult))
```

Las dos series fluctúan de modo considerable pero gradual y siguen patrones semejantes. Centrar la tasa adulta facilita interpretar coeficientes. Un primer ajuste independiente es:

```
formula1 <- youth ~ centeredadult * policy
nzunemploy.inla1 <- inla(formula1, data = nzunemploy)
round(nzunemploy.inla1$summary.fixed, 4)
```

Las medias son 16.2823 para el intercepto, 1.5333 para la tasa adulta centrada, 9.4417 para la política igualitaria y 2.8533 para su interacción; todos los intervalos son positivos. Sin embargo, los residuos bayesianos muestran autocorrelación:

```
nzunemploy.res1 <- bri.lmresid.plot(nzunemploy.inla1, type = "o")
acf(nzunemploy.res1$resid, main = "")
acf(nzunemploy.res1$resid, type = "partial", main = "")
```

La ACF decae exponencialmente y la PACF muestra un pico alto en el primer retardo, sugiriendo AR(1). Lo incorporamos como campo latente y fijamos casi en infinito la precisión residual independiente, pues la incertidumbre ya está representada por el AR(1):

```
formula2 <- youth ~ centeredadult * policy + f(time, model = "ar1")
nzunemploy.inla2 <- inla(
  formula2, data = nzunemploy,
  control.family = list(
    hyper = list(prec = list(initial = 15, fixed = TRUE))
  )
)
round(nzunemploy.inla2$summary.fixed, 4)
round(nzunemploy.inla2$summary.hyperpar, 4)
```

Los coeficientes apenas cambian: 16.3466, 1.5196, 8.9611 y 2.5083. Sus desviaciones, en cambio, aumentan notablemente, confirmando que ignorar autocorrelación subestimaba la incertidumbre. La correlación AR(1) tiene media 0.4953 e intervalo (0.3094, 0.6932), evidencia de autocorrelación moderada.

Como comprobación frecuentista:

3 Regresión lineal bayesiana

```
library(nlme)
nzunemploy.gls <- gls(
  youth ~ centeredadult * policy,
  correlation = corAR1(form = ~ 1),
  data = nzunemploy
)
summary(nzunemploy.gls)
```

GLS estima $\rho = 0.5012$ y coeficientes 16.3286, 1.5222, 9.0826 y 2.5450, muy próximos a INLA.

4 Modelos lineales generalizados

Los modelos lineales generalizados (GLM) proporcionan una familia unificadora de modelos lineales ampliamente utilizada en regresión práctica. Generalizan la regresión ordinaria al relacionar la respuesta con el predictor mediante una función de enlace y permitir que la varianza de cada medición dependa de su valor esperado. Así pueden describir respuestas con distribuciones distintas de la normal y evitan buscar transformaciones que intenten satisfacer simultáneamente normalidad, linealidad y homogeneidad de varianza. Entre los GLM más comunes están la regresión logística para datos binarios y las regresiones Poisson y binomial negativa para conteos.

4.1. GLM

Una variable aleatoria Y pertenece a una familia exponencial si su densidad o función de masa puede escribirse como

$$f(y | \theta, \phi) = \exp \left\{ \frac{y\theta - b(\theta)}{a(\phi)} + c(y, \phi) \right\}. \quad (4.1)$$

El parámetro canónico $\theta = g(\mu)$ es función de $\mu = E(Y)$; g es el enlace canónico y no depende de ϕ . El parámetro de dispersión $\phi > 0$ representa la escala. Las funciones a , b y c son conocidas y cambian con la distribución.

La familia exponencial incluye, entre otras, las distribuciones normal, gaussiana inversa, exponencial, gamma, Bernoulli, binomial, multinomial, Poisson, ji-cuadrada, Wishart y Wishart inversa. Por ejemplo, una normal de media μ y varianza σ^2 tiene $\theta = \mu$, $\phi = \sigma^2$, $a(\phi) = \phi$ y $b(\theta) = \theta^2/2$.

Si Y cuenta éxitos en n ensayos binarios independientes con probabilidad μ ,

$$f(y | \mu) = \binom{n}{y} \mu^y (1 - \mu)^{n-y},$$

entonces $\theta = \log\{\mu/(1 - \mu)\}$, $\phi = 1$ y $b(\theta) = n \log(1 + e^\theta)$. Para una Poisson,

$$f(y | \mu) = e^{-\mu} \frac{\mu^y}{y!} = \exp\{y\theta - e^\theta - \log(y!)\},$$

con $\theta = \log \mu$ y $\phi = 1$.

Una propiedad fundamental es

$$E(Y) = b'(\theta), \quad \text{Var}(Y) = a(\phi)b''(\theta).$$

$b''(\theta)$ describe la relación entre media y varianza. Para la normal el enlace canónico es identidad y la función de varianza es constante; para Poisson, enlace logarítmico y varianza μ ; para binomial, enlace logit y varianza $\mu(1 - \mu)$; para gamma, enlace inverso y varianza proporcional a μ^2 .

Un GLM contiene tres componentes:

1. **Componente aleatorio:** Y_i sigue una distribución particular de la familia exponencial.
2. **Predictor lineal:**

$$\eta_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} = \mathbf{x}_i^T \beta.$$

3. **Función de enlace:** $g(\mu_i) = \eta_i$, donde $\mu_i = E(Y_i)$.

Normalmente se utiliza el enlace canónico. El marco contiene regresión normal, logística, probit, Poisson, binomial negativa y gamma. La estimación clásica se basa en máxima verosimilitud. MCMC es una opción bayesiana común, pero INLA trata una amplia variedad de GLM de forma unificada y permite automatizar considerablemente la inferencia.

4.2. Respuestas binarias

Muchas respuestas solo admiten dos valores: éxito o fracaso, presencia o ausencia. La regresión logística estima la probabilidad de una respuesta binaria en función de uno o más predictores. Si $Y \sim \text{Bernoulli}(\pi)$,

$$f(y) = \exp \left\{ y \log \frac{\pi}{1 - \pi} + \log(1 - \pi) \right\}.$$

El parámetro canónico es el logit y la regresión es

$$Y_i \sim \text{Bernoulli}(\pi_i), \quad \text{logit}(\pi_i) = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip}.$$

Puede sustituirse el logit por el enlace probit $\Phi^{-1}(\pi)$. Ambos se comportan de modo semejante salvo en probabilidades extremas.

4.2.1. Ejemplo: bajo peso al nacer

Los datos `lowbwt` contienen 189 nacimientos registrados en una clínica obstétrica de Massachusetts; 59 bebés pesaron menos de 2500 gramos. La respuesta `LOW` indica bajo peso. Los predictores son edad materna (`AGE`), peso en la última menstruación (`LWT`), raza (`RACE`), tabaquismo durante el embarazo (`SMOKE`), hipertensión (`HT`), irritabilidad uterina (`UI`) y visitas médicas durante el primer trimestre (`FTV`). El objetivo es determinar cuáles constituyen factores de riesgo.

Como referencia de máxima verosimilitud:

```
data(lowbwt, package = "brinla")
lowbwt.glm1 <- glm(
  LOW ~ AGE + LWT + RACE + SMOKE + HT + UI + FTV,
  data = lowbwt, family = binomial()
)
round(coef(summary(lowbwt.glm1)), 4)
```

Las variables categóricas se representan mediante indicadores, tomando la primera categoría como referencia. Por ejemplo, RACE2 compara madres negras con blancas y RACE3, otras razas con blancas.

El ajuste con INLA es:

```
lowbwt.inla1 <- inla(
  LOW ~ AGE + LWT + RACE + SMOKE + HT + UI + FTV,
  data = lowbwt, family = "binomial", Ntrials = 1,
  control.compute = list(dic = TRUE, cpo = TRUE)
)
round(lowbwt.inla1$summary.fixed, 4)
```

Las estimaciones son muy semejantes a las MLE. La media posterior de LWT es -0.0176, con desviación 0.0069 e intervalo de credibilidad (-0.0317, -0.0047); por tanto, su efecto es negativo con probabilidad superior al 95 %. Los intervalos de AGE y FTV contienen cero. RACE2, RACE3, SMOKE1, HT1 y UI1 se asocian positivamente con bajo peso.

Los cocientes de momios se obtienen exponenciando coeficientes. Para LWT, $e^{-0.0176} = 0.9826$: una libra adicional de peso materno reduce en aproximadamente 1.74 % los *odds* de bajo peso, manteniendo los demás predictores.

Una eliminación hacia atrás basada en DIC conduce al modelo reducido:

```
lowbwt.inla2 <- inla(
  LOW ~ LWT + RACE + SMOKE + HT + UI,
  data = lowbwt, family = "binomial", Ntrials = 1,
  control.compute = list(dic = TRUE, cpo = TRUE)
)
c(lowbwt.inla1$dic$dic, lowbwt.inla2$dic$dic)
```

Los DIC son 221.2093 y 217.7459, por lo que se prefiere el reducido. Su predictor estimado es

$$\begin{aligned} \text{logit}(\hat{\pi}) = & 0.109 - 0.018 \text{LWT} + 1.362 \text{RACE}_2 + 0.949 \text{RACE}_3 \\ & + 1.062 \text{SMOKE} + 1.934 \text{HT} + 0.925 \text{UI}. \end{aligned}$$

Puede emplearse para valores ajustados y nuevas predicciones.

4.3. Respuestas de conteo

Un conteo toma valores $0, 1, 2, \dots$ y suele ser discreto y asimétrico. Una regresión lineal puede generar predicciones negativas imposibles y la abundancia de ceros dificulta normalizar mediante transformaciones como $\log(y + c)$.

4.3.1. Regresión Poisson

El GLM básico para conteos es

$$Y_i \sim \text{Poisson}(\mu_i), \quad \log \mu_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}.$$

La media y varianza condicionales son ambas μ_i .

Los datos AIDS registran muertes por sida en Australia por trimestre entre enero de 1983 y junio de 1986, con 14 observaciones. TIME mide trimestres desde enero de 1983 y DEATHS el conteo. La respuesta es asimétrica y crece de forma no lineal.

```
data(AIDS, package = "brinla")
AIDS.inla1 <- inla(
  DEATHS ~ TIME, data = AIDS, family = "poisson",
  control.compute = list(dic = TRUE, cpo = TRUE)
)
round(AIDS.inla1$summary.fixed, 4)
```

Las medias posteriores son 0.3408 y 0.2565:

$$\hat{\mu} = \exp(0.3408 + 0.2565 \text{ TIME}).$$

Cuatro trimestres adicionales multiplican el conteo esperado por $e^{4(0.2565)} = 2.7899$. Sin embargo, el ajuste sobreestima al principio y al final y subestima en el centro. Usar $\log(\text{TIME})$ mejora la curvatura:

```
AIDS.inla2 <- inla(
  DEATHS ~ log(TIME), data = AIDS, family = "poisson",
  control.compute = list(dic = TRUE, cpo = TRUE)
)
c(AIDS.inla1$dic$dic, AIDS.inla2$dic$dic)
```

El segundo predictor produce

$$\hat{\mu} = \exp\{-1.9424 + 2.1747 \log(\text{TIME})\}$$

y reduce DIC de 86.7031 a 74.1076. La MLE mediante `glm(DEATHS ~ log(TIME), family=poisson())` da -1.9442 y 2.1748, prácticamente idénticos.

4.3.2. Regresión binomial negativa

La igualdad Poisson entre media y varianza suele ser demasiado restrictiva. Cuando la varianza supera la nominal hay sobredispersión, y el modelo Poisson subestima los errores estándar. La binomial negativa relaja la restricción.

Supongamos $v_i \sim \text{Gamma}(\alpha, \alpha)$ y, condicionado a v_i ,

$$Y_i | v_i \sim \text{Poisson}(v_i \mu_i).$$

Marginalmente,

$$P(Y_i = y) = \frac{\Gamma(y + \alpha)}{\Gamma(y + 1)\Gamma(\alpha)} \left(\frac{\alpha}{\alpha + \mu_i} \right)^\alpha \left(\frac{\mu_i}{\alpha + \mu_i} \right)^y. \quad (4.2)$$

Entonces $E(Y_i) = \mu_i$ y $\text{Var}(Y_i) = \mu_i + \mu_i^2/\alpha$. Definimos dispersión $\phi = 1/\alpha$; $\phi = 0$ recupera Poisson. Se usa enlace logarítmico.

4.3.2.1. Ejemplo: cangrejos herradura

En 173 hembras de cangrejo herradura se registró el número de machos satélite (SATELLITES), color (COLOR), estado de espinas (SPINE), peso (WEIGHT) y anchura del caparazón (WIDTH). La media de satélites es 2.9191 y la varianza 9.9120. Dentro de cada color, las varianzas también superan ampliamente las medias: hay sobredispersión. WEIGHT y WIDTH correlacionan 0.8869, por lo que conservamos solo WIDTH.

```
data(crab, package = "brinla")
crab.inla1 <- inla(
  SATELLITES ~ COLOR + SPINE + WIDTH,
  data = crab, family = "nbinomial",
  control.compute = list(dic = TRUE, cpo = TRUE)
)
round(crab.inla1$summary.fixed, 4)
```

La media posterior de WIDTH es 0.7001, con intervalo (0.3457, 1.0691); las restantes covariables tienen intervalos que incluyen cero. Las estimaciones coinciden estrechamente con `glm.nb()`.

INLA informa el parámetro de tamaño $\alpha = 1/\phi$. Para obtener dispersión:

```
overdisp.post <- inla.tmarginal(
  fun = function(x) 1/x,
  marg = crab.inla1$marginals.hyperpar[[1]]
)
inla.emarginal(function(x) x, overdisp.post)
inla.qmarginal(c(.025, .975), overdisp.post)
```

La media de ϕ es 1.108 y su intervalo (0.7610, 1.5468), sobredispersión moderada. Al ajustar Poisson, las medias cambian relativamente poco pero las desviaciones posteriores se reducen mucho. Los DIC son 761.2103 para binomial negativa y 918.9907 para Poisson, favoreciendo claramente la primera.

4.4. Modelado de tasas

Con frecuencia se observa un conteo durante cierto tiempo o exposición: accidentes por año, muertes por grupo etario, etc. Una tasa divide el conteo entre la exposición y, a diferencia de una proporción, puede tomar cualquier valor no negativo. Poisson y binomial negativa las representan mediante un *offset*. Si e_i es la exposición,

$$\log(\mu_i/e_i) = \beta_0 + \sum_j \beta_j x_{ij},$$

equivalentemente,

$$\log \mu_i = \log e_i + \beta_0 + \sum_j \beta_j x_{ij},$$

donde el coeficiente de $\log e_i$ queda fijado en uno.

4.4.1. Ejemplo: reclamaciones de seguros

Los datos `Insurance` registran titulares expuestos a riesgo y reclamaciones de automóvil durante el tercer trimestre de 1973. Los predictores categóricos son distrito de residencia (`District`), cilindrada del automóvil (`Group`) y edad (`Age`). En `glm()` el *offset* aparece explícitamente:

```
library(MASS)
data(Insurance, package = "MASS")
insur.glm <- glm(
  Claims ~ District + Group + Age + offset(log(Holders)),
  data = Insurance, family = poisson
)
```

En INLA la exposición se pasa con `E`:

```
insur.inla1 <- inla(
  Claims ~ District + Group + Age,
  data = Insurance, family = "poisson", E = Holders
)
round(insur.inla1$summary.fixed, 4)
```

Para ciudades grandes (`District4`) la media es 0.2342 e intervalo (0.1118, 0.3541). La tasa estimada supera la rural en $e^{0.2342}-1 = 26.36\%$, con intervalo aproximado 11.83–42.49 %, manteniendo grupo y edad. También son importantes los contrastes lineales de `Group` y `Age`.

Los residuos de Pearson clásicos son $(y_i - \hat{\mu}_i) / \sqrt{\hat{\mu}_i}$. Su versión bayesiana sustituye $\hat{\mu}_i$ por $g^{-1}(\mathbf{x}_i^T \beta)$ y posee una posterior. `brinla` calcula sus medias:

```
insur.bresid <- bri.Pois.resid(insur.inla1, plot = TRUE)
abline(h = c(-1.96, 1.96), lty = 2)
qqnorm(insur.bresid$resid)
qqline(insur.bresid$resid)
```

Los residuos forman una banda horizontal aleatoria y siguen bien una normal estándar, respaldando el modelo Poisson.

4.5. Regresión gamma para datos sesgados

El GLM gamma resulta útil para respuestas continuas positivas y sesgadas. Transformar con logaritmos es habitual, pero una gamma permite interpretar parámetros directamente en términos de la media original.

Si una gamma tiene forma a y tasa b , $E(Y) = a/b$ y $\text{Var}(Y) = a/b^2$. INLA reparametriza con media $\mu = a/b$ y precisión $\phi = \mu/b$, de modo que la dispersión es $1/\phi$. El enlace predeterminado es $\mu = e^\eta$ y la hiperprevia se define sobre la precisión transformada.

4.5.1. Ejemplo: resistividad de obleas

Los datos `wafer` proceden de un factorial completo con cuatro factores binarios que pueden influir en la resistividad de una oblea semiconductora. `resist` presenta sesgo claro.

```
library(faraway)
data(wafer)
formula <- resist ~ x1 + x2 + x3 + x4
wafer.inla1 <- inla(formula, family = "gamma", data = wafer)
round(wafer.inla1$summary.fixed, 4)
round(wafer.inla1$summary.hyperpar, 4)
```

Las medias posteriores son 5.4465, 0.1212, -0.3005, 0.1798 y -0.0576. Los resultados son casi idénticos a `glm(..., family=Gamma(link="log"))`. La media posterior de dispersión es 0.0129 y el intervalo (0.0058, 0.0275):

```
disp.post <- inla.tmarginal(
  function(x) 1/x, wafer.inla1$marginals.hyperpar[[1]]
)
inla.emarginal(function(x) x, disp.post)
inla.qmarginal(c(.025, .975), disp.post)
```

Una regresión normal de `log(resist)` produce coeficientes casi iguales, pero la interpretación difiere. En ella,

$$E[\log Y] = \mathbf{x}^T \beta;$$

en la gamma,

$$\log E[Y] = \mathbf{x}^T \beta.$$

Por ejemplo, $e^{0.1212} = 1.1289$: el nivel positivo de `x1` multiplica por 1.1289 la media de resistividad en la escala original, manteniendo los otros factores.

4.6. Respuestas proporcionales

Las proporciones continuas en $(0, 1)$ suelen ser heterocedásticas: presentan mayor variación cerca del centro y menor en los extremos. Transformar mediante logit y aplicar regresión normal puede generar inferencia inexacta en muestras pequeñas y parámetros referidos a la media transformada, no a la original.

La regresión beta modela naturalmente estas respuestas, admite asimetrías y es heterocedástica. Con $p, q > 0$, reparametrizamos una beta mediante

$$\mu = \frac{p}{p+q}, \quad \tau = p+q.$$

Entonces

$$Y \sim \text{Beta}(\mu, \tau), \quad E(Y) = \mu, \quad \text{Var}(Y) = \frac{\mu(1-\mu)}{1+\tau}.$$

Una τ pequeña implica mayor dispersión. La familia beta abarca densidades simétricas, sesgadas, en U y en J. INLA utiliza el enlace logit:

$$\text{logit}(\mu_i) = \beta_0 + \sum_j \beta_j x_{ij}.$$

4.6.1. Ejemplo: rendimiento de gasolina

Los datos `GasolineYield` registran la proporción de petróleo crudo convertida en gasolina (`yield`) y como predictores gravedad del crudo (`gravity`), presión de vapor (`pressure`), temperatura al vaporizarse 10 % (`temp10`) y temperatura al vaporizarse toda la gasolina (`temp`). La respuesta está sesgada a la derecha y llega aproximadamente a 0.5.

```
library(betareg)
data(GasolineYield)
gas.inla1 <- inla(
  yield ~ gravity + pressure + temp10 + temp,
  data = GasolineYield, family = "beta",
  control.compute = list(dic = TRUE, cpo = TRUE)
)
round(gas.inla1$summary.fixed, 4)
round(gas.inla1$summary.hyperpar, 4)
```

Las medias son -2.6607, 0.0045, 0.0297, -0.0109 y 0.0104, prácticamente iguales a máxima verosimilitud. La precisión media de INLA, 88.9334, es bastante menor que la MLE 248.2419; el original deja la explicación de esta diferencia como problema abierto.

Los residuos beta estandarizados bayesianos son

$$r_i = \frac{y_i - g^{-1}(\mathbf{x}_i^T \beta)}{\sqrt{g^{-1}(\mathbf{x}_i^T \beta)[1 - g^{-1}(\mathbf{x}_i^T \beta)]/(1 + \tau)}}.$$

Se obtienen substituyendo muestras posteriores de β y τ :

```
gas.inla1.resid <- bri.beta.resid(
  gas.inla1, plot = TRUE, ylim = c(-2, 2)
)
abline(h = c(-1.96, 1.96), lty = 2)
```

Solo un caso sale de la banda y no se observa patrón sistemático. Como únicamente `temp10` y `temp` tienen intervalos que excluyen cero, ajustamos:

```
gas.inla2 <- inla(
  yield ~ temp10 + temp,
  data = GasolineYield, family = "beta",
  control.compute = list(dic = TRUE, cpo = TRUE)
)
c(gas.inla1$dic$dic, gas.inla2$dic$dic)
```

Los DIC son -126.8995 y -131.2635, por lo que se prefiere el modelo reducido. `temp10` se relaciona negativamente con el rendimiento y `temp`, positivamente. Todos sus residuos quedan en la banda y conservan un patrón aleatorio.

4.7. Modelado de datos inflados en cero

Una regresión inflada en cero modela datos con exceso de ceros. Es común en conteos; por ejemplo, reclamaciones de seguro incluyen personas que no contrataron cobertura y no pueden reclamar. INLA ofrece versiones infladas en cero para Poisson, binomial, binomial negativa y beta-binomial.

Son modelos de mezcla. Para la observación i , un proceso genera siempre cero con probabilidad ω y otro genera desde una distribución g con probabilidad $1 - \omega$:

$$Y_i = \begin{cases} 0, & \text{con probabilidad } \omega, \\ g(Y_i | \mathbf{x}_i), & \text{con probabilidad } 1 - \omega. \end{cases} \quad (4.4)$$

En el modelo de tipo 1,

$$P(Y_i = y_i | \mathbf{x}_i) = \omega I(y_i = 0) + (1 - \omega)g(y_i | \mathbf{x}_i).$$

INLA también ofrece tipo 0, cuya segunda parte se condiciona a valores positivos. Aquí usamos tipo 1.

4.7.1. Ejemplo: publicaciones científicas

Los datos `articles` estudian cómo sexo (`fem`), estado civil (`mar`), hijos pequeños (`kid5`), prestigio del posgrado (`phd`) y publicaciones del mentor (`ment`) afectan el número de artículos (`art`). De 915 científicos, 275 —30.1 %— no publicaron ninguno.

El Poisson inflado en cero es:

```
data(articles, package = "brinla")
articles.inla1 <- inla(
  art ~ fem + mar + kid5 + phd + ment,
  data = articles, family = "zeroinflatedpoisson1",
  control.compute = list(dic = TRUE, cpo = TRUE)
)
round(articles.inla1$summary.fixed, 4)
round(articles.inla1$summary.hyperpar, 4)
```

Solo `phd` incluye cero en su intervalo. La probabilidad estructural de cero tiene media 0.1556 e intervalo (0.1156, 0.1960).

La binomial negativa inflada en cero se ajusta con:

```
articles.inla2 <- inla(
  art ~ fem + mar + kid5 + phd + ment,
  data = articles, family = "zeroinflatednbinomial1",
  control.compute = list(dic = TRUE, cpo = TRUE)
)
round(articles.inla2$summary.fixed, 4)
round(articles.inla2$summary.hyperpar, 4)
```

Las medias de los predictores son parecidas, pero sus desviaciones son mayores. En particular, `mar` pasa de un intervalo apenas positivo bajo Poisson a uno que contiene cero. La probabilidad estructural de cero baja a 0.0110 porque la binomial negativa absorbe parte de la variabilidad. Los DIC son 3255.584 y 3137.209, favoreciendo la binomial negativa.

La dispersión se transforma como antes:

```
overdisp.post <- inla.tmarginal(
  function(x) 1/x,
  articles.inla2$marginals.hyperpar[[1]]
)
inla.emarginal(function(x) x, overdisp.post)
inla.qmarginal(c(.025, .975), overdisp.post)
```

Su media es 0.4457 e intervalo (0.3507, 0.5590), sobredispersión leve a moderada. El modelo concluye que las científicas publican menos artículos que los científicos, el número de hijos pequeños se asocia negativamente y las publicaciones del mentor positivamente. Estado civil y prestigio del posgrado no presentan asociación al nivel de credibilidad del 95 %.

5 Modelos lineales mixtos y lineales generalizados mixtos

En los modelos lineales y GLM suponemos que las respuestas son independientes una vez condicionado el predictor lineal. Con estructuras agrupadas o jerárquicas, o varias observaciones por individuo, las respuestas son dependientes. Este capítulo extiende LM y GLM para representar esa dependencia. Partiremos de una agrupación sencilla, estudiaremos datos longitudinales y terminaremos con modelos lineales generalizados mixtos (GLMM).

5.1. Modelos lineales mixtos

Un modelo lineal mixto (LMM) tiene respuesta gaussiana y combina componentes fijos y aleatorios:

$$\mathbf{y} = \mathbf{X}\beta + \mathbf{Z}\mathbf{u} + \varepsilon.$$

Sin $\mathbf{Z}\mathbf{u}$ sería un modelo lineal. En la formulación frecuentista, β es fijo y $\mathbf{u}$ sigue una normal multivariante de media cero y covarianza desconocida. Desde una perspectiva bayesiana todos los parámetros son aleatorios, aunque conservaremos la terminología porque ambos conjuntos reciben tratamientos distintos.

Para construir e interpretar el modelo suele ser más cómodo el formato gaussiano latente

$$\eta_i = \beta_0 + \sum_j \beta_j x_{ij} + \sum_k f_k(u_{ik}). \quad (5.1)$$

Los términos f_k introducen patrones de correlación apropiados:

- **Agrupación:** respuestas correlacionadas dentro de grupos o mediciones repetidas de una persona.
- **Jerarquía:** casos dentro de grupos que a su vez pertenecen a niveles superiores, como estudiantes, clases, escuelas y distritos.
- **Longitudinal:** seguimiento de un individuo a lo largo del tiempo.

En un LMM la respuesta debe ser gaussiana. Respuestas binomiales, Poisson u otras requieren un GLMM.

5.2. Un solo efecto aleatorio

Hawkins (2005) informa el contenido de nitrógeno de juncos en tres sitios de Cambridgeshire, con cinco observaciones por sitio. Nos interesa más la variación regional y la predicción en un nuevo lugar que comparar específicamente A, B y C; por ello el sitio es un efecto aleatorio:

$$y_{ij} = \alpha + u_j + \varepsilon_{ij}, \quad u_j \sim N(0, \sigma_u^2), \quad \varepsilon_{ij} \sim N(0, \sigma_\varepsilon^2).$$

Como referencia:

```
data(reeds, package = "brinla")
library(lme4)
mmod <- lmer(nitrogen ~ 1 + (1 | site), data = reeds)
summary(mmod)
```

Máxima verosimilitud estima $\sigma_u = 0.433$, $\sigma_\varepsilon = 0.292$ y $\alpha = 3.029$. Con INLA:

```
library(INLA)
library(brinla)
formula <- nitrogen ~ 1 + f(site, model = "iid")
imod <- inla(formula, family = "gaussian", data = reeds)
summary(imod)
```

`model="iid"` expresa efectos independientes con varianza común. La media posterior de α es 3.029 y su intervalo de credibilidad [2.663, 3.396]. INLA informa precisiones; para interpretar desviaciones estándar hay que transformar las distribuciones, no solo las medias o modas, pues estas no son invariantes:

```
invsqrt <- function(x) 1/sqrt(x)
prec.site <- imod$marginals.hyperpar[["Precision for site"]]
prec.epsilon <- imod$marginals.hyperpar[[
  "Precision for the Gaussian observations"
]]
c(
  epsilon = inla.emarginal(invsqrt, prec.epsilon),
  site = inla.emarginal(invsqrt, prec.site)
)
bri.hyperpar.summary(imod)
```

Las medias posteriores son aproximadamente 0.291 y 0.313; las modas, 0.267 y 0.222. La asimetría explica la diferencia. `inla.contrib.sd(imod)$hyper` también puede obtener resúmenes por muestreo.

El coeficiente de correlación intraclass

$$\rho = \frac{\sigma_u^2}{\sigma_u^2 + \sigma_\varepsilon^2}$$

mide la variación entre grupos respecto de la total. Puede muestrearse de la posterior conjunta:

```
sampvars <- 1/inla.hyperpar.sample(1000, imod)
sampicc <- sampvars[, 2]/rowSums(sampvars)
quantile(sampicc, c(.025, .5, .975))
```

La mediana es 0.493 y el intervalo (0.097, 0.891), amplio debido a que solo hay tres sitios. El muestreo posterior de INLA es rápido y produce observaciones independientes; no es una cadena MCMC.

Las posteriores muestran un intercepto aproximadamente normal y componentes de escala asimétricos. La posterior de σ_u está separada de cero: existe variación entre sitios. Como las dos escalas son semejantes, la diferencia entre sitios es comparable a la variación entre muestras del mismo sitio.

5.2.1. Elección de previas

Las previas predeterminadas son: previa impropia plana para el intercepto, $N(0, \infty)$; $N(0, 1000)$ para otros efectos fijos; y gamma con forma 1 y tasa 10^{-5} para las precisiones transformadas. La previa de un coeficiente puede dejar de ser difusa si los predictores tienen escalas extremas; entonces conviene estandarizar o modificarla.

La previa de σ_ε^2 suele importar menos porque cada observación aporta información. La de σ_u^2 puede dominar cuando hay pocos grupos. Las previas de complejidad penalizada (PC) (Simpson et al. 2017) colocan una exponencial sobre la desviación estándar, dan mayor peso al modelo simple $\sigma_u = 0$ y requieren calibración. Se eligen U, p tales que $P(\sigma_u > U) = p$. Una elección débilmente informativa es $p = 0.01$ y $U = 3SD(y)$:

```
sdres <- sd(reeds$nitrogen)
pcprior <- list(
  prec = list(prior = "pc.prec", param = c(3 * sdres, .01))
)
pmod <- inla(
  nitrogen ~ f(site, model = "iid", hyper = pcprior),
  family = "gaussian", data = reeds
)
bri.hyperpar.summary(pmod)
```

El error apenas cambia, pero la media posterior de la escala entre sitios sube a 0.466. También puede definirse una media Cauchy para $\sigma_u > 0$ mediante una expresión `muparser`. Con escala calibrada por $P(\sigma_u > 3SD(y)) = .01$, sus resultados —media 0.423— son comparables a la PC.

No existe una previa inequívocamente mejor. Intercepto y error son poco sensibles, pero el efecto de sitio no: estimar una desviación con tres grupos implica gran incertidumbre. El libro prefiere PC

porque se apoya en información de escala y en una preferencia explícita por el modelo sencillo; la media Cauchy es una alternativa defendible.

5.2.2. Efectos aleatorios

Las marginales de u_A, u_B, u_C están en `pmod$marginals.random$site` y muestran el orden $B < A < C$, con algo de solapamiento. Para calcular correctamente $P(u_C > u_A)$ debe respetarse su correlación conjunta:

```
pmod <- inla(
  nitrogen ~ f(site, model = "iid", hyper = pcprior),
  family = "gaussian", data = reeds,
  control.compute = list(config = TRUE)
)
psamp <- inla.posterior.sample(1000, pmod)
lvsamp <- t(sapply(psamp, function(x) x$latent))
colnames(lvsamp) <- row.names(psamp[[1]]$latent)
mean(lvsamp[, "site:C"] > lvsamp[, "site:A"])
```

La probabilidad es 0.987. Es mayor de lo que sugeriría comparar marginales independientes porque los efectos posteriores están positivamente correlacionados.

5.3. Datos longitudinales

Los datos longitudinales miden individuos en varios momentos. Las observaciones de una persona no son independientes y pueden compartir variación no explicada. Singer y Willett (2003) presenta puntuaciones PIAT de lectura de 89 niños a los 6.5, 8.5 y 10.5 años. Las puntuaciones crecen; quien comienza alto tiende a seguir alto.

5.3.1. Intercepto aleatorio

El modelo más sencillo es

$$y_{ij} = \beta_0 + \beta_1 t_j + u_i + \varepsilon_{ij}, \text{quada } u_i \sim N(0, \sigma_u^2).$$

```
data(reading, package = "brinla")
formula <- piat ~ agegrp + f(id, model = "iid")
imod <- inla(formula, family = "gaussian", data = reading)
imod$summary.fixed
bri.hyperpar.summary(imod)
```

La media posterior del intercepto es -11.535 y la pendiente 5.031: la puntuación crece unos cinco puntos por año. Las escalas posteriores son $\sigma_\varepsilon = 6.71$ y $\sigma_u = 5.30$, próximas a `lmer()`. La variación entre estudiantes en un momento es comparable a la mejora esperada en un año. Los 89 efectos individuales tienen media cero; aproximadamente la mitad están entre -3 y 3, mientras uno alcanza 14.

5.3.2. Pendiente e intercepto aleatorios

Las pendientes también varían:

$$y_{ij} = \beta_0 + \beta_1 t_j + u_{0i} + u_{1i} t_j + \varepsilon_{ij},$$

con (u_{0i}, u_{1i}) normal bivalente. Centramos la edad en 8.5 para que el intercepto sea significativo. INLA requiere índices separados y `iid2d`:

```
reading$cagegrp <- reading$agegrp - 8.5
nid <- nlevels(reading$id)
reading$numid <- as.numeric(reading$id)
reading$slopeid <- reading$numid + nid
formula <- piat ~ cagegrp +
  f(numid, model = "iid2d", n = 2 * nid) +
  f(slopeid, cagegrp, copy = "numid")
imod <- inla(formula, family = "gaussian", data = reading)
```

`copy` induce correlación, no igualdad. Las medias fijas son 31.224 a los 8.5 años y 5.031 puntos por año. Las escalas posteriores son 5.51 para el error, 5.69 para interceptos y 1.92 para pendientes. La correlación intercepto–pendiente tiene media 0.944 e intervalo (0.815, 0.987): estudiantes inicialmente fuertes mejoran más en escala absoluta.

Al modelar `log(piat)`, la correlación tiene media 0.059 e intervalo (-0.162, 0.276). En términos relativos, los estudiantes fuertes mantienen aproximadamente su ventaja; no hay evidencia de que esta aumente.

5.3.3. Predicción

Para un nuevo estudiante con puntuaciones 18 y 25 a los 6.5 y 8.5 años, añadimos la respuesta faltante a los 10.5:

```
reading$id <- as.numeric(reading$id)
newsub <- data.frame(
  id = 90, agegrp = c(6.5, 8.5, 10.5),
  piat = c(18, 25, NA)
)
nreading <- rbind(reading, newsub)
imod <- inla(
  piat ~ agegrp + f(id, model = "iid"),
```

```
family = "gaussian", data = nreading,
control.predictor = list(compute = TRUE)
)
pm90 <- imod$marginals.fitted.values[[270]]
```

La predictiva del predictor queda por debajo de la media general esperada cercana a 41 y es más concentrada que la de un estudiante sin mediciones previas. Esta distribución solo incorpora incertidumbre del predictor. Para una nueva observación hay que sumar un nuevo error:

```
nsamp <- 10000
randprec <- inla.hyperpar.sample(nsamp, imod)[, 1]
neweps <- rnorm(nsamp, 0, 1/sqrt(randprec))
newobs <- inla.rmarginal(nsamp, pm90) + neweps
density(newobs)
```

La predictiva observacional es más dispersa. No es exactamente normal porque la desviación del nuevo error también es aleatoria.

5.4. Modelo clásico con matriz Z

La representación de Henderson

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\mathbf{u} + \boldsymbol{\varepsilon} \quad (5.2)$$

puede especificarse directamente. `lme4` ayuda a construir matrices:

```
mmod <- lmer(nitrogen ~ 1 + (1 | site), reeds)
Z <- getME(mmod, "Z")
X <- getME(mmod, "X")
n <- nrow(reeds)
formula <- y ~ -1 + X + f(id.z, model = "z", Z = Z)
imodZ <- inla(
  formula,
  data = list(y = reeds$nitrogen, id.z = 1:n, X = X)
)
```

El resultado reproduce el análisis anterior. En general $\mathbf{u} \sim N(0, \tau^{-1}\mathbf{C})$ para una matriz fija $\mathbf{C}$. Esta formulación admite una sola precisión para el bloque y no puede reproducir sin más la pendiente e intercepto aleatorios correlacionados, pero habilita otras aplicaciones.

5.4.1. Regresión ridge revisitada

Con predictores colineales, ridge minimiza

$$(\mathbf{y} - \mathbf{Z}\mathbf{u})^T(\mathbf{y} - \mathbf{Z}\mathbf{u}) + \lambda \sum_j u_j^2.$$

El equivalente bayesiano usa $\mathbf{u} \sim N(0, \sigma_u^2 \mathbf{I})$ y $\varepsilon \sim N(0, \sigma_\varepsilon^2 \mathbf{I})$, con $\lambda = \sigma_\varepsilon^2 / \sigma_u^2$.

En `meatspec`, 215 muestras de carne poseen contenido graso y absorbancias en 100 longitudes de onda. Usamos 172 para entrenamiento y 43 para prueba. Una regresión ordinaria obtiene RMSE 3.814 y coeficientes extremadamente inestables. El modelo `z`, escalando la respuesta por 100 y dejando las 43 respuestas como NA, produce distribuciones predictivas:

```
data(meatspec, package = "brinla")
n <- nrow(meatspec)
X <- matrix(1, n, 1)
Z <- as.matrix(meatspec[, -101])
y <- meatspec$fat
y[173:215] <- NA
formula <- y ~ -1 + X + f(idx.Z, model = "z", Z = Z)
zmod <- inla(
  formula,
  data = list(y = y/100, idx.Z = 1:n, X = X),
  control.predictor = list(compute = TRUE)
)
```

El RMSE de prueba baja a 1.903 y los coeficientes se vuelven suaves respecto de la longitud de onda. Una formulación alternativa define $\eta = \mathbf{A}\eta'$ con $\mathbf{A} = [\mathbf{X} : \mathbf{Z}]$ mediante `control.predictor=list(A=cbind(X,Z))`; obtiene RMSE 1.902. Estas formulaciones estiman dentro del modelo la intensidad de contracción, a diferencia de fijar directamente previas informativas para cada coeficiente.

5.5. Modelos lineales generalizados mixtos

Un GLMM combina una respuesta de familia exponencial con efectos aleatorios:

$$g(\mu) = \eta = \mathbf{X}\beta + \mathbf{Z}\mathbf{u}.$$

Previas gaussianas para β y $\mathbf{u}$ lo convierten en un LGM apto para INLA. Los GLMM pueden ser difíciles para máxima verosimilitud; el enfoque bayesiano a veces encuentra soluciones cuando la optimización pura no.

5.6. GLMM Poisson

Un estudio de Nitrofen asignó 50 pulgas de agua a cinco concentraciones del herbicida y contó crías vivas en tres puestas. El número de crías de una misma pulga está correlacionado. Un modelo natural es

$$Y_i \sim \text{Poisson}(e^{\eta_i}), \quad \eta_i = \mathbf{x}_i^T \beta + u_j,$$

donde u_j representa la pulga. El patrón exploratorio sugiere interacción entre concentración y puesta.

```
data(nitrofen, package = "boot")
library(dplyr)
library(tidyr)
lnitrofen <- nitrofen |>
  select(-total) |>
  mutate(id = row_number()) |>
  pivot_longer(starts_with("brood"),
               names_to = "brood", values_to = "live") |>
  arrange(id)
lnitrofen$brood <- factor(lnitrofen$brood, labels = 1:3)

formula <- live ~ I(conc/300) * brood + f(id, model = "iid")
imod <- inla(formula, family = "poisson", data = lnitrofen)
```

Dividir concentración por 300 evita problemas de escala. Las medias posteriores son -0.041 para la pendiente de la primera puesta, 1.164 y 1.346 para los niveles iniciales de las puestas 2 y 3, y -1.664 y -1.821 para sus interacciones. La primera pendiente incluye cero; las otras dos son claramente negativas. Exponenciando, las puestas 2 y 3 producen inicialmente 3.20 y 3.84 veces más crías, pero caen más de 80 % al aumentar la concentración. La escala individual tiene media 0.294: una pulga típica multiplica la tasa aproximadamente por 1.3 o su inversa.

El predictor lineal en concentración tiene DIC 785.90 frente a 841.97 para $\log(\text{conc}+1)$, por lo que se conserva. Un Q-Q de efectos individuales no detecta pulgas especialmente anómalas. CPO identifica como caso más improbable una pulga a concentración 310 con 10 crías en la segunda puesta; las otras nueve tienen cero. PIT señala el mismo caso y muestra que los extremos tienden a tener más crías de las esperadas. `cpo$failure` es cero; cuando no lo sea debe usarse `inla.cpo()`.

Una previa PC calibrada alrededor de una desviación 0.3 produce casi la misma posterior; con 50 individuos el resultado es poco sensible. Añadir un efecto iid por observación para sobredispersión da escala 0.010 frente a 0.294 para pulga, por lo que la sobredispersión adicional es despreciable.

5.7. GLMM binomial

Los datos `ohio` siguen 537 niños de 7 a 10 años durante cuatro años. La respuesta indica sibilancias y `smoke` si la madre fuma. Hay cuatro respuestas correlacionadas por niño. Usamos

$$\text{logit } P(Y_{ij} = 1) = \beta_0 + \beta_1 \text{age}_{ij} + \beta_2 \text{smoke}_i + u_i.$$

```
data(ohio, package = "brinla")
formula <- resp ~ age + smoke + f(id, model = "iid")
imod <- inla(formula, family = "binomial", data = ohio)
imod$summary.fixed
bri.hyperpar.summary(imod)
```

Las medias son -2.993, -0.167 y 0.391. Un año adicional multiplica los *odds* por 0.847, reducción cercana a 15 %, con intervalo completamente bajo uno. Una madre fumadora los multiplica por 1.478, pero su intervalo (0.925, 2.371) incluye uno: no podemos asegurar aumento, aunque uno tan grande como 137 % sigue siendo plausible. La asociación no prueba causalidad.

La escala individual tiene media 1.926, que en *odds* representa un factor cercano a 7. El efecto es fuerte: 355 niños nunca presentan sibilancias, mientras 18 lo hacen en los cuatro momentos. La probabilidad posterior de que el coeficiente de tabaco sea negativo es

```
inla.pmarginal(0, imod$marginals.fixed$smoke)
```

igual a 0.0513. No es un valor *p*: expresa directamente $P(\beta_{\text{smoke}} < 0 \mid y)$.

La edad lineal ajusta mal las ocho proporciones observadas. Comparando modelos lineal, edad como factor y edad por tabaco, los DIC son 1466.2, 1463.1 y 1463.4; WAIC, 1418.9, 1416.2 y 1417.6. Se prefiere edad como factor sin interacción. Respecto de los 7 años, a los 10 los *odds* caen aproximadamente 42 %; los 8 y 9 años cambian poco.

Podemos permitir que el efecto individual evolucione mediante AR(1), replicado por niño:

```
ohio$obst <- rep(1:4, 537)
ohio$repl <- ohio$id + 1
formula <- resp ~ factor(age) + smoke +
  f(obst, model = "ar1", replicate = repl)
imod <- inla(formula, family = "binomial", data = ohio)
```

Los efectos fijos apenas cambian. La escala es 1.972 y ρ tiene media 0.985 e intervalo (0.946, 0.999): la salud pulmonar subyacente de un niño se mantiene bastante constante durante los cuatro años.

5.7.1. Mejora de la aproximación

INLA puede ser inexacto en datos binarios escasos. La corrección basada en cópulas de Ferkingstad y Rue (2015) se activa así:

```
cmmod <- inla(
  resp ~ age + smoke + f(id, model = "iid"),
  family = "binomial", data = ohio,
  control.inla = list(correct = TRUE)
)
```

5 Modelos lineales mixtos y lineales generalizados mixtos

Los efectos fijos cambian poco, pero la escala individual pasa de aproximadamente 1.93 a 2.06. La corrección casi no cuesta tiempo y tiende a mejorar GLMM, especialmente binarios; se recomienda para todos los GLMM, aunque aporta poco en casos fáciles como el Poisson anterior.

6 Análisis de supervivencia

El análisis de supervivencia estudia datos cuya respuesta es el tiempo hasta un suceso de interés. Se aplica a muerte, aparición de enfermedades, fallos de equipos, terminación de empleos, jubilación, matrimonio y muchos otros eventos. Puede interesar caracterizar la distribución del tiempo, comparar grupos o relacionarlo con covariables.

Los datos suelen recogerse durante un periodo finito. Algunos sujetos no alcanzan el desenlace y solo sabemos que su supervivencia excede el tiempo observado: su respuesta está censurada. Desde Cox (1972), el modelo de riesgos proporcionales de Cox es la opción predeterminada. Describe el riesgo mediante una función basal no especificada y efectos lineales de covariables. El análisis tradicional usa verosimilitud parcial; Bayes utiliza la verosimilitud completa para estimar todos los elementos.

6.1. Introducción

Sea $T > 0$ un tiempo continuo. Su función de distribución es $F(t) = P(T \leq t)$ y la función de supervivencia

$$S(t) = 1 - F(t) = P(T > t).$$

$S(t)$ es no creciente, $S(0) = 1$ y, para un tiempo propio, $S(\infty) = 0$. Su densidad es $f(t) = -S'(t)$. La función de riesgo instantáneo es

$$h(t) = \lim_{\Delta t \rightarrow 0} \frac{P(t \leq T < t + \Delta t \mid T \geq t)}{\Delta t} = \frac{f(t)}{S(t)} = -\frac{d}{dt} \log S(t).$$

El riesgo acumulado

$$H(t) = \int_0^t h(u) du = -\log S(t)$$

implica $S(t) = \exp\{-H(t)\}$.

Para n sujetos observamos $(t_i, \delta_i, \mathbf{x}_i)$, donde $\delta_i = 1$ señala el evento y $\delta_i = 0$ censura derecha. El modelo de Cox es

$$h(t \mid \mathbf{x}) = h_0(t) \exp(\beta_1 x_1 + \cdots + \beta_p x_p). \quad (6.1)$$

El cociente de riesgos de dos sujetos no depende del tiempo, de donde proviene el nombre «riesgos proporcionales». Diferentes supuestos sobre $h_0(t)$ producen distintos modelos.

6.2. Modelos semiparamétricos

6.2.1. Riesgo basal constante por tramos

Una construcción bayesiana conveniente divide el eje temporal mediante $0 = s_0 < s_1 < \dots < s_K$ y supone

$$h_0(t) = \lambda_k, \quad t \in (s_{k-1}, s_k].$$

Para el sujeto i en el intervalo k ,

$$h(t_i) = \exp\{\log \lambda_k + \mathbf{x}_i^T \beta\}.$$

Su contribución a la log-verosimilitud puede reescribirse como la suma de k contribuciones Poisson: ceros en los intervalos atravesados y δ_i en el último, con exposiciones iguales a las longitudes recorridas. Esta ampliación de datos convierte el modelo en un LGM apto para INLA.

6.2.1.1. Ejemplo ACTG 320

El ensayo ACTG 320 incluyó 1151 personas con VIH. Comparó un régimen de tres fármacos con Indinavir ($\text{tx}=1$) frente a dos fármacos, y registró tiempo hasta diagnóstico definitorio de sida o muerte, edad, sexo, CD4 basal y meses previos de zidovudina.

La referencia frecuentista es:

```
data(ACTG320, package = "brinla")
library(survival)
ACTG320.coxph <- coxph(
  Surv(time, censor) ~ tx + age + sex + priorzdv,
  data = ACTG320
)
```

INLA crea la respuesta con `inla.surv()` y asigna una caminata aleatoria de primer orden a los log-riesgos basales de 20 intervalos:

```
ACTG320.formula <- inla.surv(time, censor) ~
  tx + age + sex + priorzdv
ACTG320.inla1 <- inla(
  ACTG320.formula, family = "coxph", data = ACTG320,
  control.hazard = list(model = "rw1", n.intervals = 20),
  control.compute = list(dic = TRUE)
)
```

La media posterior del tratamiento es -0.6879 , con intervalo $(-1.1181, -0.2730)$. El cociente de riesgos es $e^{-0.6879} = 0.5026$, con intervalo $(0.3269, 0.7611)$: manteniendo las demás covariables, el régimen triple reduce aproximadamente a la mitad la tasa de progresión o muerte. Sexo y zidovudina previa no son importantes. Edad queda en el límite, con intervalo $(-0.0006, 0.0426)$. El intercepto aparece porque INLA estima el riesgo basal, a diferencia de la verosimilitud parcial.

6.2.2. Riesgos proporcionales estratificados

Si una covariable viola proporcionalidad, puede estratificarse. Cada uno de S grupos tiene su propio riesgo basal $h_{0j}(t)$, pero comparte β . Se asignan RW1 con precisión común a los log-riesgos de cada estrato.

En ACTG 320 creamos cuartiles de CD4:

```
ACTG320$cd4group <- as.numeric(cut(
  ACTG320$cd4,
  breaks = c(-Inf, quantile(ACTG320$cd4, c(.25, .5, .75)), Inf),
  labels = 1:4
))
ACTG320.inla2 <- inla(
  ACTG320.formula, family = "coxph", data = ACTG320,
  control.hazard = list(
    model = "rw1", n.intervals = 20,
    strata.name = "cd4group"
  ),
  control.compute = list(dic = TRUE)
)
```

Los riesgos basales difieren marcadamente: decrecen en los dos grupos de CD4 bajo y aumentan en los dos superiores. DIC baja de 1316.253 a 1274.168, respaldando la estratificación. El efecto de tratamiento permanece cercano, -0.6625 .

6.3. Modelos de tiempo de fallo acelerado

Los modelos paramétricos considerados poseen representación de tiempo acelerado (AFT):

$$S(t | \mathbf{x}) = S_0\{t \exp(\mathbf{x}^T \beta)\}. \quad (6.3)$$

$\exp(\mathbf{x}^T \beta)$ es el factor de aceleración. Equivalentemente,

$$\log T = \gamma_0 + \gamma_1 x_1 + \dots + \gamma_p x_p + \sigma \varepsilon, \quad (6.4)$$

con $\gamma_j = -\beta_j$. Una exponencial o Weibull corresponde a error de valor extremo; log-normal a error normal y log-logística a error logístico.

Para Weibull,

$$S(t \mid \alpha, \lambda) = e^{-\lambda t^\alpha}, \quad f(t) = \alpha \lambda t^{\alpha-1} e^{-\lambda t^\alpha}, \quad h(t) = \alpha \lambda t^{\alpha-1}.$$

$\alpha = 1$ produce exponencial. Weibull tiene representaciones AFT y de riesgos proporcionales. INLA admite `exponentialsurv`, `weibullsurv`, `lognormalsurv` y `loglogistic`.

6.3.1. Ejemplo: cáncer de laringe

Los datos incluyen 90 hombres diagnosticados entre 1970 y 1978, con tiempo hasta muerte o fin del estudio, etapa clínica, edad y año de diagnóstico. Ajustamos Weibull:

```
data(larynx, package = "brinla")
formula <- inla.surv(time, delta) ~ factor(stage) + age
larynx.inla1 <- inla(
  formula, family = "weibullsurv", data = larynx,
  control.compute = list(dic = TRUE)
)
```

`survreg()` informa coeficientes γ de log-tiempo; INLA informa los coeficientes de riesgo $\beta = -\gamma/\sigma$, por lo que los signos son opuestos. En INLA, un valor positivo indica peor supervivencia.

La etapa 4 tiene media 1.7059 e intervalo (0.8896, 2.4983) respecto de la etapa 1. El factor $e^{1.7059} = 5.5063$ indica que la mediana de supervivencia de etapa 1 es aproximadamente 5.5 veces la de etapa 4, con intervalo de factores (2.434, 12.162). Edad y etapas 2–3 no excluyen cero al 95 %.

6.4. Diagnóstico del modelo

Los residuos de Cox–Snell bayesianos son

$$r_{Ci} = H_i(t_i, \theta \mid \mathbf{x}_i) = -\log S(t_i, \theta \mid \mathbf{x}_i). \quad (6.8)$$

Se obtiene su posterior sustituyendo muestras de parámetros o, aproximadamente, sus medias. Si el modelo es adecuado, se comportan como una muestra censurada exponencial unitaria. El estimador Nelson–Aalen de su riesgo acumulado debe seguir una recta de pendiente uno al graficarlo contra r_C .

Comparamos Weibull, exponencial y Cox:

```
larynx.inla2 <- inla(
  formula, family = "exponentialsurv", data = larynx,
  control.compute = list(dic = TRUE)
)
larynx.inla3 <- inla(
  formula, family = "coxph", data = larynx,
```

```

control.hazard = list(model = "rw1", n.intervals = 20),
control.compute = list(dic = TRUE)
)
r1 <- bri.surv.resid(larynx.inla1, larynx$time, larynx$delta)
r2 <- bri.surv.resid(larynx.inla2, larynx$time, larynx$delta)
r3 <- bri.surv.resid(larynx.inla3, larynx$time, larynx$delta)

```

Los tres ajustes son aceptables; el exponencial sigue mejor la diagonal, mientras Weibull queda algo por encima salvo en la cola.

Los residuos de martingala son

$$r_{Mi} = \delta_i - r_{Ci},$$

y comparan el evento observado con el número esperado. Son asimétricos, acotados por 1 y sin cota inferior. Los residuos de devianza

$$r_{Di} = \text{sgn}(r_{Mi}) [-2\{r_{Mi} + \delta_i \log(\delta_i - r_{Mi})\}]^{1/2}$$

son más aproximadamente normales. Las gráficas contra edad no muestran patrón en ninguno de los tres modelos.

Los residuos de martingala también ayudan a decidir la forma funcional de una covariable. Se ajusta el modelo sin ella, se grafican residuos contra la covariable y se superpone una curva suave. En `larynx`, curvas RW2 contra `diagyr` son aproximadamente lineales, por lo que basta incluir el año de diagnóstico sin transformación.

6.5. Datos censurados por intervalo

Con censura por intervalo solo sabemos $T \in [t^{(1)}, t^{(2)}]$. Con truncamiento izquierdo, el sujeto entra al conjunto de riesgo después de un tiempo conocido. Una observación general incluye límites, truncamiento, indicador y covariables. Los AFT con previas gaussianas siguen siendo LGM y pueden ajustarse con INLA. El truco Poisson del Cox por tramos no se extiende a censura por intervalo, por lo que INLA no maneja esa combinación semiparamétrica.

6.5.1. Ejemplo: emergencia dental

El estudio belga Signal Tandmobiel siguió 4386 escolares. Analizamos la edad de emergencia del primer premolar superior izquierdo, medida desde los 5 años. `LEFT` y `RIGHT` delimitan el intervalo; `RIGHT=999` indica censura derecha. `SEX` distingue niña y niño; `DMF` señala si el diente temporal predecesor estaba cariado, perdido o empastado.

```
data(tooth24, package = "brinla")
tooth24$cens <- with(tooth24, ifelse(RIGHT == 999, 0, 3))
tooth24.formula <- inla.surv(LEFT, cens, RIGHT) ~ SEX + DMF
tooth24.inla <- inla(
  tooth24.formula, family = "loglogistic", data = tooth24
)
```

Las medias posteriores son 1.7732 para intercepto, -0.0726 para niña y -0.0903 para DMF, con ambos intervalos completamente negativos. Los resultados casi coinciden con `survreg(..., dist="loglogistic")`. Para niñas, $e^{-0.0726} = 0.930$: la mediana del tiempo desde los cinco años hasta la emergencia es 0.93 veces la de niños con igual DMF.

INLA informa la forma log-logística $\alpha = 7.023$, mientras `survreg` informa $s = 1/\alpha = 0.1365$. La log-logística es el único AFT de los considerados que posee forma de *odds* proporcionales. El cociente de *odds* de fallo para niñas es aproximadamente 1.67: a un tiempo dado, sus *odds* de que el diente ya haya emergido son 1.67 veces los de niños.

6.6. Modelos de fragilidad

La fragilidad introduce un efecto aleatorio multiplicativo sobre el riesgo para representar heterogeneidad no observada y asociación dentro de grupos. Para el individuo k del grupo i , un Weibull con fragilidad puede escribirse

$$t_{ik} \mid \lambda_{ik} \sim \text{Weibull}(\alpha, \lambda_{ik}), \quad \log \lambda_{ik} = \mathbf{x}_{ik}^T \beta + b_i,$$

de modo que

$$h(t_{ik}) = \alpha t_{ik}^{\alpha-1} \exp(\mathbf{x}_{ik}^T \beta + b_i). \quad (6.10)$$

Con $b_i \sim N(0, \tau_b^{-1})$ y previas gaussianas y gamma, es un LGM.

6.6.1. Ejemplo: infecciones renales

Los datos contienen tiempos hasta primera y segunda infección del catéter en 38 pacientes de diálisis; 24 % están censurados. Dos tiempos del mismo paciente comparten fragilidad. Predictores: edad, sexo y enfermedad.

```
data(kidney, package = "survival")
formula <- inla.surv(time, status) ~ age + sex + disease +
  f(id, model = "iid",
    hyper = list(prec = list(param = c(.1, .1))))
kidney.inla <- inla(
  formula, family = "weibullsurv", data = kidney
)
```

```
kidney.hp <- inla.hyperpar(kidney.inla)
bri.hyperpar.summary(kidney.hp)
```

Solo sexo tiene intervalo completamente distinto de cero: las mujeres presentan menor riesgo de infección. La forma Weibull refinada tiene media 1.163. La desviación de fragilidad tiene media 0.659, intervalo (0.272, 1.167) y posterior sesgada a la derecha; coincide razonablemente con la estimación frecuentista 0.628.

6.7. Modelado conjunto longitudinal y de tiempo al evento

Muchos estudios clínicos miden repetidamente un biomarcador y registran tiempo hasta muerte o enfermedad. Modelarlos por separado es inapropiado cuando el proceso longitudinal se relaciona con supervivencia. Un modelo conjunto los conecta mediante efectos gaussianos latentes compartidos.

Para el sujeto i , el submodelo longitudinal es

$$y_{ij} \mid \eta_{ij}, \sigma^2 \sim N(\eta_{ij}, \sigma^2), \text{quad} \eta_{ij} = \mathbf{x}_{1ij}^T \beta_1 + W_{1i}(s_{ij}). \quad (6.11)$$

El submodelo de supervivencia, por ejemplo Weibull, usa

$$\log \lambda_i(t) = \mathbf{x}_{2i}(t)^T \beta_2 + W_{2i}(t). \quad (6.12)$$

Una construcción flexible es

$$W_{1i}(s) = U_{1i} + U_{2i}s,$$

$$W_{2i}(t) = \gamma_1 U_{1i} + \gamma_2 U_{2i} + \gamma_3 \{U_{1i} + U_{2i}t\} + U_{3i}. \quad (6.14)$$

$\gamma_1, \gamma_2, \gamma_3$ miden asociaciones inducidas por intercepto, pendiente y valor longitudinal en el evento. Con normales bivariantes para (U_1, U_2) , fragilidad normal y previas estándar, todo es un campo gaussiano latente.

6.7.1. Ejemplo: ensayo clínico de sida

El estudio siguió 467 pacientes asignados a didanosina o zalcitabina. Registró raíz de CD4 al inicio y a 2, 6, 12 y 18 meses, y tiempo hasta muerte. También sexo, infección oportunista previa (PREVOI) y fracaso o intolerancia a AZT.

El submodelo longitudinal incluye tiempo, tratamiento por tiempo, sexo, PREVOI, estrato e intercepto y pendiente individuales. El submodelo de supervivencia exponencial incluye tratamiento, sexo, PREVOI y estrato. El modelo seleccionado enlaza ambos mediante $W_{2i} = \gamma_1 U_{1i} + \gamma_2 U_{2i}$.

INLA permite distintas verosimilitudes por observación. Se apilan una respuesta gaussiana y otra `inla.surv`, rellenando con NA donde una fila pertenece a la otra respuesta; se preparan covariables separadas y efectos compartidos mediante `iid2d` y `copy`:

```

data(joint, package = "brinla")
longdat <- joint$longitudinal
survdat <- joint$survival
n1 <- nrow(longdat); n2 <- nrow(survdat)

y.long <- c(longdat$y, rep(NA, n2))
y.surv <- inla.surv(
  c(rep(NA, n1), survdat$SURVTIME),
  c(rep(NA, n1), survdat$CENSOR)
)
Yjoint <- list(y.long, y.surv)

```

La llamada final usa `family=c("gaussian","exponentialsurv")`, efectos U11/U21 como iid2d y copias U12/U22 en supervivencia. El código fuente conserva la preparación completa de índices y covariables en la edición original; la idea crucial es compartir los mismos efectos con coeficientes de copia estimables.

En el submodelo longitudinal, CD4 disminuye con el tiempo: media -0.2653 e intervalo (-0.3612, -0.1699). PREVOI también reduce CD4, -2.3492 con intervalo (-2.8230, -1.8758). En supervivencia, solo PREVOI tiene un intervalo completamente distinto de cero. Los coeficientes de asociación son -0.1933 y -1.6047, ambos claramente negativos: la supervivencia está vinculada tanto al nivel inicial de CD4 como a su velocidad de descenso. Clínicamente es razonable: CD4 alto refleja mejor salud y un descenso rápido anticipa peor supervivencia.

7 Modelos de caminata aleatoria para métodos de suavizado

Los métodos de suavizado desempeñan un papel importante en la regresión no paramétrica. En este capítulo se presentan *splines* de suavizado, *splines* de placa delgada y *splines* de regresión penalizados (P-splines), se muestra su relación con las distribuciones a priori de caminata aleatoria (RW) y se explica cómo efectuar inferencia bayesiana con INLA.

7.1. Introducción

Dados valores fijos $x_1, \dots, x_n \in \mathbb{R}$, supongamos

$$y_i = f(x_i) + \varepsilon_i, \quad i = 1, \dots, n, \quad (7.1)$$

donde los ε_i son independientes e idénticamente distribuidos, de media cero y varianza desconocida σ_ε^2 . El objetivo es estimar f .

El enfoque paramétrico supone que $f(x)$ pertenece a una familia $f(x | \beta)$ con un número finito de parámetros: por ejemplo, una función lineal, polinómica o exponencial. Es eficiente cuando la familia es correcta, comprime la información necesaria para predecir y suele ofrecer parámetros interpretables; por ello debe preferirse cuando existe buena información sustantiva. Su inconveniente es que excluye muchas funciones plausibles.

El enfoque no paramétrico elige f de una familia amplia de funciones suaves. Busca conservar la señal importante y omitir el ruido. La relación ya no se resume mediante una fórmula sencilla y suele requerir una descripción gráfica y más información para predecir. A cambio, su flexibilidad reduce el riesgo de errores graves cuando se sabe poco acerca de la forma funcional apropiada.

7.2. *Splines* de suavizado

Para el modelo Ecuación 7.1, el *spline* de suavizado de grado $2m - 1$ elige f para minimizar

$$\sum_{i=1}^n \{y_i - f(x_i)\}^2 + \lambda \int \{f^{(m)}(x)\}^2 dx. \quad (7.2)$$

El primer término mide la proximidad a los datos; el segundo penaliza la rugosidad. El parámetro λ equilibra ambos objetivos. Para $\lambda = 0$ se obtiene una interpolación y, cuando $\lambda \rightarrow \infty$, el ajuste de mínimos cuadrados dentro del espacio nulo de la penalización. Habitualmente $m = 1$ o 2 , lo que produce *splines* lineales o cúbicos.

7.2.1. Priori RW para ubicaciones equiespaciadas

Ordenemos $x_1 < \dots < x_n$ y definamos $d_i = x_i - x_{i-1}$. Si $d_i = d$, la penalización puede aproximarse por diferencias hacia atrás:

$$\int \{f^{(m)}(x)\}^2 dx \approx d^{1-2m} \sum_{i=m+1}^n \{\nabla^m f(x_i)\}^2.$$

Se supone entonces

$$\nabla^m f(x_i) \stackrel{\text{ind}}{\sim} N(0, \sigma_f^2),$$

donde $\nabla f(x_i) = f(x_i) - f(x_{i-1})$ y $\nabla^2 f(x_i) = f(x_i) - 2f(x_{i-1}) + f(x_{i-2})$. Para $\mathbf{f} = (f(x_1), \dots, f(x_n))^T$, la densidad es gaussiana singular con precisión $\sigma_f^{-2} \mathbf{Q}_m$, donde $\mathbf{Q}_m = \mathbf{D}_m^T \mathbf{D}_m$. Su rango es $n - m$ y su espacio nulo está generado por polinomios de orden menor que m . Con verosimilitud gaussiana, la media posterior es la versión bayesiana discretizada del *spline* y $\lambda = \sigma_\epsilon^2 / \sigma_f^2$.

La suavidad aparece en las distribuciones condicionales completas. Para RW1, $f(x_i)$ depende de sus vecinos inmediatos; para RW2, de los dos vecinos a cada lado. Esta dependencia local hace que $\mathbf{Q}_m$ sea muy dispersa y permite cálculos rápidos. La singularidad exige restricciones de identificabilidad: con intercepto se usa habitualmente $\sum_i f(x_i) = 0$; si también hay pendiente se necesita otra restricción.

7.2.1.1. Ejemplo simulado

Se generan 100 observaciones equiespaciadas con $f(x) = \sin^3(6\pi x)$ y ruido normal de desviación estándar 0.2:

```
library(INLA)
library(brinla)
set.seed(1)
n <- 100
x <- seq(0, 1, length.out = n)
f.true <- sin(2 * pi * x * 3)^3
y <- f.true + rnorm(n, sd = 0.2)
data.inla <- list(y = y, x = x)

formula1 <- y ~ -1 + f(x, model = "rw1", constr = FALSE)
formula2 <- y ~ -1 + f(x, model = "rw2", constr = FALSE)
result1 <- inla(formula1, data = data.inla)
result2 <- inla(formula2, data = data.inla)
```

-1 excluye el intercepto y `constr = FALSE` evita la restricción de suma cero. Las medias y bandas creíbles se encuentran en `summary.random$x`. RW1 resulta demasiado ondulante; RW2 es más suave, pero pierde parte de la inflexión cerca de $x = 0.75$ y el mínimo próximo a 0.9. La función verdadera posee suavidad variable, mientras que ambos modelos suponen suavidad constante.

Como comparación frecuentista, `smooth.spline()` selecciona λ por validación cruzada y `mgcv::gam(y ~ s(x))` ajusta una placa delgada de rango bajo. El primero queda entre RW1 y RW2 en suavidad; el segundo proporciona errores estándar derivados de la covarianza posterior bayesiana de sus parámetros.

7.2.2. Elección de las distribuciones a priori de las varianzas

INLA especifica priors sobre las precisiones $\delta = 1/\sigma_\epsilon^2$ y $\tau = 1/\sigma_f^2$. La opción predeterminada corresponde a una gamma con $a = 1$ y $b = 5 \times 10^{-5}$. Como suele ser difícil elicitar estos parámetros, se emplean priors débiles: $a = \epsilon_1, b = \epsilon_2$; $a = -1, b = 0$ para una forma plana relacionada con REML; $a = -1/2, b = 0$ como elección práctica; o $a = b = 0$ para Jeffreys. Algunas son impropias: la de Jeffreys sólo puede usarse para δ sin comprometer la propiedad posterior bajo las condiciones estudiadas en la literatura. La gamma con parámetros positivos pequeños suele ser más estable.

```
lgprior.error <- list(prec = list(param = c(0, 0)))
lgprior.rw <- list(prec = list(param = c(-0.5, 0)))
formula <- y ~ -1 + f(x, model = "rw2", constr = FALSE,
                    hyper = lgprior.rw)
result <- inla(formula, data = data.inla,
               control.family = list(hyper = lgprior.error))
```

7.2.2.1. Escalamiento del prior

Una misma trayectoria reexpresada en $[0, 0.1]$ o $[0, 1000]$ puede producir ajustes muy distintos bajo un hiperprior fijo. Los modelos RW penalizan desviaciones locales y la escala del predictor altera su magnitud. Además, una precisión no significa exactamente lo mismo bajo diferentes vecindades.

La opción `scale.model = TRUE` reescala el modelo para que su varianza generalizada —la media geométrica de las varianzas marginales— sea uno. Así, el hiperparámetro adquiere una interpretación comparable entre escalas y estructuras. Está disponible para RW1, RW2, RW2D y Besag.

```
formula.scaled <- y ~ -1 +
  f(x, model = "rw2", constr = FALSE, scale.model = TRUE)
result.scaled <- inla(formula.scaled, data = data.inla)
```

El costo es que la salida queda expresada en la nueva escala; no siempre conviene aplicarla si la escala original ya posee significado sustantivo.

7.2.3. Caminatas aleatorias en ubicaciones no equiespaciadas

Los *splines* pueden representarse mediante la ecuación diferencial estocástica

$$\frac{d^m f(x)}{dx^m} = \sigma_f \frac{dW(x)}{dx}, \quad m = 1, 2. \quad (7.3)$$

Una representación exacta de proceso gaussiano tendría una covarianza densa. La solución débil conserva una precisión dispersa. Para RW1,

$$f(x_{i+1}) - f(x_i) \sim N(0, d_i \sigma_f^2),$$

y la media condicional pondera los vecinos según sus distancias. Para RW2, una aproximación por elementos finitos al paseo aleatorio integrado produce una matriz de precisión bandeada, de rango $n - 2$, cuyo espacio nulo está generado por $\mathbf{1}$ y $(x_1, \dots, x_n)^\top$.

7.2.3.1. Guía de alquileres de Múnich

Los datos contienen 2 035 departamentos de 380 distritos. La respuesta es el alquiler por metro cuadrado; entre los predictores están superficie, año de construcción, localización e indicadores de equipamiento. Se observan relaciones no lineales con superficie y año:

```
data(Munich, package = "brinla")
formula1 <- rent ~ -1 + f(floor.size, model = "rw2", constr = FALSE)
formula2 <- rent ~ -1 + f(year, model = "rw2", constr = FALSE)
result1 <- inla(formula1, data = Munich)
result2 <- inla(formula2, data = Munich)
```

INLA detecta automáticamente el espaciado irregular. Ambos efectos son claramente no lineales. Entre 1920 y 1950 hay pocos datos; allí el ajuste se vuelve casi lineal por tramos y las bandas se ensanchan.

Para predecir en una malla que incluya todos los valores observados se utiliza `values`:

```
formula.year <- rent ~ -1 +
  f(year, model = "rw2", values = 1918:2001, constr = FALSE)
result.year <- inla(formula.year, data = Munich)
```

Otra posibilidad consiste en añadir casos con respuesta ausente:

```
x.new <- c(1925, 1938, 1945)
data.pred <- list(y = c(Munich$rent, rep(NA, length(x.new))),
  x = c(Munich$year, x.new))
formula.pred <- y ~ -1 + f(x, model = "rw2", constr = FALSE)
result.pred <- inla(formula.pred, data = data.pred,
  control.predictor = list(compute = TRUE))
```

Las distribuciones así obtenidas corresponden a la media del alquiler. Un intervalo predictivo para una observación nueva debe incorporar además el error ε : se muestrea la precisión posterior con `inla.hyperpar.sample()`, se generan nuevos errores normales, se muestrea el predictor con `inla.rmarginal()` y se suman ambos componentes. Por ello esos intervalos son mucho más anchos que los intervalos creíbles del predictor lineal.

7.3. Splines de placa delgada

Con dos predictores,

$$y_i = f(x_{1i}, x_{2i}) + \varepsilon_i,$$

el *spline* de placa delgada minimiza la suma de cuadrados más $\lambda J_2(f)$, donde

$$J_2(f) = \iint \left[\left(\frac{\partial^2 f}{\partial x_1^2} \right)^2 + 2 \left(\frac{\partial^2 f}{\partial x_1 \partial x_2} \right)^2 + \left(\frac{\partial^2 f}{\partial x_2^2} \right)^2 \right] dx_1 dx_2. \quad (7.6)$$

La penalización es invariante ante rotaciones y traslaciones, y vale cero únicamente para funciones lineales en x_1, x_2 . Mecánicamente, es proporcional a la energía de flexión de una placa elástica infinita que interpola los puntos.

7.3.1. Retículas regulares

En una retícula $n_1 \times n_2$, se aplican diferencias segundas en ambas direcciones y una diferencia cruzada. El prior RW2D resultante tiene precisión

$$\mathbf{Q} = \mathbf{I}_{n_2} \otimes \mathbf{B}_2 + \mathbf{B}_2 \otimes \mathbf{I}_{n_1} + 2\mathbf{B}_1 \otimes \mathbf{B}_1, \quad (7.7)$$

con $\mathbf{B}_k = \mathbf{D}_k^T \mathbf{D}_k$. Es una matriz dispersa de rango $n_1 n_2 - 3$. Cada valor interior depende condicionalmente de doce vecinos. La dispersión es crucial porque la dimensión crece con rapidez.

```
## Ejemplo esquemático en una retícula regular
formula.rw2d <- y ~ -1 + f(index, model = "rw2d",
                           nrow = nrow, ncol = ncol,
                           constr = FALSE)
```

7.3.2. Ubicaciones irregulares

En localizaciones dispersas se construye una triangulación y una aproximación por elementos finitos. La función `bri.tps.prior()` crea el prior de placa delgada a partir de una malla INLA. El ejemplo SPDEtoy ilustra el procedimiento:

```
data(SPDEtoy, package = "brinla")
coords <- cbind(SPDEtoy$x, SPDEtoy$z)
mesh <- inla.mesh.2d(coords, max.edge = c(0.15, 0.2), cutoff = 0.02)
tps <- bri.tps.prior(mesh)
data.inla <- list(y = SPDEtoy$y, x = mesh$idix$loc)
result <- inla(y ~ -1 + f(x, model = tps), data = data.inla)
```

La predicción conjunta en puntos nuevos se realiza incorporándolos a la malla y anteponiendo valores NA a la respuesta. Los resúmenes están en `summary.fitted.values`; las marginales permiten calcular intervalos de máxima densidad posterior con `inla.hpdmarginal()`.

7.4. Modelo espacial de Besag

En datos de área, dos regiones son vecinas si comparten frontera —aunque pueden emplearse otras definiciones—. Para regiones i y j vecinas,

$$f(x_i) - f(x_j) \sim N(0, \sigma_f^2/w_{ij}),$$

con pesos positivos y simétricos. La precisión tiene entradas

$$Q_{ij} = \begin{cases} w_{i+}, & i = j, \\ -w_{ij}, & i \sim j, \\ 0, & \text{en otro caso,} \end{cases}$$

donde w_{i+} suma los pesos de los vecinos. Como cada fila suma cero, el rango es $n - 1$. La media condicional de una región es el promedio ponderado de sus vecinos. Es un caso particular del modelo autorregresivo intrínseco de Besag.

En Múnich, el efecto espacial del distrito se ajusta así:

```
g <- system.file("demodata/munich.graph", package = "INLA")
g.file <- inla.read.graph(g)
formula <- rent ~ 1 + f(location, model = "besag", graph = g.file)
result <- inla(formula, data = Munich,
               control.predictor = list(compute = TRUE))
```

El grafo contiene los 380 nodos, el número de vecinos y sus índices. Los alquileres estimados son altos en el centro, junto al río Isar y cerca de parques; aparecen efectos negativos en distritos periféricos, donde también suele ser mayor la incertidumbre.

7.5. Splines de regresión penalizados (P-splines)

Un P-spline aproxima

$$f(x) = \sum_{j=1}^p \beta_j B_j(x)$$

mediante bases B-spline y penaliza diferencias de orden m entre coeficientes adyacentes:

$$\sum_{i=1}^n \left[y_i - \sum_{j=1}^p \beta_j B_j(x_i) \right]^2 + \lambda \sum_{j=m+1}^p (\nabla^m \beta_j)^2. \quad (7.12)$$

Su representación bayesiana es

$$\mathbf{y} \mid \beta, \sigma_\varepsilon^2 \sim N(\mathbf{B}\beta, \sigma_\varepsilon^2 \mathbf{I}), \quad \beta \mid \sigma_\beta^2 \sim N(\mathbf{0}, \sigma_\beta^2 \mathbf{Q}_m^-), \quad (7.13)$$

con $\lambda = \sigma_\varepsilon^2 / \sigma_\beta^2$. A diferencia del *spline* de suavizado, se usan muchas menos bases que observaciones; pueden incluirse suficientes nudos para asegurar flexibilidad y dejar que la penalización evite el sobreajuste.

```
library(splines)
p <- 25
B.tmp <- bs(x, df = p, intercept = TRUE)
attributes(B.tmp) <- NULL
Bmat <- as(matrix(B.tmp, n, p), "sparseMatrix")
data.inla <- list(y = y, x = 1:p)
formula <- y ~ -1 + f(x, model = "rw2", constr = FALSE)
result <- inla(formula, data = data.inla,
               control.predictor = list(A = Bmat, compute = TRUE))
```

Con penalización RW1, aumentar de 25 a 80 grados de libertad puede producir sobreajuste. RW2 da curvas más suaves y menos sensibles al número de nudos, aunque puede suavizar en exceso los extremos.

7.6. Suavizado adaptativo con *splines*

Una única λ aplica igual suavizado en todo el dominio y puede funcionar mal ante picos, saltos o cambios frecuentes de curvatura. El modelo adaptativo sustituye el parámetro por una función positiva:

$$\lambda(x) \frac{d^2 f(x)}{dx^2} = \frac{dW(x)}{dx}. \quad (7.14)$$

Valores pequeños permiten oscilaciones rápidas; valores grandes estiran la función y reducen la rugosidad. Se modela $v(x) = \log \lambda(x)$ mediante bases B-spline,

$$v(x) = \sum_{k=1}^q \gamma_k B_k(x),$$

y se asigna a γ un prior gaussiano propio. Una precisión identidad es sencilla pero sensible a los nudos; un prior SPDE disperso ofrece estimaciones más precisas y estables.

```
adapt <- bri.adapt.prior(x, nknot = 5, type = "spde")
data.inla <- list(y = y, x = adapt$x.ind)
result <- inla(y ~ -1 + f(x, model = adapt), data = data.inla)
```

En el ejemplo simulado, el ajuste adaptativo mejora globalmente a los *splines* de suavizado y P-splines. El prior SPDE es menos sensible que el independiente a elegir cinco o diez nudos.

7.7. Regresión no paramétrica generalizada

Si Y_i pertenece a la familia exponencial y $\mu_i = E(Y_i)$, el modelo

$$g(\mu_i) = f(x_i)$$

combina GLM y suavizado no paramétrico. Un prior gaussiano para f conserva la estructura gaussiana latente requerida por INLA.

7.7.1. Respuestas binomial y Poisson

Se simula $f(x) = \sin x$ para 200 puntos en $[0, 6]$. Para respuestas binomiales pueden usarse enlaces logit, probit o log-log complementario:

```
set.seed(2)
n <- 200
x <- seq(0, 6, length.out = n)
eta <- sin(x)
Ntrials <- sample(c(1, 5, 10, 15), n, replace = TRUE)
prob <- exp(eta) / (1 + exp(eta))
y <- rbinom(n, Ntrials, prob)
formula <- y ~ -1 + f(x, model = "rw2", constr = FALSE)
result <- inla(formula, family = "binomial", data = list(y = y, x = x),
               Ntrials = Ntrials,
               control.predictor = list(compute = TRUE),
               control.family = list(link = "logit"))
```

Para Poisson con exposición conocida E_i ,

$$Y_i \sim \text{Poisson}(\Lambda_i), \quad \log \Lambda_i = \log E_i + \sin(x_i),$$

se pasa $E = E$ a `inla()`. Si las exposiciones no valen uno, `summary.fitted.values` resume $\exp\{f(x_i)\}$; sus medias, desviaciones y cuantiles deben multiplicarse por E_i para obtener Λ_i .

7.7.2. Precipitación en Tokio

Los datos Tokyo registran lluvia diaria durante dos años. Para el 29 de febrero hay una sola observación; los demás días tienen dos. Se modela el número de días lluviosos como binomial y el logit de su probabilidad mediante una RW2 circular, que conecta el final de diciembre con el comienzo de enero:

```
data(Tokyo, package = "INLA")
formula <- y ~ -1 + f(time, model = "rw2", cyclic = TRUE,
                      constr = FALSE)
result <- inla(formula, family = "binomial", Ntrials = n,
               data = Tokyo, control.predictor = list(compute = TRUE))
```

La probabilidad diaria típica no supera 0.5 y es relativamente elevada en abril, junio y agosto. Para predecir los primeros tres días de 1985 se añaden respuestas NA, se extienden time y n, y se usa control.predictor = list(compute = TRUE, link = 1).

7.8. Conjuntos de excursión con incertidumbre

Para localizar dónde $f(x)$ supera un nivel u , es común definir

$$D_m = \{x : P(f(x) > u \mid \mathbf{y}) > 1 - \alpha\}. \quad (7.15)$$

Pero α es un error puntual y no controla la probabilidad simultánea sobre todo el conjunto. Un conjunto de excursión D exige

$$P\{f(x) > u \text{ para todo } x \in D \mid \mathbf{y}\} \geq 1 - \alpha.$$

Su cálculo requiere integración de alta dimensión. El método de Bolin y Lindgren combina una familia paramétrica de conjuntos con muestreo de importancia secuencial.

7.8.1. Datos fósiles

Los datos contienen 106 conchas fósiles, su edad en millones de años y la razón de isótopos de estroncio. Como algunas edades se repiten y el espaciado es irregular, se agrupan en 100 intervalos y se usa RW2 escalado:

```
data(fossil, package = "brinla")
age.new <- inla.group(fossil$age, n = 100)
inla.data <- list(y = fossil$sr, x = age.new)
formula <- y ~ -1 + f(x, model = "rw2", constr = FALSE,
                    scale.model = TRUE)
result <- inla(formula, data = inla.data,
               control.compute = list(config = TRUE))
```

La curva revela variaciones importantes; una depresión alrededor de 98 millones de años no es concluyente porque su intervalo es ancho. Las probabilidades marginales de superar 0.74 se calculan con `inla.pmarginal()`, pero no son simultáneas. El conjunto de excursión al 95 % se obtiene con:

```
res.exc <- excursions.brinla(result, name = "x", u = 0.74,  
                             alpha = 0.05, type = ">", method = "NI")  
res.exc$E
```

El conjunto es menor que el basado en probabilidades marginales. La función de excursión `res.exc$F`, entre cero y uno, ofrece una medida simultánea análoga en espíritu a las probabilidades puntuales; siempre queda por debajo de ellas.

En los datos de Tokio interesa hallar días cuya probabilidad de lluvia exceda 0.3 simultáneamente. Como el campo latente está en escala logit, se transforma el umbral y, por tratarse de datos no gaussianos, se usa NIQC:

```
u.pred <- log(0.3 / (1 - 0.3))  
res.exc <- excursions.brinla(result, name = "time", u = u.pred,  
                             type = ">", method = "NIQC", alpha = 0.05)
```

El análisis marginal selecciona 32 días consecutivos entre mayo y junio; el requisito conjunto al 95 % conserva 28. Esta diferencia ilustra por qué una colección de afirmaciones puntuales no equivale a una afirmación simultánea sobre toda una región.

8 Regresión con procesos gaussianos

La regresión con procesos gaussianos (GPR) asigna un prior de proceso gaussiano a la función que relaciona los predictores con la respuesta. Puede implementarse con INLA, aunque es necesario elegir representaciones que conserven la eficiencia computacional.

8.1. Introducción

Considérese

$$y_i = f(x_i) + \varepsilon_i, \quad i = 1, \dots, n,$$

y el prior

$$f(x) \sim GP\{m(x), k(x, x')\}.$$

Cualquier colección finita de valores de f tiene una distribución gaussiana conjunta con media m y covarianza k . Esto parece encajar inmediatamente en un modelo gaussiano latente, pero surgen dos dificultades: interesa estimar f también fuera de los puntos observados y, para muchas covarianzas, la matriz de precisión es densa. En problemas medianos o grandes se necesitan covarianzas que permitan una precisión dispersa.

La solución procede de la ecuación diferencial parcial estocástica (SPDE)

$$(\kappa^2 - \Delta)^{\alpha/2} \{\tau f(x)\} = W(x), \quad x \in \mathbb{R}^d, \quad (8.1)$$

donde κ es un parámetro de escala, Δ el laplaciano, α controla la suavidad, τ se relaciona con la varianza y W es ruido blanco gaussiano. Su solución estacionaria posee covarianza Matérn, con $\nu = \alpha - d/2$. INLA usa habitualmente $\alpha = 2$; los valores disponibles $0 < \alpha \leq 2$ permiten aproximaciones dispersas. El límite de núcleo gaussiano, de soporte no acotado, conduce a una precisión densa y no resulta práctico aquí.

La solución se aproxima mediante

$$f(x) = \sum_{k=1}^b \beta_k B_k(x),$$

con bases locales de soporte compacto y coeficientes determinados por elementos finitos. b debe ser suficientemente grande para representar la curva, pero no tanto que desperdicie cálculo.

Es preferible expresar el prior mediante la desviación estándar marginal σ y el alcance ρ , distancia a la que la correlación cae aproximadamente a 0.13. Ambos se relacionan con τ y κ ; se pueden especificar valores centrales σ_0, ρ_0 y perturbaciones gaussianas en escala logarítmica:

$$\log \sigma = \log \sigma_0 + \theta_1, \quad \log \rho = \log \rho_0 + \theta_2. \quad (8.2)$$

8.1.1. Ejemplo de isótopos en fósiles

Los datos registran la razón de isótopos de estroncio en conchas fósiles del Cretácico medio, entre aproximadamente 90 y 125 millones de años. La razón se reescala para facilitar su lectura.

```
library(INLA)
library(brinla)
data(fossil, package = "brinla")
fossil$sr <- (fossil$sr - 0.7) * 100
```

El ajuste SPDE se construye por etapas. Primero se crea una malla unidimensional de 25 bases cuadráticas:

```
nbasis <- 25
mesh <- inla.mesh.1d(
  seq(min(fossil$age), max(fossil$age), length.out = nbasis),
  degree = 2
)
```

El grado dos produce una curva más suave que los grados cero o uno. Aquí el número de bases determina la flexibilidad disponible, no el grado efectivo de suavizado, que depende sobre todo de ρ .

```
alpha <- 2
nu <- alpha - 1/2
sigma0 <- sd(fossil$sr)
rho0 <- 0.25 * diff(range(fossil$age))
kappa0 <- sqrt(8 * nu) / rho0
tau0 <- sqrt(1 / (4 * kappa0^3 * sigma0^2))

spde <- inla.spde2.matern(
  mesh, alpha = alpha,
  B.tau = cbind(log(tau0), 1, 0),
  B.kappa = cbind(log(kappa0), 0, 1),
  theta.prior.prec = 1e-4
)
```

`B.tau` y `B.kappa` definen modelos lineales para $\log \tau$ y $\log \kappa$; `theta.prior.prec` fija la precisión gaussiana de sus perturbaciones. Se han utilizado valores iniciales derivados de los datos, aunque el conocimiento experto debe prevalecer cuando esté disponible.

La matriz A proyecta la representación de la malla sobre los lugares donde se desean posteriores. El índice y la pila mantienen alineados datos, efectos y proyección:

```
A <- inla.spde.make.A(mesh, loc = fossil$age)
index <- inla.spde.make.index("sinc", n.spde = spde$n.spde)
st.est <- inla.stack(
  data = list(y = fossil$sr), A = list(A),
  effects = list(index), tag = "est"
)

formula <- y ~ -1 + f(sinc, model = spde)
result <- inla(
  formula, data = inla.stack.data(st.est), family = "gaussian",
  control.predictor = list(A = inla.stack.A(st.est), compute = TRUE)
)
```

El intercepto se excluye por redundancia. Los índices de `inla.stack.index()` permiten extraer la media posterior y las bandas creíbles de `summary.fitted.values`. Las bandas se ensanchan donde escasean los datos. `bri.gpr(fossil$age, fossil$sr)` reúne estos pasos, pero conocer la construcción completa permite modificar la malla y los priors.

8.2. Priors de complejidad penalizada

Los priors PC proporcionan una manera interpretable y coherente de regularizar el modelo (Simpson et al. 2017). Se especifican mediante

$$P(\rho < \rho_0) = p_\rho, \quad P(\sigma > \sigma_0) = p_\sigma.$$

ρ_0 representa un alcance sorprendentemente corto y σ_0 una variabilidad sorprendentemente grande. Las probabilidades pequeñas no fijan esos valores como destino del posterior: expresan información débil sobre escalas plausibles.

Para los fósiles puede establecerse $P(\rho < 5) = 0.05$ y $P(\sigma > 2) = 0.05$:

```
spde.pc <- inla.spde2.pcmatern(
  mesh, alpha = alpha,
  prior.range = c(5, 0.05),
  prior.sigma = c(2, 0.05)
)

formula.pc <- y ~ -1 + f(sinc, model = spde.pc)
result.pc <- inla(
  formula.pc, data = inla.stack.data(st.est), family = "gaussian",
  control.predictor = list(A = inla.stack.A(st.est), compute = TRUE)
)
```

El ajuste es muy parecido al anterior. En `brinla`, la llamada abreviada es `bri.gpr(fossil$age, fossil$sr, pcprior = c(5, 2))`.

8.3. Bandas creíbles para la suavidad

Las bandas creíbles puntuales describen la posición de la curva, pero no responden directamente si una ondulación es real: dentro de ellas caben funciones de suavidades muy diferentes. En GPR, el posterior de ρ cuantifica precisamente esa incertidumbre.

```
error.sd <- bri.hyper.sd(result$marginals.hyperpar[[1]])
mres <- inla.spde.result(result, "sinc", spde)
sigma.marg <- inla.tmarginal(
  function(x) sqrt(x), mres$marginals.variance.nominal[[1]]
)
rho.marg <- mres$marginals.range.nominal[[1]]
```

En el ejemplo, la incertidumbre sobre el error de medición es pequeña, pero la del alcance es considerable. Para visualizar su efecto, se fija σ en su mediana posterior y se reajusta el modelo con los extremos del intervalo creíble de ρ (equivalentemente, los extremos correspondientes de κ). Las dos medias posteriores forman una banda de suavidad: una representa el extremo rugoso y otra el suave.

Ambas curvas muestran una depresión cerca de 97 millones de años, aunque es más marcada en el extremo rugoso. La conclusión sobre su existencia es por tanto más sólida que la sugerida por una sola curva. `bri.smoothband()` automatiza el cálculo. Estas bandas hablan de la *forma* de f , no de su valor en un punto; para esto último siguen siendo necesarias las bandas creíbles ordinarias.

8.4. Campos no estacionarios

Una función puede variar en amplitud y suavidad a lo largo del dominio. La extensión no estacionaria escribe

$$\log \tau(x) = \gamma_\tau^\top \mathbf{b}_\tau(x), \quad \log \kappa(x) = \gamma_\kappa^\top \mathbf{b}_\kappa(x),$$

con bases que pueden compartir o no coeficientes. Para demostrarlo se usa la función de suavidad variable $\sin^3(6\pi x)$ con ruido normal.

Un ajuste estacionario es demasiado rugoso en la parte plana y demasiado suave donde la curva cambia de prisa. Se introducen cinco bases B-spline para cada parámetro:

```
basis.T <- as.matrix(inla.mesh.basis(mesh, type = "b.spline",
                                   n = 5, degree = 2))
basis.K <- as.matrix(inla.mesh.basis(mesh, type = "b.spline",
                                   n = 5, degree = 2))
spde.ns <- inla.spde2.matern(
  mesh, alpha = alpha,
  B.tau = cbind(basis.T[-1, ], 0),
  B.kappa = cbind(0, basis.K[-1, ] / 2),
  theta.prior.prec = 1e-4
)
```

Los ceros asignan conjuntos separados de parámetros; la división entre dos ajusta la parametrización interna de κ . El campo no estacionario sigue la región plana y a la vez recupera máximos, mínimos e inflexiones. `bri.nonstat()` ofrece una interfaz abreviada.

8.5. Interpolación con incertidumbre

Si se observan pares $(x_i, f(x_i))$ prácticamente sin error, todavía existe incertidumbre entre los puntos. Esto ocurre, por ejemplo, cuando evaluar f requiere simulaciones informáticas costosas. GPR permite cuantificarla llevando la varianza de observación casi a cero.

```
x <- c(0, 0.1, 0.2, 0.3, 0.7, 1.0)
y <- c(0, 0.5, 0, -0.5, 1, 0)
td <- data.frame(x, y)

nbasis <- 100
mesh <- inla.mesh.1d(seq(0, 1, length.out = nbasis), degree = 2)
spde <- inla.spde2.pcmatern(
  mesh, alpha = 2,
  prior.range = c(0.05, 0.1), prior.sigma = c(5, 0.05)
)
A <- inla.spde.make.A(mesh, loc = td$x)
Ap <- inla.spde.make.A(mesh, loc = seq(0, 1, length.out = 101))
index <- inla.spde.make.index("sinc", n.spde = spde$n.spde)

st.est <- inla.stack(data = list(y = td$y), A = list(A),
  effects = list(index), tag = "est")
st.pred <- inla.stack(data = list(y = NA), A = list(Ap),
  effects = list(index), tag = "pred")
stack.all <- inla.stack(st.est, st.pred)
```

La precisión del error se fija en 10^8 :

```
formula <- y ~ -1 + f(sinc, model = spde)
result <- inla(
  formula, data = inla.stack.data(stack.all), family = "gaussian",
  control.predictor = list(A = inla.stack.A(stack.all), compute = TRUE),
  control.family = list(
    hyper = list(prec = list(fixed = TRUE, initial = 1e8))
  )
)
```

La curva pasa prácticamente por las seis observaciones, pero las bandas se abren entre ellas. Puede extraerse la marginal en cualquier punto de la malla, por ejemplo $x = 0.5$. Con tan pocos datos, la elección de α afecta mucho el resultado; cambios moderados de los priors de alcance y desviación suelen afectar menos.

También aquí pueden trazarse los ajustes asociados con los extremos del intervalo posterior de ρ . La representación rugosa pierde pronto la correlación entre puntos separados y retorna hacia un nivel constante; la representación del extremo superior es más suave. Esta vista complementa las bandas puntuales: una describe incertidumbre sobre la posición, la otra sobre la suavidad.

8.6. Respuesta de supervivencia

GPR puede incorporarse al predictor lineal de distribuciones no gaussianas. En un modelo de tiempo de falla acelerado Weibull se sustituye la relación paramétrica por

$$\log \lambda = f(x),$$

donde λ es la tasa. Pueden añadirse términos paramétricos u otros procesos para más covariables.

En los datos de cáncer de laringe se modela el tiempo de supervivencia únicamente mediante la edad:

```
data(larynx, package = "brinla")
xspat <- larynx$age
mesh <- inla.mesh.1d(
  seq(min(xspat), max(xspat), length.out = 25), degree = 2
)
spde <- inla.spde2.pcmatern(
  mesh, alpha = 2,
  prior.range = c(20, 0.1), prior.sigma = c(10, 0.05)
)
A <- inla.spde.make.A(mesh, loc = xspat)
index <- inla.spde.make.index("sinc", n.spde = spde$n.spde)
st.est <- inla.stack(
  data = list(time = larynx$time, censor = larynx$delta),
  A = list(A), effects = list(index), tag = "est"
)

formula <- inla.surv(time, censor) ~ 0 + f(sinc, model = spde)
result <- inla(
  formula, data = inla.stack.data(st.est), family = "weibull.surv",
  control.predictor = list(A = inla.stack.A(st.est), compute = TRUE)
)
```

La forma Weibull es un hiperparámetro. Junto con $\lambda = \exp(\eta)$ permite transformar el predictor en supervivencia media y riesgo, propagando sus cuantiles para obtener bandas creíbles. El riesgo crece con la edad y no aparece evidencia fuerte de no linealidad, de modo que el término lineal usado en el modelo paramétrico del capítulo 6 resulta razonable.

9 Modelos aditivos y aditivos generalizados

Los suavizadores del capítulo 7 pueden extenderse a más dimensiones, pero la varianza de los estimadores no paramétricos crece con rapidez con el número de predictores: la llamada maldición de la dimensionalidad. Imponer estructura puede introducir sesgo, pero reducir drásticamente la varianza. La estructura más utilizada es la aditiva.

9.1. Modelos aditivos

La regresión lineal

$$y_i = \beta_0 + \sum_{j=1}^p \beta_j x_{ij} + \varepsilon_i$$

puede flexibilizarse mediante transformaciones, aunque la cantidad de términos crece, especialmente al incluir interacciones. En el otro extremo, estimar una sola función $f(x_{i1}, \dots, x_{ip})$ es impráctico para $p > 2$. El compromiso aditivo es

$$y_i = \beta_0 + \sum_{j=1}^p f_j(x_{ij}) + \varepsilon_i. \quad (9.1)$$

Cada f_j puede ser paramétrica o una función suave desconocida. El modelo sigue siendo interpretable porque sus efectos marginales se pueden representar; las variables categóricas entran como en regresión ordinaria. Si hay interacciones fuertes, deben añadirse términos $f_{jk}(x_j, x_k)$ o curvas distintas por nivel de un factor.

Frecuentemente se ajustan estos modelos mediante *backfitting* o bases spline con verosimilitud penalizada. En la versión bayesiana, $\varepsilon_i \sim N(0, \sigma^2)$ y cada f_j recibe un prior suave $p(f_j \mid \tau_j)$. El MCMC con *backfitting* puede mezclar lentamente porque la actualización de cada función depende de las demás. Con priors gaussianos de precisión dispersa, el modelo es gaussiano latente e INLA ofrece una alternativa eficiente.

9.1.1. Datos simulados

El ejemplo de Gu y Wahba genera 400 observaciones, cuatro predictores en $[0, 1]$ y ruido normal de desviación estándar 2:

```

library(INLA)
library(brinla)
library(mgcv)
set.seed(2)
dat <- gamSim(1, n = 400, dist = "normal", scale = 2)

n.group <- 50
dat.inla <- list(
  y = dat$y,
  x0 = inla.group(dat$x0, n = n.group, method = "quantile"),
  x1 = inla.group(dat$x1, n = n.group, method = "quantile"),
  x2 = inla.group(dat$x2, n = n.group, method = "quantile"),
  x3 = inla.group(dat$x3, n = n.group, method = "quantile")
)

formula <- y ~
  f(x0, model = "rw2", scale.model = TRUE) +
  f(x1, model = "rw2", scale.model = TRUE) +
  f(x2, model = "rw2", scale.model = TRUE) +
  f(x3, model = "rw2", scale.model = TRUE)
result <- inla(formula, data = dat.inla)

```

Se agrupan valores demasiado próximos y se escalan los cuatro priors RW2. La restricción predefinida de suma cero identifica las funciones frente al intercepto; por ello, al comparar con la verdad, también deben centrarse las funciones verdaderas. Los cuatro ajustes recuperan bien sus formas. La desviación posterior del ruido queda cerca de 2.

9.1.2. Guía de alquileres de Múnich

Los análisis separados del capítulo 7 se combinan ahora con indicadores de calidad y número de habitaciones. El modelo incluye un efecto espacial Besag para el distrito, RW2 para año y superficie y coeficientes lineales para las variables categóricas. Se omite el intercepto porque los indicadores de habitaciones actúan como niveles de referencia.

```

data(Munich, package = "brinla")
g <- system.file("demodata/munich.graph", package = "INLA")

formula <- rent ~
  f(location, model = "besag", graph = g, scale.model = TRUE) +
  f(year, model = "rw2", values = 1918:2001, scale.model = TRUE) +
  f(floor.size, model = "rw2", values = 17:185, scale.model = TRUE) +
  Gute.Wohnlage + Beste.Wohnlage + Keine.Wwv + Keine.Zh +
  Kein.Badkach + Besond.Bad + Gehobene.Kueche +
  zim1 + zim2 + zim3 + zim4 + zim5 + zim6 - 1

```

```
result <- inla(formula, data = Munich,
               control.predictor = list(compute = TRUE))
```

Todos los coeficientes categóricos tienen intervalos creíbles al 95 % que excluyen cero. El efecto de la superficie disminuye hasta unos 50 m² y después se estabiliza; el año muestra una forma en U entre 1920 y 1960 y luego aumenta. Los alquileres son mayores en las regiones centrales, mientras que la incertidumbre espacial es mayor en la periferia.

El gráfico de residuos frente al ajuste no presenta un patrón sistemático, aunque el modelo sobreestima ligeramente alquileres bajos y subestima los altos. La asimetría a la derecha de la respuesta hace imperfecta la suposición normal, pero el ajuste global es razonable.

9.2. Modelos aditivos generalizados

Si Y_i pertenece a la familia exponencial, con $E(Y_i) = \mu_i$, un GAM adopta la forma

$$g(\mu_i) = \eta_i = \beta_0 + \sum_{j=1}^p f_j(x_{ij}). \quad (9.3)$$

Así se combinan GLM y modelos aditivos. En INLA basta incorporar la aproximación de Laplace para la verosimilitud no gaussiana.

9.2.1. Respuesta binaria: cifosis

Los datos corresponden a 83 pacientes pediátricos sometidos a cirugía vertebral. La respuesta indica presencia de cifosis; los predictores son edad en meses, vértebra inicial y número de niveles intervenidos. Primero se permite que los tres efectos sean no paramétricos:

$$\text{logit}(p_i) = \beta_0 + f_1(\text{Age}_i) + f_2(\text{StartVert}_i) + f_3(\text{NumVert}_i). \quad (9.4)$$

```
data(kyphosis, package = "brinla")
formula1 <- Kyphosis ~ 1 +
  f(Age, model = "rw2") +
  f(StartVert, model = "rw2") +
  f(NumVert, model = "rw2")
result1 <- inla(
  formula1, family = "binomial", data = kyphosis,
  control.predictor = list(compute = TRUE),
  control.compute = list(waic = TRUE)
)
```

El riesgo aumenta con la edad hasta aproximadamente 120 meses y luego disminuye; las bandas se ensanchan mucho después de 200 meses por falta de observaciones. `StartVert` y `NumVert` muestran patrones esencialmente lineales. El GAM sugiere por tanto el modelo más simple

$$\eta_i = \beta_0 + \beta_1 \text{StartVert}_i + \beta_2 \text{NumVert}_i + \beta_3 \text{Age}_i + \beta_4 \text{Age}_i^2. \quad (9.5)$$

```
kyphosis$AgeSq <- kyphosis$Age^2
formula2 <- Kyphosis ~ StartVert + NumVert + Age + AgeSq
result2 <- inla(
  formula2, family = "binomial", data = kyphosis,
  control.predictor = list(compute = TRUE),
  control.compute = list(waic = TRUE)
)
```

Al controlar la edad, una vértebra inicial mayor reduce el riesgo y más vértebras intervenidas lo aumentan. Ambos términos de edad son distintos de cero. Los WAIC son aproximadamente 65.92 para el GAM y 65.47 para el cuadrático: la sencillez del modelo paramétrico compensa su pequeña pérdida de flexibilidad, pero fue el GAM el que reveló su forma.

9.2.2. Respuesta de conteo: huevos de caballa

El levantamiento de 1992 contiene 634 muestras de huevos, sus coordenadas, área de red, salinidad, temperatura a 20 m y distancia al contorno submarino de 200 m. Se modela

$$Y_i \sim \text{Poisson}(\lambda_i),$$

$$\log \lambda_i = \log(\text{net.area}_i) + \beta_1 \text{salinity}_i + \beta_2 \text{c.dist}_i + f_1(\text{temp.20m}_i) + f_2(\text{lon}_i, \text{lat}_i). \quad (9.6)$$

f_1 usa RW2 y f_2 un prior de placa delgada sobre una triangulación:

```
data(mack, package = "gamair")
loc.obs <- cbind(mack$lon, mack$lat)
mesh <- inla.mesh.2d(loc.obs, cutoff = 0.05, max.edge = c(0.5, 1))
tps <- bri.tps.prior(mesh)
node <- mesh$idx$loc

formula <- egg.count ~ -1 + salinity + c.dist +
  f(temp.20m, model = "rw2") +
  f(node, model = tps, diagonal = 1e-6)
result <- inla(formula, family = "poisson", data = mack,
  offset = log(net.area))
```

La salinidad tiene efecto positivo; el intervalo de `c.dist` contiene cero. La temperatura produce un patrón complejo: ascenso lento hasta unos 14.5 °C, descenso acusado hasta 16 °C, nuevo ascenso y caída final.

Para predecir sobre la cuadrícula `mackp`, se unen sus covariables y ubicaciones a las observadas, se añaden respuestas NA, se reconstruyen `mapla` y `prior` y se indica el enlace para los casos ausentes:

```
link <- rep(NA, length(y.pre))
link[is.na(y.pre)] <- 1
result.pred <- inla(
  formula, family = "poisson", data = mack.pre, offset = log(E.pre),
  control.predictor = list(link = link, compute = TRUE),
  control.compute = list(config = TRUE)
)
```

La abundancia predicha es alta en el borde occidental y baja en el sudeste; la semejanza con el mapa espacial indica que la localización domina a las otras covariables. Para localizar celdas con al menos 10 huevos y probabilidad conjunta 0.95 se usa el umbral en escala logarítmica:

```
res.exc <- excursions.brinla(
  result.pred, name = "Predictor", ind = idx.pre,
  u = log(10), type = ">", alpha = 0.05, method = "NIQC"
)
```

9.3. Modelos aditivos generalizados mixtos

Un GAMM añade a un GAM efectos aleatorios que representan agrupamiento o jerarquías:

$$g(\mu_i) = \beta_0 + \sum_j f_j(x_{ij}) + \sum_k g_k(u_{ik}). \quad (9.7)$$

Con priors gaussianos en todos los componentes, sigue siendo un modelo gaussiano latente.

9.3.1. Huevos de lenguado en el canal de Bristol

Se midió la densidad de huevos en cuatro etapas de desarrollo, en estaciones visitadas durante cinco campañas. Las coordenadas son `lo` y `la`, `t` es el tiempo de la campaña, `a.0` y `a.1` delimitan la edad del huevo. Se usa la amplitud de la clase como *offset* y su edad media como predictor:

```
data(sole, package = "gamair")
solr <- sole
solr$off <- log(solr$a.1 - solr$a.0)
solr$a <- (solr$a.1 + solr$a.0) / 2
solr$t <- (solr$t - mean(solr$t)) / sqrt(var(solr$t))
solr$la <- solr$la - mean(solr$la)
```

```

solr$lo <- solr$lo - mean(solr$lo)
solr$station <- as.numeric(factor(with(solr, paste(la, lo, t))))
solr$eggs <- solr$eggs * 1000
solr$off <- solr$off + log(1000)

```

Más del 76 % de las respuestas son cero. Se usa una binomial negativa inflada en cero, con términos lineales de edad, interacciones espacio-tiempo polinómicas, RW2 para el tiempo, placa delgada espacial y efecto iid de estación:

```

loc <- cbind(solr$lo, solr$la)
mesh <- inla.mesh.2d(loc, max.edge = c(0.1, 0.2))
tps <- bri.tps.prior(mesh, constr = TRUE)
node <- mesh$idx$loc

formula1 <- eggs ~ a + I(la * t) + I(la * t^2) +
  I(lo * t) + I(lo * t^2) +
  f(t, a, model = "rw2", scale.model = TRUE) +
  f(node, model = tps, diagonal = 1e-6) +
  f(station, model = "iid")

result <- inla(
  formula1, family = "zeroinflatednbinomial0",
  offset = off, data = solr,
  control.predictor = list(compute = TRUE),
  control.compute = list(dic = TRUE, waic = TRUE, cpo = TRUE)
)

```

Se comparan este GAMM, el mismo modelo sin estación y una versión Poisson inflada en cero. DIC y WAIC favorecen claramente la binomial negativa con efecto de estación, confirmando tanto agrupamiento como sobredispersión. La edad media tiene efecto negativo; latitud-tiempo interactúan positivamente y longitud-tiempo negativamente. El efecto temporal es cóncavo y el mapa muestra densidades elevadas en el sudeste. La probabilidad estructural de cero estimada, 0.761, coincide casi exactamente con la proporción observada.

Para diagnóstico se examina el CPO $p(y_i | \mathbf{y}_{-i})$. Los indicadores `result$cpo$failure` detectan aproximaciones dudosas; en el ejemplo hay 68 y se recalculan explícitamente:

```
improved.result <- inla.cpo(result)
```

La observación con menor CPO contiene 17 048 unidades en la primera etapa, frente a 319, 319 y 159 en las otras etapas de la misma estación. Es un caso genuinamente inusual que merece investigación sustantiva.

10 Regresión con error en las variables

Los modelos de regresión ordinarios suponen que los predictores se observan sin error. Cuando no es así, las estimaciones pueden ser sesgadas e inconsistentes y las conclusiones, erróneas. Los modelos de error en las variables incorporan explícitamente la incertidumbre de medición de los predictores.

10.1. Introducción

El problema aparece en numerosos campos: la ingesta habitual de grasas en epidemiología nutricional; las intensidades fluorescentes de microarreglos; la calibración entre laboratorios químicos; velocidades estelares con errores heteroscedásticos; y modelos de volatilidad estocástica en finanzas. Ignorar el error puede ocultar rasgos de los datos, reducir potencia y sesgar funciones y parámetros.

En el modelo de error clásico se observa una aproximación W al predictor latente X :

$$W_i = X_i + U_i,$$

con $E(U_i) = 0$ e independencia entre X_i y U_i , por lo que $E(W_i | X_i) = X_i$. En el error de Berkson, en cambio, el experimentador fija un objetivo W_i y el valor realmente alcanzado es

$$X_i = W_i + U_i.$$

La dirección condicionante es esencial.

Considérese el modelo lineal clásico

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \text{ y } W_i = X_i + U_i. \quad (10.1)$$

Al sustituir $X_i = W_i - U_i$, el error compuesto es $\eta_i = \varepsilon_i - \beta_1 U_i$ y está correlacionado con W_i . Si σ_X^2 y σ_U^2 son las varianzas, el límite del estimador ingenuo es

$$\text{plim } \hat{\beta}_1 = \beta_1 \frac{\sigma_X^2}{\sigma_X^2 + \sigma_U^2}.$$

Este sesgo de atenuación acerca la pendiente a cero. En regresión múltiple, un solo predictor contaminado puede sesgar todos los coeficientes.

10.2. Modelos con error clásico

Un GLMM general con un predictor latente adopta la forma

$$\mu_i = h(\eta_i), \quad \eta_i = \beta_0 + \beta_x X_i + \mathbf{x}_i^\top \alpha + \mathbf{z}_i^\top \gamma, \quad W_i = X_i + U_i. \quad (10.2)$$

h es la inversa del enlace, $\mathbf{x}_i$ contiene predictores sin error y γ efectos aleatorios. Sin el último término se obtiene un GLM con error de medición.

10.2.1. Modelo lineal sencillo con heterocedasticidad

Se completa el modelo con una distribución de exposición para el predictor:

$$\begin{aligned} Y_i &= \beta_0 + \beta_1 X_i + \varepsilon_i, & \varepsilon_i &\sim N(0, \sigma_\varepsilon^2), \\ W_i &= X_i + U_i, & U_i &\sim N(0, d_i \sigma_U^2), \\ X_i &= \lambda + \xi_i, & \xi_i &\sim N(0, \sigma_X^2). \end{aligned} \quad (10.3)$$

Los pesos conocidos d_i permiten errores heteroscedásticos. En INLA se utiliza `model = "mec"`, cuyos hiperparámetros representan β_1 , la precisión del error, la media de X y su precisión.

Se simulan 100 datos con $\beta_0 = 1$, $\beta_1 = 5$ y las tres precisiones iguales a uno:

```
library(INLA)
library(brinla)
set.seed(5)
n <- 100
x <- rnorm(n)
d <- runif(n, 0.5, 1.5)
w <- x + rnorm(n, sd = 1 / sqrt(d))
y <- 1 + 5 * x + rnorm(n)
sim.data <- data.frame(y, w, d)

naive <- inla(y ~ w, data = sim.data, family = "gaussian")
```

El modelo ingenuo estima una pendiente cercana a 2.28, cuyo intervalo creíble ni siquiera contiene el valor verdadero 5. Para corregirla se especifican priors e iniciales razonables —puede aprovecharse el ajuste ingenuo—:

```
prior.beta <- c(0, 0.0001)
prior.prec.u <- c(10, 10)
prior.prec.x <- c(10, 10)
prior.prec.y <- c(10, 10)
init.prec.u <- 1
init.prec.x <- 1 / (var(w) - 1)
init.prec.y <- naive$summary.hyperpar$mean
```

```

formula <- y ~ f(
  w, model = "mec", scale = d, values = w,
  hyper = list(
    beta = list(prior = "gaussian", param = prior.beta,
               fixed = FALSE),
    prec.u = list(prior = "loggamma", param = prior.prec.u,
                 initial = log(init.prec.u), fixed = FALSE),
    mean.x = list(prior = "gaussian", initial = 0, fixed = TRUE),
    prec.x = list(prior = "loggamma", param = prior.prec.x,
                 initial = log(init.prec.x), fixed = FALSE)
  )
)

corrected <- inla(
  formula, data = sim.data, family = "gaussian",
  control.family = list(hyper = list(
    prec = list(param = prior.prec.y,
               initial = log(init.prec.y), fixed = FALSE)
  )),
  control.fixed = list(mean.intercept = prior.beta[1],
                      prec.intercept = prior.beta[2])
)

```

`fixed` determina si se estima el hiperparámetro o se conserva su valor inicial. El ajuste corregido estima $\beta_1 \approx 5.15$, con intervalo aproximado (4.26, 6.12), y recupera bien el intercepto y las precisiones.

10.2.2. Modelo de exposición con mediciones replicadas

Si existen réplicas W_{ik} del mismo X_i ,

$$W_{ik} \mid X_i \sim N(X_i, \sigma_U^2),$$

y el modelo de exposición puede depender de covariables sin error:

$$X_i \mid \mathbf{x}_i \sim N(\lambda_0 + \mathbf{x}_i^\top \lambda, \sigma_X^2).$$

La representación jerárquica conjunta es

$$\begin{aligned}
 E(Y_i) &= h(\beta_0 + \beta_x X_i + \mathbf{x}_i^\top \alpha + \mathbf{z}_i^\top \gamma), \\
 W_{ik} &= X_i + U_{ik}, \\
 0 &= -X_i + \lambda_0 + \mathbf{x}_i^\top \lambda + \xi_i.
 \end{aligned} \tag{10.4}$$

10.2.2.1. Estudio de Framingham

Hay 1 615 hombres de 31 a 65 años y 128 casos de cardiopatía coronaria durante ocho años. Se usan edad, tabaquismo y presión sistólica transformada. Dos promedios de exámenes sucesivos son réplicas del nivel habitual latente:

```
data(framingham, package = "brinla")
fram <- subset(framingham, select = c(AGE, SMOKE, FIRSTCHD))
fram$W1 <- log((framingham$SBP21 + framingham$SBP22) / 2 - 50)
fram$W2 <- log((framingham$SBP31 + framingham$SBP32) / 2 - 50)
fram$W <- (fram$W1 + fram$W2) / 2
```

Edad y tabaquismo intervienen tanto en la regresión logística de la enfermedad como en el modelo de exposición. Se aumenta la respuesta a una matriz de tres columnas: Bernoulli para enfermedad, gaussiana para la pseudoobservación cero del modelo de exposición y gaussiana para las dos réplicas. La función `copy` garantiza que el mismo X_i se use en todos los componentes.

```
n <- nrow(fram)
Y <- matrix(NA, 4 * n, 3)
Y[1:n, 1] <- fram$FIRSTCHD
Y[n + 1:n, 2] <- 0
Y[2 * n + 1:n, 3] <- fram$W1
Y[3 * n + 1:n, 3] <- fram$W2

beta.x <- c(1:n, rep(NA, 3 * n))
idx.x <- c(rep(NA, n), rep(1:n, 3))
weight.x <- c(rep(1, n), rep(-1, n), rep(1, 2 * n))
```

La fórmula esencial contiene dos efectos especiales:

```
fram.formula <- Y ~
  f(beta.x, copy = "idx.x",
    hyper = list(beta = list(param = prior.beta, fixed = FALSE))) +
  f(idx.x, weight.x, model = "iid", values = 1:n,
    hyper = list(prec = list(initial = -15, fixed = TRUE))) +
  beta.0 - 1 + beta.smoke + beta.age +
  lambda.0 + lambda.smoke + lambda.age
```

La precisión casi nula fijada en el efecto iid evita duplicar la incertidumbre, pues ésta ya está descrita por el modelo de exposición. En la llamada a `inla()` se usa `family = c("binomial", "gaussian", "gaussian")` y una lista `control.family` en el mismo orden. `inla.hyperpar()` mejora la integración de los hiperparámetros, entre ellos el coeficiente del predictor contaminado.

El coeficiente corregido de presión sistólica transformada es aproximadamente 1.96, con intervalo (1.02, 2.90); manteniendo lo demás fijo, una unidad multiplica las *odds* de enfermedad por $\exp(1.96) \approx 7.08$. El modelo ingenuo produce 1.77, otra manifestación de la atenuación. Los efectos de edad y tabaquismo cambian muy poco.

10.3. Modelos con error de Berkson

El GLMM correspondiente es

$$\mu_i = h(\eta_i), \quad \eta_i = \beta_0 + \beta_x X_i + \mathbf{x}_i^T \alpha + \mathbf{z}_i^T \gamma, \quad \text{qqquad} X_i = W_i + U_i. \quad (10.5)$$

Aquí $X_i | W_i \sim N(W_i, d_i \sigma_U^2)$; al condicionar en el objetivo observado ya no corresponde un modelo de exposición. La forma jerárquica es

$$E(Y_i) = h(\eta_i), \quad -W_i = -X_i + U_i. \quad (10.6)$$

INLA la implementa mediante `model = "meb"`.

10.3.1. Bronquitis y exposición al polvo

Se estudió bronquitis crónica en una planta de ingeniería de Múnich. La exposición verdadera al polvo no podía medirse exactamente; `dust` resume varias muestras, y también se registraron tabaquismo y duración. Se analizan 488 trabajadores por encima del umbral 1.28: alrededor de 30 % presenta bronquitis y 74 % fuma. La concentración media es 1.93, prácticamente independiente de tabaquismo y duración.

El análisis requiere un prior razonablemente informativo para la varianza del error. Siguiendo el estudio original se toma una varianza inicial de 1.3:

```
data(bronch, package = "brinla")
bronch1 <- subset(bronch, dust >= 1.28)
prior.beta <- c(0, 0.01)
prec.u <- 1 / 1.3
prior.prec.u <- c(1 / 1.3, 0.01)

bronch.formula <- cbr ~ smoking + expo +
  f(dust, model = "meb", hyper = list(
    beta = list(param = prior.beta, fixed = FALSE),
    prec.u = list(param = prior.prec.u,
                  initial = log(prec.u), fixed = FALSE)
  ))

bronch.meb <- inla(
  bronch.formula, data = bronch1, family = "binomial",
  control.fixed = list(
    mean.intercept = prior.beta[1], prec.intercept = prior.beta[2],
    mean = prior.beta[1], prec = prior.beta[2]
  )
)
bronch.meb <- inla.hyperpar(bronch.meb)
```

En el modelo ingenuo, el intervalo del efecto del polvo incluye cero. Tras corregir el error de Berkson, su media posterior es alrededor de 1.04 y el intervalo (0.40, 1.93): el efecto es positivo con probabilidad alta. También son positivos tabaquismo y duración.

Los métodos bayesianos ofrecen gran flexibilidad para errores de medición, pero su implementación MCMC específica puede ser lenta y difícil de diagnosticar. Los componentes `mec`, `meb`, las respuestas múltiples y `copy` hacen accesibles con INLA modelos que de otro modo exigirían algoritmos especializados.

11 Temas diversos en INLA

Este capítulo reúne extensiones sobre *splines*, datos funcionales, valores extremos y estimación de densidades.

11.1. *Splines* como modelos mixtos

En la regresión no paramétrica

$$Y_i = f(x_i) + \varepsilon_i, \quad \varepsilon_i \sim N(0, \sigma_\varepsilon^2),$$

la función suave puede representarse como un modelo lineal mixto.

11.1.1. Bases de potencia truncada

Los *splines* de base de potencia truncada (TPB) usan nudos en cuantiles de x . Si $a_+^p = a^p$ para $a > 0$ y cero en otro caso,

$$f(x_i) = \beta_0 + \beta_1 x_i + \cdots + \beta_p x_i^p + \sum_{j=1}^r u_j (x_i - t_j)_+^p.$$

Con matrices $\mathbf{X}$ para el polinomio y $\mathbf{Z}$ para las bases truncadas,

$$\mathbf{y} = \mathbf{X}\beta + \mathbf{Z}\mathbf{u} + \varepsilon, \quad \mathbf{u} \sim N(\mathbf{0}, \sigma_u^2 \mathbf{I}), \quad \varepsilon \sim N(\mathbf{0}, \sigma_\varepsilon^2 \mathbf{I}). \quad (11.1)$$

El cociente $\lambda = \sigma_\varepsilon^2 / \sigma_u^2$ controla la suavidad. En un análisis frecuentista se emplean BLUP y REML; en el bayesiano se asignan priors gaussianos difusos a β y priors débiles a las varianzas. Una regla usual toma $r = \min(n_x/4, 35)$, donde n_x es el número de valores distintos, aunque suelen bastar entre 5 y 20 nudos.

11.1.2. *Splines* de O'Sullivan

Los O-splines combinan bases B-spline cúbicas con la penalización del *spline* de suavizado:

$$\int \{f''(x)\}^2 dx = \beta^\top \Omega \beta,$$

y minimizan

$$(\mathbf{y} - \mathbf{B}\beta)^\top (\mathbf{y} - \mathbf{B}\beta) + \lambda \beta^\top \Omega \beta. \quad (11.2)$$

Una descomposición espectral de Ω separa partes fijas y aleatorias y produce de nuevo el modelo mixto (11.1). Con nudos equiespaciados, los P-splines cúbicos sustituyen Ω por $\mathbf{D}_2^\top \mathbf{D}_2$; las tres familias están por tanto estrechamente relacionadas.

11.1.3. Ingresos de trabajadores canadienses

Los datos contienen 205 pares de edad y logaritmo del ingreso anual. Para TPB cuadrático, `spline.mixed()` genera las matrices del modelo:

```
library(INLA)
library(brinla)
data(age.income, package = "SemiPar")

X <- spline.mixed(age.income$age, degree = 2, type = "TPB")$X
Z <- spline.mixed(age.income$age, degree = 2, type = "TPB")$Z
age.income$ID <- seq_len(nrow(age.income))

formula <- log.income ~ -1 + X +
  f(ID, model = "z", Z = Z,
    hyper = list(prec = list(param = c(1e-6, 1e-6))))
result.tpb <- inla(formula, data = age.income,
  control.predictor = list(compute = TRUE))
```

Se excluye el intercepto porque ya está en **X**. La curva y sus bandas aparecen en `summary.fitted.values`; los coeficientes fijos y aleatorios se conservan por separado.

El O-spline se ajusta con el mismo código cambiando `type = "OSS"`. En este ejemplo es un poco menos suave aun con los mismos nudos y priors. También puede expresarse directamente como

$$\mathbf{y} \mid \beta, \sigma_\varepsilon^2 \sim N(\mathbf{B}\beta, \sigma_\varepsilon^2 \mathbf{I}), \quad \beta \mid \sigma_\beta^2 \sim N(\mathbf{0}, \sigma_\beta^2 \Omega^-). \quad (11.3)$$

```

B.tmp <- spline.mixed(age.income$age, type = "OSS")$B
Bmat <- as(B.tmp, "sparseMatrix")
Q <- as(spline.mixed(age.income$age, type = "OSS")$Q, "sparseMatrix")
data.inla <- list(y = age.income$log.income, x = 1:ncol(Bmat))
formula <- y ~ -1 +
  f(x, model = "generic0", Cmatrix = Q,
    hyper = list(prec = list(param = c(1e-6, 1e-6))))
result.oss <- inla(formula, data = data.inla,
  control.predictor = list(A = Bmat, compute = TRUE))

```

Las formulaciones directa y mixta suavizan coeficientes distintos y pueden producir pequeñas diferencias pese a compartir priors nominales. La misma construcción se extiende a respuestas no gaussianas cambiando `family`.

11.2. Análisis de varianza para datos funcionales

Los datos funcionales son curvas o superficies, tratadas como realizaciones completas y no como simples secuencias de puntos. Un ANOVA funcional de una vía es

$$Y_{ik}(x) = \mu(x) + \alpha_i(x) + \varepsilon_{ik}(x), \quad (11.4)$$

donde μ es la media global y α_i el efecto del nivel i . Se requiere una restricción como $\sum_i \alpha_i(x) = 0$ o fijar un nivel de referencia.

Con dos factores y una respuesta de familia exponencial,

$$g(\mu_{ijk}(x)) = \mu(x) + \alpha_i(x) + \beta_j(x) + \gamma_{ij}(x). \quad (11.5)$$

Las restricciones apropiadas identifican los efectos principales y la interacción. Priors gaussianos suaves convierten estos modelos en gaussianos latentes; los conjuntos de excursión permiten determinar regiones donde una función efecto difiere simultáneamente de cero.

11.2.1. Imagen por tensor de difusión

Los datos DTI contienen perfiles de anisotropía fraccional de pacientes con esclerosis múltiple a lo largo del cuerpo calloso y del tracto corticoespinal derecho (RCST). Se seleccionan 18 pacientes con cuatro visitas y se analiza RCST. Las discontinuidades de algunos perfiles reflejan valores ausentes.

Como la respuesta está entre cero y uno, se usa una beta con media $p_{ij}(x)$:

$$\text{logit}\{p_{ij}(x)\} = \mu(x) + \alpha_i(x), \quad i = 1, 2, 3, 4, \quad (11.6)$$

tomando $\alpha_4(x) = 0$. Así, μ es la media de la cuarta visita. Las funciones reciben priors RW2.

```

data(DTI, package = "refund")
DTI.sub <- DTI[DTI$Nscans == 4 & DTI$case == 1, ]
ns <- ncol(DTI.sub$rcst)
ng <- length(unique(DTI.sub$visit))
n <- length(unique(DTI.sub$ID))

D1 <- Matrix::Matrix(rep(1, ng * n), ng * n, 1)
A.mu <- kronecker(D1, Matrix::Diagonal(n = ns))
D2 <- Matrix::Diagonal(n = ng - 1)
D3 <- Matrix::Matrix(rep(0, ng - 1), 1, ng - 1)
D4 <- kronecker(rbind(D2, D3), Matrix::Diagonal(n = ns))
A.alpha <- kronecker(Matrix::Matrix(rep(1, n), n, 1), D4)
A <- cbind(A.mu, A.alpha)

```

Se crean índices para μ , las tres réplicas de α y sus combinaciones lineales:

```

mu <- 1:ns
alpha.idx <- rep(1:ns, ng - 1)
alpha.rep <- rep(1:(ng - 1), each = ns)
mu2 <- c(mu, rep(NA, length(alpha.idx)))
alpha2 <- c(rep(NA, length(mu)), alpha.idx)
alpha2.rep <- c(rep(NA, length(mu)), alpha.rep)

y <- as.vector(t(DTI.sub$rcst))
data.inla <- list(y = y, mu = mu2, alpha = alpha2,
                 alpha.rep = alpha2.rep)
formula <- y ~ -1 +
  f(mu, model = "rw2", constr = FALSE, scale.model = TRUE) +
  f(alpha, model = "rw2", constr = FALSE, scale.model = TRUE,
     replicate = alpha.rep)

```

`inla.make.lincombs()` construye $\mu + \alpha_i$ para las primeras visitas. El ajuste usa `family = "beta"`, la matriz A , `config = TRUE` y esas combinaciones. Los perfiles medios tienen formas semejantes y se desplazan hacia arriba con las visitas; las diferencias respecto de la cuarta visita se aplanan progresivamente.

Para localizar diferencias simultáneamente significativas:

```

res.excl <- excursions.brinla(
  result, name = "alpha", ind = 1:ns,
  u = 0, type = "!=" , alpha = 0.05, method = "NIQC"
)

```

Se repite con los índices de los otros efectos. Las regiones de excursión se reducen a medida que avanza el seguimiento; las tres comparten aproximadamente las posiciones 10 a 40. Esto indica un efecto funcional de visita y sugiere que la parte media del RCST cambia más deprisa que los extremos.

11.3. Valores extremos

Cuando interesa el máximo de muchas variables —por ejemplo, la mayor reclamación o el caudal máximo— se usa la distribución generalizada de valores extremos (GEV):

$$F(y \mid \mu, \tau, \xi) = \exp \left[-\{1 + \xi \sqrt{\tau s} (y - \mu)\}^{-1/\xi} \right],$$

definida cuando el término entre llaves es positivo. μ es localización, τ precisión, ξ forma y s un factor fijo de escala. El límite $\xi \rightarrow 0$ es Gumbel; $\xi > 0$ produce Fréchet y $\xi < 0$ una Weibull invertida con cota superior.

11.3.1. Caudales máximos del río Calder

Se observan máximos anuales en Cumbria entre 1973 y 2014. Una tendencia lineal en la localización GEV evita la inadecuación de un modelo normal para colas y asimetría:

```
data(calder, package = "brinla")
calder$year <- calder$WaterYear - 1973
imod <- inla(Flow ~ 1 + year, data = calder,
             family = "gev", scale = 0.1)
```

El escalamiento lleva la respuesta a unidades pequeñas y facilita la convergencia. La pendiente posterior es aproximadamente 0.76 y $P(\beta_1 < 0) \approx 0.0019$, evidencia fuerte de aumento del caudal máximo.

El máximo observado, 173.17 m³/s en 1997, tiene probabilidad de excedencia estimada 0.0086 y, por tanto, intervalo de recurrencia puntual de unos 116 años. Para 2017, la tendencia reduce ese intervalo a unos 74 años.

Un intervalo creíble requiere la dependencia conjunta entre τ , ξ , intercepto y pendiente. Se habilita la configuración posterior y se muestrea conjuntamente:

```
nsamp <- 999
imod <- inla(
  Flow ~ 1 + year, data = calder, family = "gev", scale = 0.1,
  control.compute = list(config = TRUE),
  control.inla = list(int.strategy = "grid", dz = 0.2)
)
post <- inla.posterior.sample(nsamp, imod)
```

El muestreo refleja la cuadrícula de integración de hiperparámetros; reducir dz de 0.75 a 0.2 la hace más fina, a mayor costo. Transformando cada muestra al intervalo de recurrencia se obtiene una mediana cercana a 70 años y un intervalo creíble aproximado de 21 a 513 años. La gran amplitud es sustantiva: incluso su extremo inferior puede ser preocupante para la planificación de inundaciones.

11.4. Estimación de densidades con INLA

El procedimiento *root-unroot* convierte la estimación de una densidad en regresión no paramétrica:

1. Se divide la muestra en T intervalos iguales y se cuentan $C_1, \dots, C_T$ observaciones.
2. Se aplica la transformación estabilizadora $Y_j = \sqrt{C_j + 1/4}$.
3. Se ajusta $Y_j = m_j + \varepsilon_j$ mediante RW2 y se obtienen la media y cuantiles posteriores de m_j .
4. Se eleva al cuadrado y se normaliza para que la densidad integre uno; lo mismo produce las bandas creíbles.

El paso de suavizado corresponde a una versión discreta de la ecuación

$$\frac{d^2 m(z)}{dz^2} = \sigma \frac{dW(z)}{dz}. \quad (11.7)$$

Una aproximación de Galerkin con bases lineales por tramos convierte sus pesos en un GMRF de precisión dispersa y rango $n - 2$, lo que hace viable el cálculo con INLA.

`bri.density()` implementa el algoritmo. En una muestra normal estándar:

```
set.seed(123)
x <- rnorm(500)
den.inla <- bri.density(x, cut = 0.3)
den.kernel <- density(x, bw = "SJ")
```

y en una mezcla bimodal:

```
set.seed(123)
z <- c(rnorm(500, -1.5, 1), rnorm(500, 2.5, 0.75))
den.inla <- bri.density(z, cut = 0.3)
den.kernel <- density(z, bw = "SJ")
```

Los ajustes INLA son muy próximos a los estimadores kernel con ancho de banda *plug-in* de Sheather–Jones. La ventaja bayesiana es que las bandas creíbles de la densidad aparecen como producto natural del mismo ajuste, sin un procedimiento adicional.

Blangiardo, Marta, y Michela Cameletti. 2015. *Spatial and Spatio-temporal Bayesian Models with R-INLA*. Wiley.

Carlin, Bradley P., y Thomas A. Louis. 2008. *Bayesian Methods for Data Analysis*. 3.^a ed. CRC Press.

Chaloner, Kathryn, y Rollin Brant. 1988. «A Bayesian Approach to Outlier Detection and Residual Analysis». *Biometrika* 75: 651-59.

Chatterjee, Samprit, y Ali S. Hadi. 2015. *Regression Analysis by Example*. 5.^a ed. Wiley.

Cox, D. R. 1972. «Regression Models and Life-Tables». *Journal of the Royal Statistical Society: Series B* 34: 187-220.

Dawid, A. P. 1984. «Statistical Theory: The Prequential Approach». *Journal of the Royal Statistical Society: Series A* 147: 278-92.

- Diebold, Francis X., Todd A. Gunther, y Anthony S. Tay. 1998. «Evaluating Density Forecasts». *International Economic Review* 39: 863-83.
- Draper, David. 1995. «Assessment and Propagation of Model Uncertainty». *Journal of the Royal Statistical Society: Series B* 57: 45-97.
- Evans, Michael, y Hadas Moshonov. 2006. «Checking for Prior-Data Conflict». *Bayesian Analysis* 1: 893-914.
- Everitt, Brian S., y Torsten Hothorn. 2006. *A Handbook of Statistical Analyses Using R*. Chapman; Hall/CRC.
- Ferkingstad, Egil, y Håvard Rue. 2015. «Improving the INLA Approach for Approximate Bayesian Inference for Latent Gaussian Models». *Electronic Journal of Statistics* 9: 2706-31.
- Freedman, Wendy L. et al. 2001. «Final Results from the Hubble Space Telescope Key Project to Measure the Hubble Constant». *The Astrophysical Journal* 553: 47-72.
- Geisser, Seymour, y William F. Eddy. 1979. «A Predictive Approach to Model Selection». *Journal of the American Statistical Association* 74: 153-60.
- Gelfand, Alan E., y Adrian F. M. Smith. 1990. «Sampling-Based Approaches to Calculating Marginal Densities». *Journal of the American Statistical Association* 85: 398-409.
- Gelman, Andrew, John B. Carlin, Hal S. Stern, David B. Dunson, Aki Vehtari, y Donald B. Rubin. 2014. *Bayesian Data Analysis*. 3.^a ed. CRC Press.
- Gneiting, Tilmann, Fadoua Balabdaoui, y Adrian E. Raftery. 2007. «Probabilistic Forecasts, Calibration and Sharpness». *Journal of the Royal Statistical Society: Series B* 69: 243-68.
- Hadfield, Jarrod D. 2010. «MCMC Methods for Multi-response Generalized Linear Mixed Models: The MCMCglmm R Package». *Journal of Statistical Software* 33 (2): 1-22.
- Hastings, W. K. 1970. «Monte Carlo Sampling Methods Using Markov Chains and Their Applications». *Biometrika* 57: 97-109.
- Hawkins, Bradford A. 2005. «Pattern and Process in Host-Parasitoid Interactions».
- Held, Leonhard, Birgit Schrödle, y Håvard Rue. 2010. «Posterior and Cross-validatory Predictive Checks: A Comparison of MCMC and INLA». *Statistical Modelling* 10: 397-419.
- Hjort, Nils Lid, Fredrik A. Dahl, y Gunnhildur H. Steinbakk. 2006. «Post-Processing Posterior Predictive P Values». *Journal of the American Statistical Association* 101: 1157-74.
- Hoerl, Arthur E., y Robert W. Kennard. 1970. «Ridge Regression: Biased Estimation for Nonorthogonal Problems». *Technometrics* 12: 55-67.
- Jolliffe, Ian T. 1982. «A Note on the Use of Principal Components in Regression». *Applied Statistics* 31: 300-303.
- Lange, Kenneth L., Roderick J. A. Little, y Jeremy M. G. Taylor. 1989. «Robust Statistical Modeling Using the t Distribution». *Journal of the American Statistical Association* 84: 881-96.
- Le Cam, Lucien. 2012. *Asymptotic Methods in Statistical Decision Theory*. Springer.
- Lunn, David, Christopher Jackson, Nicky Best, Andrew Thomas, y David Spiegelhalter. 2012. *The BUGS Book*. CRC Press.
- Marshall, E. C., y David J. Spiegelhalter. 2007. «Identifying Outliers in Bayesian Hierarchical Models: A Simulation-Based Approach». *Bayesian Analysis* 2: 409-44.
- Martins, Thiago G., Daniel Simpson, Finn Lindgren, y Håvard Rue. 2013. «Bayesian Computing with INLA: New Features». *Computational Statistics and Data Analysis* 67: 68-83.
- Meng, Xiao-Li. 1994. «Posterior Predictive P-Values». *Annals of Statistics* 22: 1142-60.
- Metropolis, Nicholas, Arianna W. Rosenbluth, Marshall N. Rosenbluth, Augusta H. Teller, y Edward Teller. 1953. «Equation of State Calculations by Fast Computing Machines». *The Journal of Chemical Physics* 21: 1087-92.
- Montgomery, Douglas C. 2013. *Design and Analysis of Experiments*. 8.^a ed. Wiley.
- Pettit, L. I. 1990. «The Conditional Predictive Ordinate for the Normal Distribution». *Journal of*

- the Royal Statistical Society: Series B* 52: 175-84.
- Plummer, Martyn. 2003. «JAGS: A Program for Analysis of Bayesian Graphical Models Using Gibbs Sampling».
- Rue, Håvard, y Leonhard Held. 2005. *Gaussian Markov Random Fields: Theory and Applications*. Chapman; Hall/CRC.
- Rue, Håvard, Sara Martino, y Nicolas Chopin. 2009. «Approximate Bayesian Inference for Latent Gaussian Models by Using Integrated Nested Laplace Approximations». *Journal of the Royal Statistical Society: Series B* 71: 319-92.
- Rue, Håvard, Andrea Riebler, Sigrunn H. Sørbye, Janine B. Illian, Daniel P. Simpson, y Finn K. Lindgren. 2017. «Bayesian Computing with INLA: A Review». *Annual Review of Statistics and Its Application* 4: 395-421.
- Shumway, Robert H., y David S. Stoffer. 2011. *Time Series Analysis and Its Applications*. 3.^a ed. Springer.
- Simpson, Daniel, Håvard Rue, Andrea Riebler, Thiago G. Martins, y Sigrunn H. Sørbye. 2017. «Penalising Model Component Complexity: A Principled, Practical Approach to Constructing Priors». *Statistical Science* 32: 1-28.
- Singer, Judith D., y John B. Willett. 2003. *Applied Longitudinal Data Analysis*. Oxford University Press.
- Spiegelhalter, David J., Nicola G. Best, Bradley P. Carlin, y Angelika van der Linde. 2002. «Bayesian Measures of Model Complexity and Fit». *Journal of the Royal Statistical Society: Series B* 64: 583-639.
- . 2014. «The Deviance Information Criterion: 12 Years On». *Journal of the Royal Statistical Society: Series B* 76: 485-93.
- Stan Development Team. 2016. *Stan Modeling Language Users Guide and Reference Manual*.
- Tierney, Luke, y Joseph B. Kadane. 1986. «Accurate Approximations for Posterior Moments and Marginal Densities». *Journal of the American Statistical Association* 81: 82-86.
- Umlauf, Nikolaus, Daniel Adler, Thomas Kneib, Stefan Lang, y Achim Zeileis. 2015. «Structured Additive Regression Models: An R Interface to BayesX». *Journal of Statistical Software* 63 (21): 1-46.
- Watanabe, Sumio. 2010. «Asymptotic Equivalence of Bayes Cross Validation and Widely Applicable Information Criterion». *Journal of Machine Learning Research* 11: 3571-94.
- Wood, Simon N. 2006. *Generalized Additive Models: An Introduction with R*. Chapman; Hall/CRC.